Arquitetura, treinamento e transferência

Nestor, Letícia e Gabriel
Introdução a Deep Learning - extensão do projeto IMDb.

Este estudo treina CNNs e ajusta BERT, DistilBERT e ModernBERT-base para relacionar resultados com convoluções, atenção, otimização e generalização. São 87 treinos reais com três sementes: 42 CNNs, 27 cabeças sobre encoders congelados e 18 ajustes completos. Um baseline TF-IDF completa a comparação.

Pergunta	Experimento	Material da disciplina
Como filtros locais classificam texto?	CNN 1D, janelas e largura	Prince 10; slides 10
Adam e SGD aprendem igual?	Taxa comum e três taxas por método	Prince 6; slides 06
Quando o ajuste se torna overfitting?	Dropout e curvas treino/validação	Prince 8-9; slides 08-09
O que muda com pré-treinamento?	Encoder congelado e ajuste integral	Prince 11-12; slides 11-12

Os papéis dos dados

Treino: **6.144** resenhas. Validação: **1.536**. Nova auditoria interna: **2.048**, excluindo todos os papéis da extensão MLP. As amostras vêm apenas do treino oficial limpo. O teste oficial de 25 mil exemplos não foi reaberto. Esta auditoria é interna, não um novo benchmark externo.

Todos os modelos recebem o mesmo prefixo de até 128 palavras separadas por espaço. A CNN e os encoders admitem no máximo 256 tokens; a truncagem adicional é medida. O TF-IDF usa o prefixo completo, sem esse limite adicional. O rótulo continua sendo o da resenha completa, mesmo quando o prefixo omite a avaliação final.

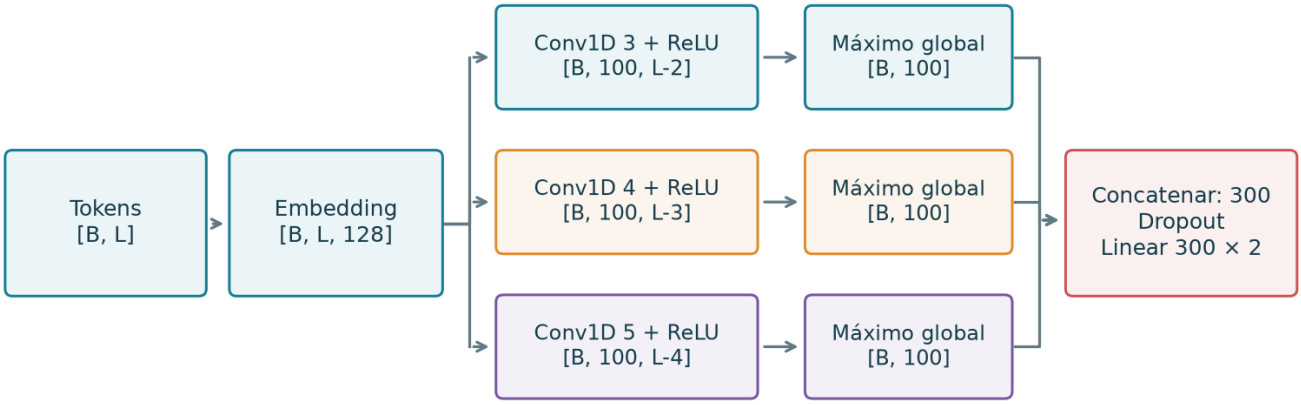
Seleção antes da auditoria

Cada treino escolhe a época com menor CE de validação. Para cada método, escolhemos a taxa que minimiza a média dessas perdas nas três sementes. Congelamos código, revisões, pesos, taxas e épocas antes de transferir a entrada da nova auditoria para a execução.

Os relatórios originais, o estudo MLP e o steering do Qwen permanecem separados. Não misturamos métricas de testes, prefixos ou divisões diferentes.

O apêndice BPE acrescenta três treinos da mesma CNN com subpalavras, comparados a três checkpoints por palavras em outra auditoria interna. A comparação distingue aprender o tokenizer de aprender os pesos da rede.

A CNN usada neste estudo



L ≤ 256 tokens. Filtros compartilham pesos entre posições. Janelas de padding não competem pelo máximo.

A entrada é uma sequência de índices. Um embedding treinável associa a cada índice 128 números. Cada filtro combina todos esses canais em uma janela local de 3, 4 ou 5 tokens. Os mesmos pesos deslizam pelas posições. A ReLU introduz não linearidade; o máximo global retém a maior resposta de cada filtro.

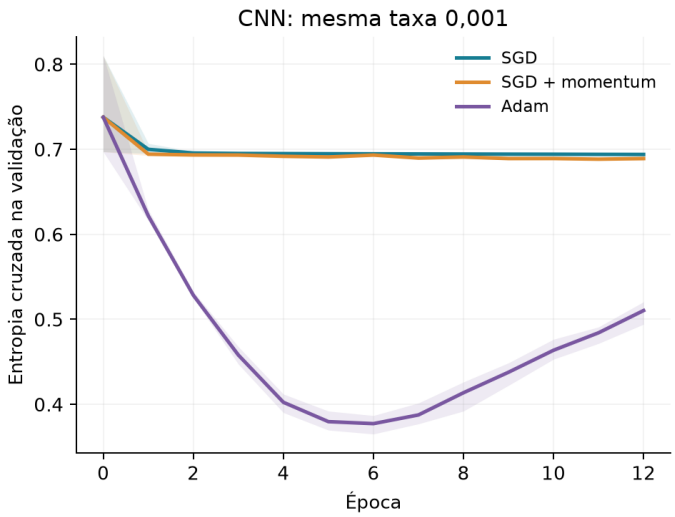
Cem filtros em cada uma das três janelas produzem 300 máximos. Concatenamos esses valores, aplicamos dropout e uma camada linear com duas saídas. O modelo principal tem **2.714.502** parâmetros treináveis, incluindo o embedding. Ele aprende do zero, sem vetores pré-treinados. A saída contém dois logits; usamos softmax para exibir probabilidades.

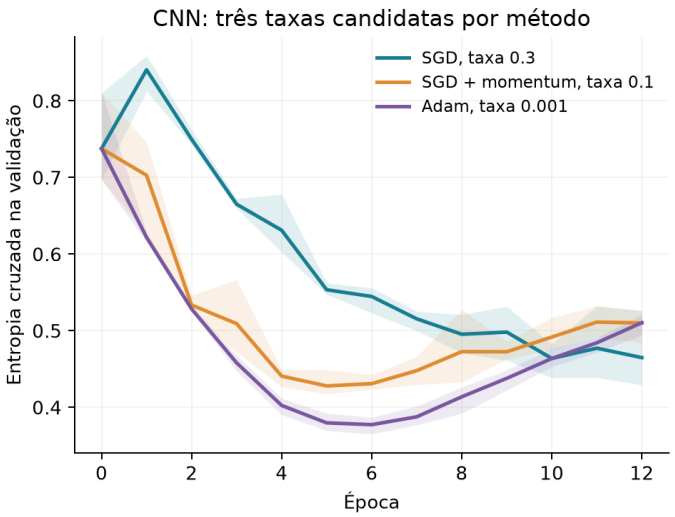
Operação	Formato por minibatch
Índices	B × L
Embedding	B × L × 128
Conv1D de janela k	B × 100 × (L-k+1)
Máximo de cada ramo	B × 100
Concatenação e saída	B × 300; depois B × 2

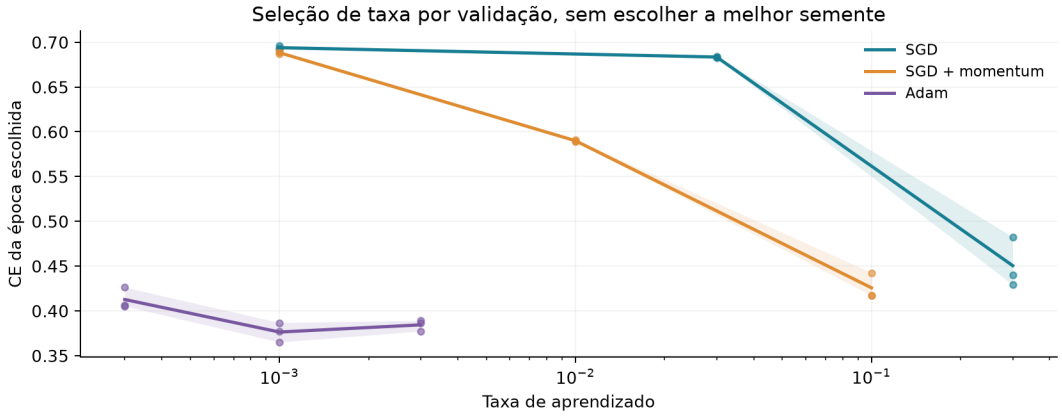
No padding, janelas inválidas não competem pelo máximo. Para entradas menores que uma janela, o código mantém uma janela mínima com zeros de padding. A convolução preserva ordem local; o máximo perde a localização exata do padrão vencedor. A rede rasa não modela todas as relações distantes do texto.

Fontes: Prince 10; Redes Convolucionais, páginas do arquivo 11-22 e 36; inspiração arquitetural em Kim (2014), sem reproduzir integralmente seu protocolo.

A taxa muda a comparação





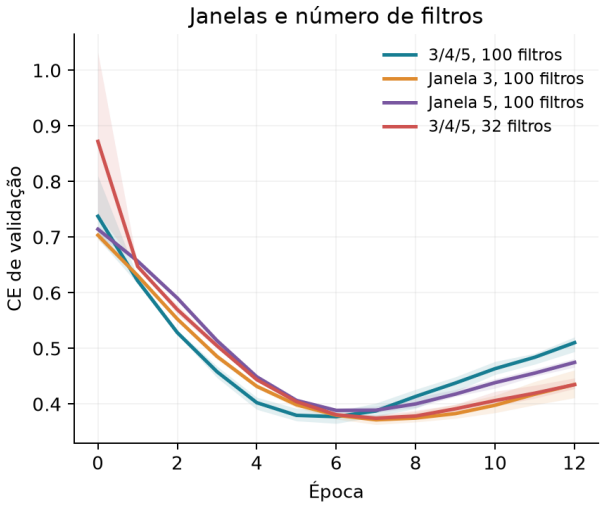


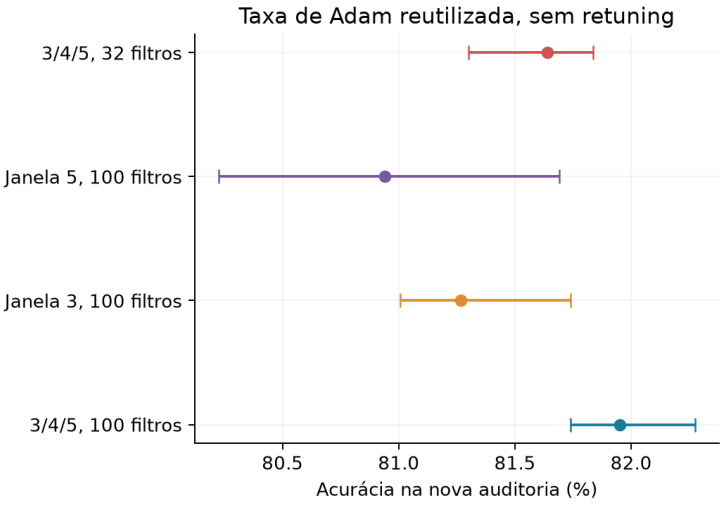
Método	Taxa escolhida	Acurácia interna	CE interna
SGD	0.3	76,53%	0.480
SGD + momentum	0.1	79,35%	0.470
Adam	0.001	81,95%	0.409

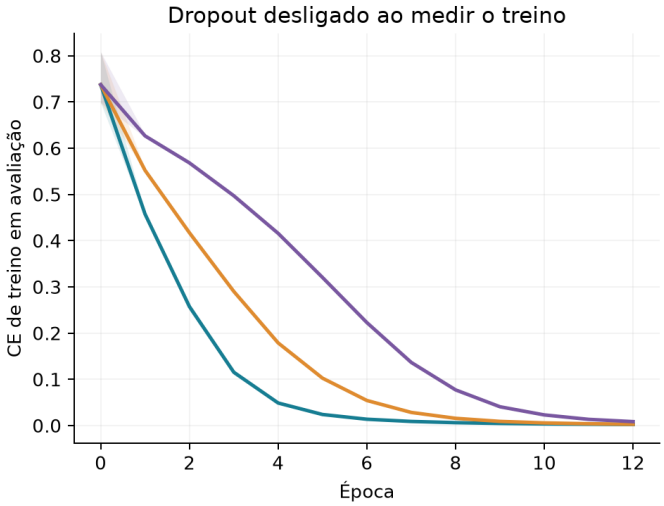
As três taxas de cada algoritmo estão fixadas no protocolo. Cada condição usa os mesmos pesos e minibatches por semente, doze épocas e clipping de norma 1. O painel com 0,001 responde o que ocorre mantendo a taxa. O outro inclui a escolha de validação, uma comparação diferente. Faixas mostram mínimo/máximo das três sementes.

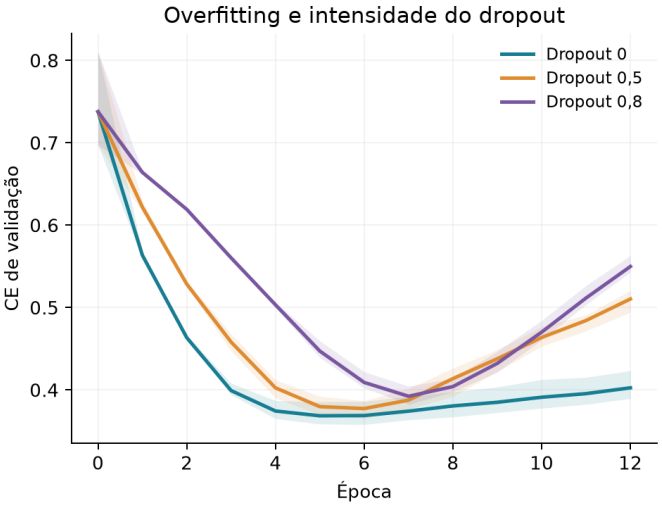
Os métodos usam escalas de atualização diferentes. Um método lento na taxa comum pode melhorar com outra taxa. Os dados descrevem este orçamento e grade; não estabelecem superioridade universal de um otimizador. Fonte: Prince 6.1-6.5 e slides Ajuste de Modelos.

Filtros e dropout na CNN









Variante de dropout	Épocas escolhidas	CE interna	Acurácia interna
Dropout 0,5	5, 6, 6	0.409	81,95%
Dropout 0	5, 6, 5	0.411	81,80%
Dropout 0,8	7, 7, 7	0.422	80,44%

A grade de arquitetura compara janelas 3, 5 ou 3/4/5 e 32 ou cem filtros por janela. Todas as variantes reutilizam a taxa de Adam escolhida para a CNN principal. O embedding ocupa grande parte dos parâmetros, por isso reduzir filtros não reduz a rede inteira na mesma proporção.

O treino continua por doze épocas para mostrar a trajetória. A avaliação usa o checkpoint escolhido pela CE de validação. Curvas de treino com dropout desligado permitem distinguir ajuste dos dados e o ruído da regularização. Fonte: Prince 8-10 e slides Regularização.

BERT, DistilBERT e ModernBERT

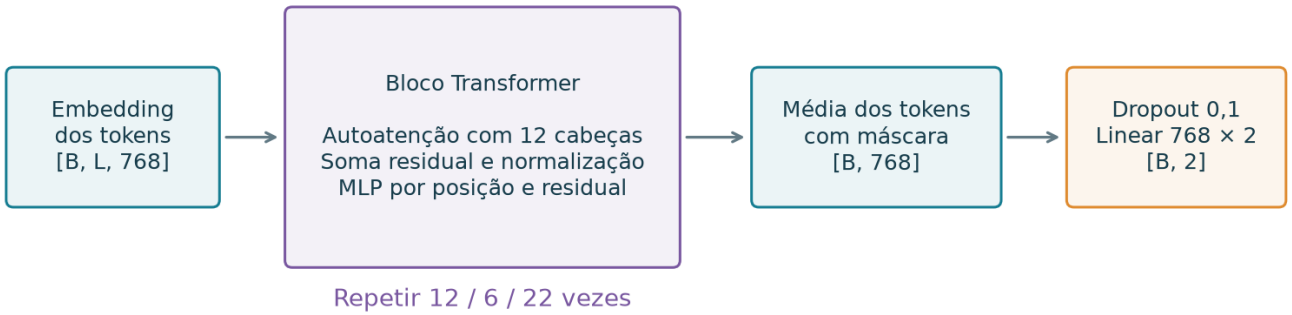


Diagrama funcional. Ordem de normalização e atenção variam. ModernBERT alterna atenção local e global e usa RoPE.

Um encoder Transformer transforma cada token usando o contexto. Na autoatenção, projeções aprendidas produzem queries, keys e values. A compatibilidade entre query e key determina os pesos da combinação dos values. Há múltiplas cabeças, transformações por posição, resíduos e normalização. A informação de posição permite distinguir ordens diferentes.

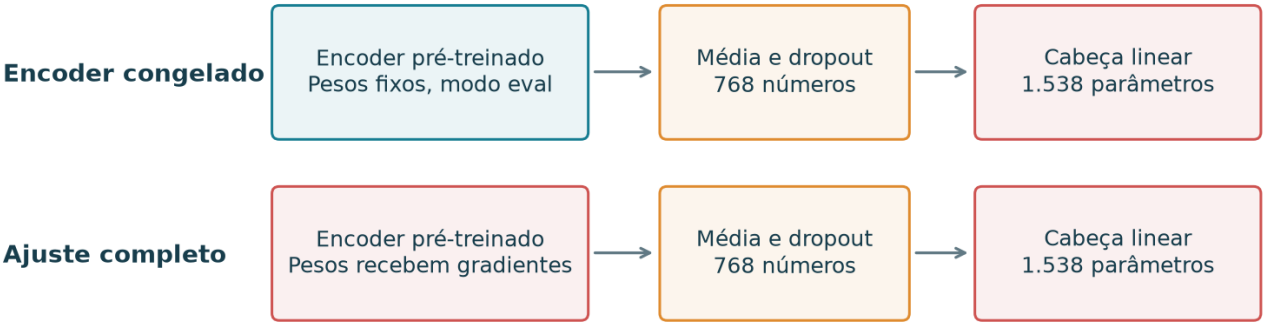
Encoder	Blocos	Dimensão / cabeças	Parâmetros do classificador completo
BERT-base	12	768 / 12	108.893.186
DistilBERT	6	768 / 12	66.364.418
ModernBERT-base	22	768 / 12	149.015.810

BERT-base usa atenção bidirecional global e posições aprendidas. DistilBERT reduz a pilha para seis blocos e incorpora destilação em seu pré-treinamento. ModernBERT-base combina 22 blocos, posições rotativas e atenção local intercalada com global. Não usamos sua capacidade máxima de contexto: todos recebem o mesmo prefixo curto neste ensaio.

A saída de cada token tem 768 dimensões. A média dos estados finais exclui padding e tokens especiais. Acrescentamos dropout 0,1 e Linear(768,2). O pooler original de BERT é removido; por isso a contagem difere de tabelas que incluem pooler ou cabeça de pré-treinamento.

O diagrama é funcional. A ordem de normalização e dos resíduos varia entre as famílias. Fontes: Prince 11-12; Transformers, páginas 7-18, 21-31 e 35-38; Devlin et al., Sanh et al. e Warner et al.

Congelar ou ajustar todos os pesos



Congelado: vetor pré-computado, treina a cabeça. Completo: backward atravessa também todos os blocos do encoder.

Regime	Pesos treináveis	Receita	Grade
Encoder congelado	Cabeça: 1.538	40 épocas, batch 128, Adam	0,001; 0,01; 0,1
Ajuste completo	Encoder e cabeça	3 épocas, batch 32, AdamW	0,00001; 0,00003

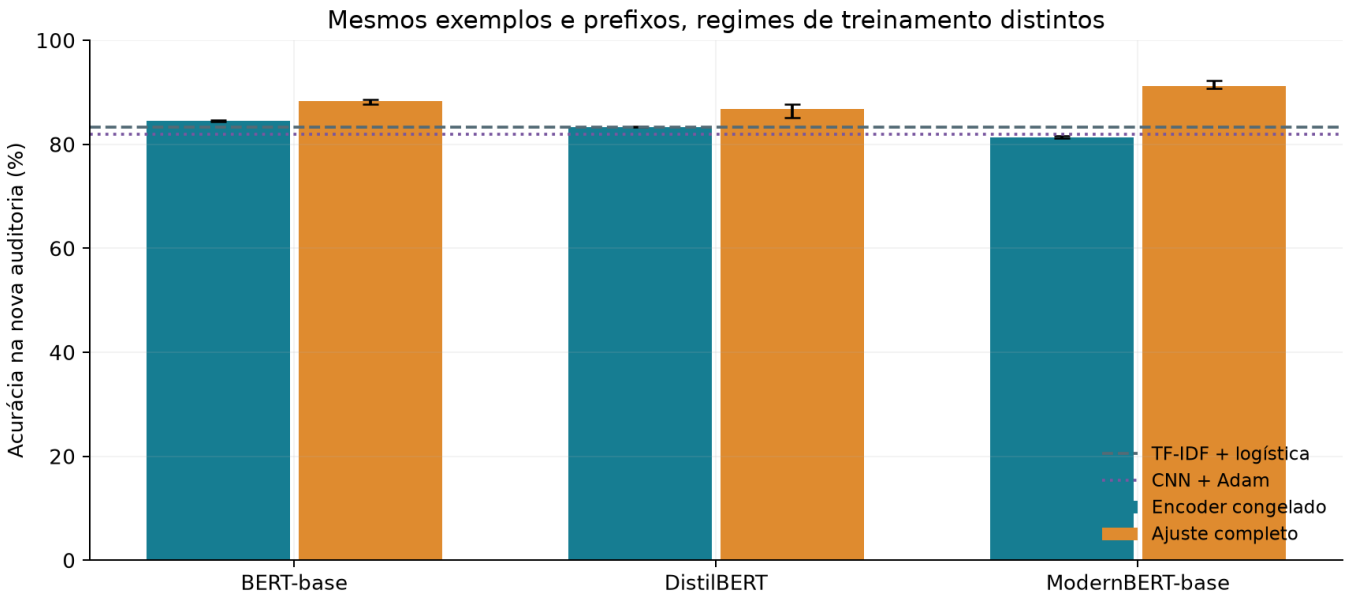
No modo congelado, o encoder fica em avaliação e gera vetores uma única vez. Nenhum gradiente atualiza seus pesos. A cabeça recebe gradientes e aprende a separar esses vetores. No ajuste completo, o backward atravessa também o encoder e adapta suas representações à tarefa.

As cabeças começam com os mesmos pesos na mesma semente. O ajuste completo usa warmup de 10%, redução linear da taxa, decaimento desacoplado de 0,01 nos pesos matriciais e clipping 1. Vieses e parâmetros de normalização ficam sem decaimento.

Esta comparação avalia duas receitas práticas. Orçamento, otimizador, dropout do encoder e atualização dos pesos mudam juntos. Portanto, não isolamos destravar o encoder como única causa de um ganho. A cabeça mantém dropout 0,1 nos dois regimes; no congelado, o encoder permanece determinístico em avaliação.

Os modelos partem de pré-treinamento público, sem checkpoints já ajustados no IMDb. Revisões e hashes estão fixados. Encoders usam BF16 com parâmetros e estado do otimizador FP32, atenção SDPA e TF32 desligado. A CNN usa FP32. Fonte: documentação oficial e protocolo executável.

Os resultados dos encoders

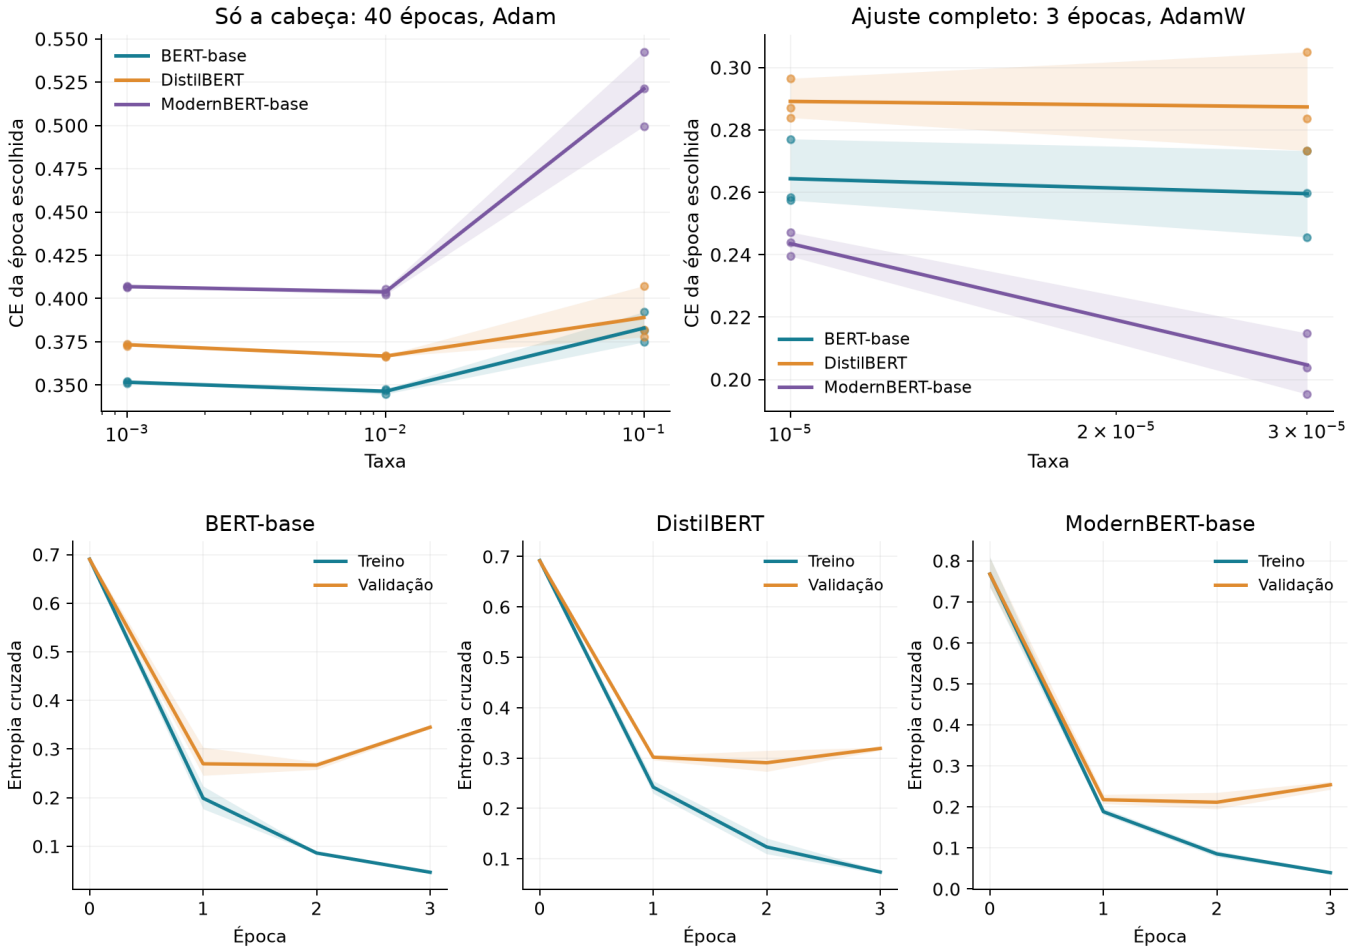


Modelo / regime	Taxa	Acurácia média	Mínimo - máximo	CE
BERT-base congelado	0.01	84,52%	84,42% - 84,62%	0.366
BERT-base completo	3e-05	88,31%	87,70% - 88,67%	0.303
DistilBERT congelado	0.01	83,35%	83,30% - 83,40%	0.384
DistilBERT completo	3e-05	86,80%	85,11% - 87,74%	0.338
ModernBERT-base congelado	0.01	81,30%	81,10% - 81,54%	0.410
ModernBERT-base completo	3e-05	91,24%	90,72% - 92,19%	0.246

No mesmo recorte, o baseline TF-IDF + logística tem acurácia 83,30% e CE 0.385. A CNN + Adam tem acurácia média 81,95%. São controles úteis para verificar se a complexidade adicional ajuda neste orçamento.

A amostra é a nova auditoria interna de 2.048 exemplos. A faixa entre três sementes não é intervalo de confiança sobre a população. A diferença entre famílias também inclui pré-treinamento, tokenização e escala. As probabilidades não foram calibradas e a CE pode divergir da acurácia.

Trajetórias e seleção na validação

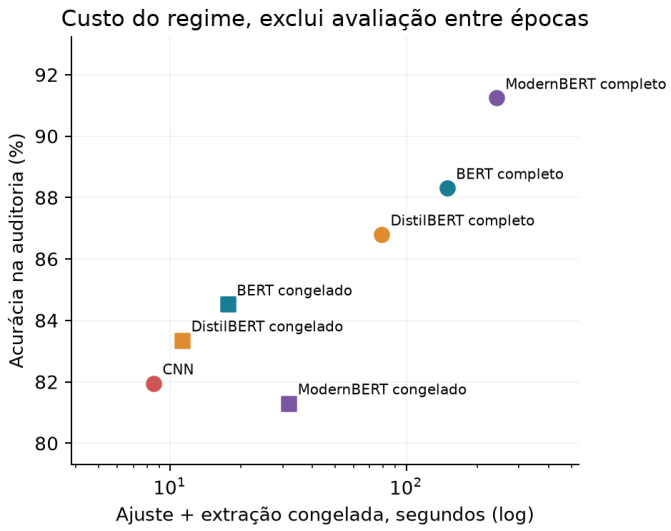


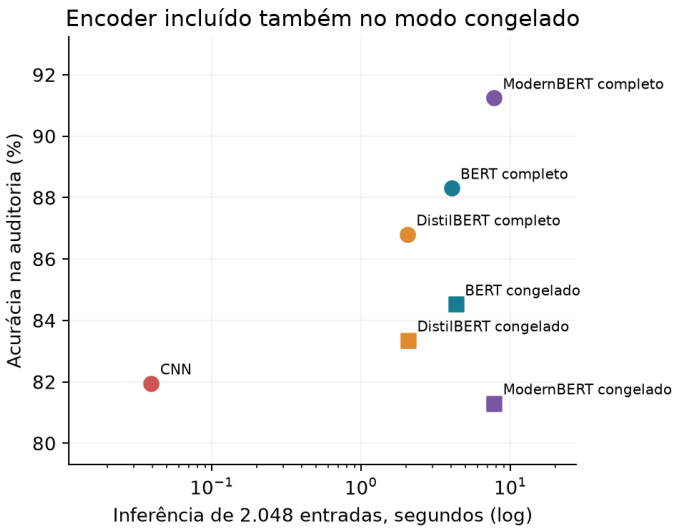
A grade congelada contém três taxas; a completa contém duas. Cada ponto usa três sementes. A escolha usa a média da CE de cada checkpoint selecionado, sem consultar a auditoria. As curvas inferiores mostram treino e validação com a taxa selecionada para o ajuste completo.

Três épocas são um orçamento, não uma prova de convergência. Um encoder pode precisar de outra taxa, regularização ou mais passos para alcançar seu melhor resultado. O objetivo é observar aprendizagem e custo com um protocolo explícito, mantendo todas as tentativas publicadas.

A curva da época zero mostra a cabeça aleatória e não participa da escolha de checkpoint. As condições congeladas não recalculam o encoder a cada época. O notebook permite consultar todas as trajetórias e taxas descartadas.

Qualidade e custo medidos juntos





Modelo / regime	Ajuste + vetores (s)	Inferência / 2.048 (s)
BERT-base congelado	17.57	4.30
BERT-base ajuste completo	148.93	4.02
DistilBERT congelado	11.28	2.06
DistilBERT ajuste completo	78.67	2.04
ModernBERT-base congelado	31.87	7.75
ModernBERT-base ajuste completo	240.99	7.72

No congelado, o ajuste inclui a extração dos vetores de treino e validação, mais a média do treino da cabeça. O ajuste completo e a CNN contam apenas os minibatches de treino. As avaliações entre épocas, o carregamento e o download ficam fora desse cronômetro. O tempo total por execução também está nos resultados.

Na inferência, somamos o encoder congelado ao custo da cabeça. Assim, não tratamos a cabeça isolada como se fosse o modelo completo. A medição usa batch 64, exclui tokenização e carregamento. Não há repetição sistemática de benchmark de latência.

A implementação usa atenção SDPA e não tenta extrair a máxima eficiência de cada arquitetura. BF16, formato de entrada e kernels afetam tempo. Valores medidos no NVIDIA GB10 não devem ser generalizados para outro hardware.

O mesmo texto em modelos diferentes

Positivo: exemplo próprio

I expected to hate this film. I was wrong. The strange opening leads to a clever story, the cast is excellent, and the ending is surprisingly warm. What looked like a disaster turned out to be a wonderful evening.

Modelo	P(positivo), sem calibração
CNN	0.838
BERT-base	0.975
DistilBERT	0.980
ModernBERT-base	0.987

Negativo: exemplo próprio

Beautiful images, a talented cast, and a memorable score are all here. Unfortunately the story is a mess. The impressive first ten minutes give way to repetitive scenes, empty speeches, and an ending that feels completely unearned. I cannot recommend it.

Modelo	P(positivo), sem calibração
CNN	0.105
BERT-base	0.002
DistilBERT	0.067
ModernBERT-base	0.039

Definimos estes textos antes de observar suas predições e os avaliamos após o congelamento, usando a semente 17 em todos os casos. Ilustram negação, reversão de expectativa e avaliação mista. A intenção do autor é uma referência didática, sem substituir um conjunto de avaliação anotado.

O notebook e o HTML mostram os quatro exemplos nos oito classificadores, além das janelas que contribuem à margem linear da CNN. Essa decomposição é exata na última camada, mas não estabelece causalidade das palavras sobre a decisão.

Ligação com a disciplina

Tema visto no curso	O que os experimentos mostram
Convolução e viés indutivo	Pesos compartilhados, janelas locais, pooling e filtros treináveis.
Gradientes e otimizadores	Taxa comum e taxa selecionada respondem perguntas diferentes.
Generalização e regularização	Curvas de validação escolhem checkpoints; dropout pode mudar o compromisso entre ajuste e generalização.
Resíduos e Transformers	Atenção e MLPs por posição usam caminhos residuais, com variantes entre famílias.
Espaço de representações	Congelar o encoder treina uma fronteira sobre vetores existentes. Ajuste integral modifica também os vetores.
Double descent e steering	Permanecem estudos separados: regressão sintética e intervenção nas ativações do Qwen, respectivamente.

Roteiro sugerido

Para uma fala curta, selecione o diagrama CNN, a comparação de otimizadores, as curvas de dropout, a distinção congelado/completo e a comparação dos encoders. Use double descent ou steering como uma demonstração adicional, conforme o tempo disponível. Os slides incluem notas e material de apoio para não transformar a fala numa lista de métricas.

Verificação e limites

O verificador reconstrói 217 métricas de treino/validação e auditoria, confirma as escolhas de taxa, as épocas e as partidas pareadas. Uma nova avaliação na GPU reconstrói os 43 checkpoints. O protocolo usa uma única divisão, três sementes e grades pequenas. Não mede superioridade universal nem isola o efeito da arquitetura do pré-treinamento. Não auditamos a presença de resenhas nos corpora de pré-treinamento.

Referências

Prince, Understanding Deep Learning, capítulos 6-12. Slides MAE5920: Redes Convolucionais, páginas do arquivo 11-22, 36 e 51-52; Transformers, páginas 7-18, 21-31 e 35-38. Os hashes do acervo ficam no catálogo de referências.

Kim (2014), ACL D14-1181. Devlin et al. (2019), ACL N19-1423. Sanh et al. (2019), arXiv:1910.01108. Warner et al. (2024), arXiv:2412.13663. Model card e implementação oficial de ModernBERT no Hugging Face. URLs no HTML e no catálogo docs/REFERENCIAS_SEQUENCIAS.json.

Aprender as peças do texto

O tokenizer por palavras monta um vocabulário de frequência no treino. O BPE também aprende no treino, mas começa com caracteres e combina pares frequentes. As regras aprendidas permitem representar palavras raras por partes. Depois congelamos essas regras e treinamos a CNN do zero.

Etapa	O que aprende	Como aprende
Tokenizer BPE	Vocabulário e regras de união	Contagem de pares no texto de treino, sem rótulos
CNN	Embeddings, filtros e saída	Gradientes da classificação usando os rótulos
Validação e auditoria	Nenhum parâmetro	Aplicam as regras e os pesos já aprendidos

Preservamos a limpeza da CNN: minúsculas, regex de palavras e números e espaços entre tokens. Usamos WhitespaceSplit, BPE de caracteres e marcador de fim de palavra </w>. Não usamos BPE de bytes nem os tokenizers dos Transformers. PAD é 0 e UNK é 1. O vocabulário final tem exatamente 20 mil entradas.

Exemplos do tokenizer aprendido

Palavra	Vocabulário por palavras	BPE
pallbearer	<unk>	p + all + bearer</w>
unwatchable	unwatchable	unwatchable</w>
wasn't	wasn't	wasn't</w>
cinematography	cinematography	cinematography</w>

Uma inferência passo a passo

As primeiras regras aprendidas no treino foram t + h; i + n; th + e</w>. Abaixo, aplicamos as regras já congeladas a uma palavra.

Passo	Estado da palavra pallbearer
0	p + a + l + l + b + e + a + r + e + r</w>
1	p + a + l + l + b + e + a + re + r</w>
2	p + al + l + b + e + a + re + r</w>
3	p + al + l + be + a + re + r</w>
4	p + all + be + a + re + r</w>
5	p + all + be + are + r</w>
6	p + all + be + arer</w>
7	p + all + bearer</w>

A sequência aplica as prioridades das regras já aprendidas. Ela não reaprende BPE na inferência. As peças não precisam corresponder a morfemas. Caracteres ausentes do alfabeto de treino ainda podem gerar UNK.

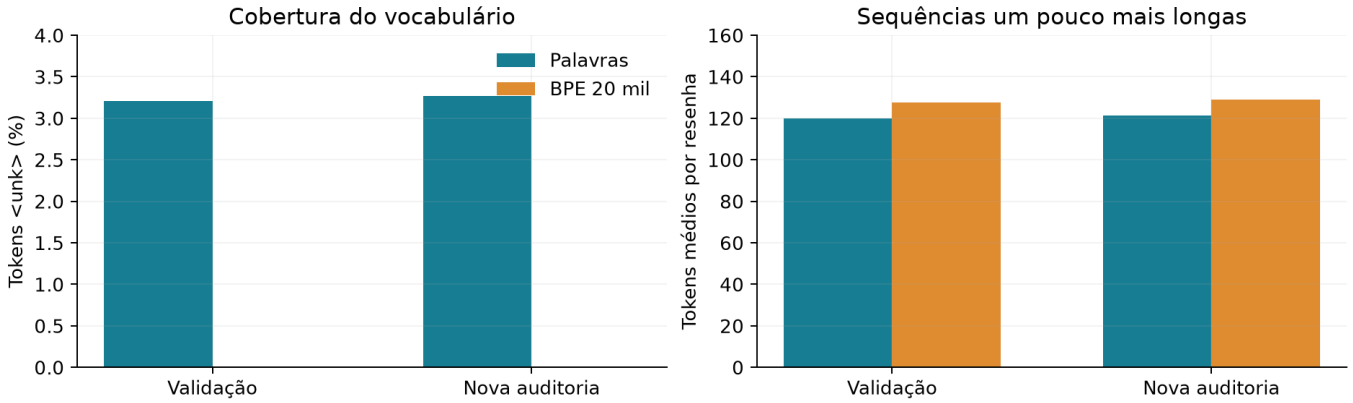
Fontes: Sennrich, Haddow e Birch (2016), ACL P16-1162; documentação Tokenizers, Quicktour. O artigo trata tradução e não garante melhoria na nossa tarefa. URLs no HTML e em docs/PROTOCOLO_BPE.md.

A mesma CNN, outras unidades

Acrescentamos três treinos BPE e reutilizamos três checkpoints da CNN por palavras. Ambos usam os mesmos 6.144 exemplos de treino e 1.536 de validação, com os mesmos prefixos de 128 palavras. O BPE vê apenas o texto de treino. Os rótulos são usados depois, pela rede.

Controle	Valor nos dois modelos
Vocabulário e embedding	20.000 entradas, 128 dimensões
Convoluções e saída	3/4/5, 100 filtros por janela, dropout 0,5, saída 300 × 2
Otimização	Adam 0,001, batch 64, clipping 1, 12 épocas
Partidas pareadas	Sementes 17, 29, 43; matrizes iniciais e minibatches iguais
Seleção	Menor CE de validação por semente, épocas 1 a 12
Parâmetros treináveis	2.714.502 em cada modelo

A taxa veio da seleção anterior da CNN por palavras e não foi ajustada para o BPE. O limite é de 256 tokens em ambos. Matrizes iniciais iguais não tornam os embeddings semanticamente iguais: cada índice aponta para uma palavra ou uma subpalavra diferente. As janelas 3/4/5 agora medem unidades diferentes.

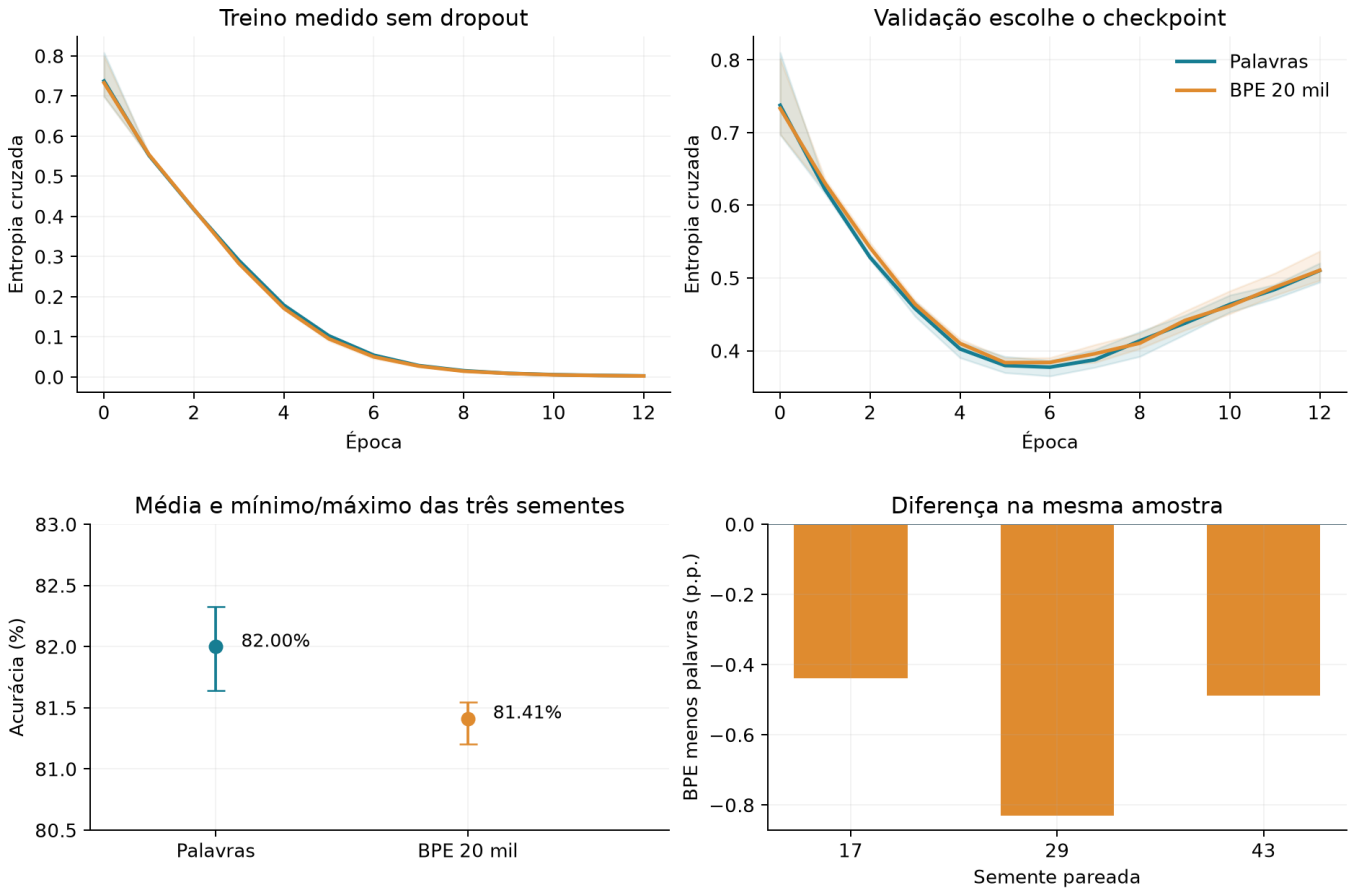


Na nova auditoria, palavras produzem **3,27%** de tokens UNK e BPE, **0,00%**. O comprimento médio passa de 121.3 para 129.1 tokens (+6.4%). Nenhuma resenha foi truncada nos três papéis. Essa cobertura é uma observação deste corpus, sem garantia para qualquer texto futuro.

Auditoria nova para os seis checkpoints

Reservamos 2.048 resenhas balanceadas do treino oficial limpo, excluindo todos os papéis dos estudos didáticos MLP e CNN/encoders. O arquivo de entrada ficou fora do treino e foi liberado só após congelar os seis checkpoints. O teste oficial não foi reaberto. Esta amostra é diferente daquela usada na tabela dos encoders; os números não devem ser misturados.

Cobertura e classificação



Tokenização	Acurácia média	CE média	F1 macro
Palavras	82,00%	0.396	0.820
BPE 20 mil	81,41%	0.405	0.814

Nesta receita, BPE fica 0.59 ponto percentual abaixo em média. As três diferenças pareadas são negativas. Retirar UNKs preserva mais detalhes lexicais, mas isso não basta para melhorar uma CNN com este conjunto de janelas, taxa e orçamento. Não concluímos que BPE seja pior de modo geral.

Faixas mostram mínimo/máximo das três sementes. Uma divisão e três partidas não quantificam toda a incerteza. A comparação não procura a melhor receita para cada tokenizer. Os seis checkpoints reproduziram exatamente seus logits em outro processo; 18 conjuntos de métricas foram reconstruídos. Tempos brutos contêm efeitos de aquecimento e não sustentam uma comparação de velocidade.