Arquitetura, treinamento e transferência

Nestor, Letícia e Gabriel
Introdução a Deep Learning - extensão do projeto IMDb.

Este estudo treina CNNs e ajusta BERT, DistilBERT e ModernBERT-base para relacionar resultados com convoluções, atenção, otimização e generalização. São 87 treinos reais com três sementes: 42 CNNs, 27 cabeças sobre encoders congelados e 18 ajustes completos. Um baseline TF-IDF completa a comparação.

Pergunta	Experimento	Material da disciplina
Como filtros locais classificam texto?	CNN 1D, janelas e largura	Prince 10; slides 10
Adam e SGD aprendem igual?	Taxa comum e três taxas por método	Prince 6; slides 06
Quando o ajuste se torna overfitting?	Dropout e curvas treino/validação	Prince 8-9; slides 08-09
O que muda com pré-treinamento?	Encoder congelado e ajuste integral	Prince 11-12; slides 11-12

Os papéis dos dados

Treino: **6.144** resenhas. Validação: **1.536**. Nova auditoria interna: **2.048**, excluindo todos os papéis da extensão MLP. As amostras vêm apenas do treino oficial limpo. O teste oficial de 25 mil exemplos não foi reaberto. Esta auditoria é interna, não um novo benchmark externo.

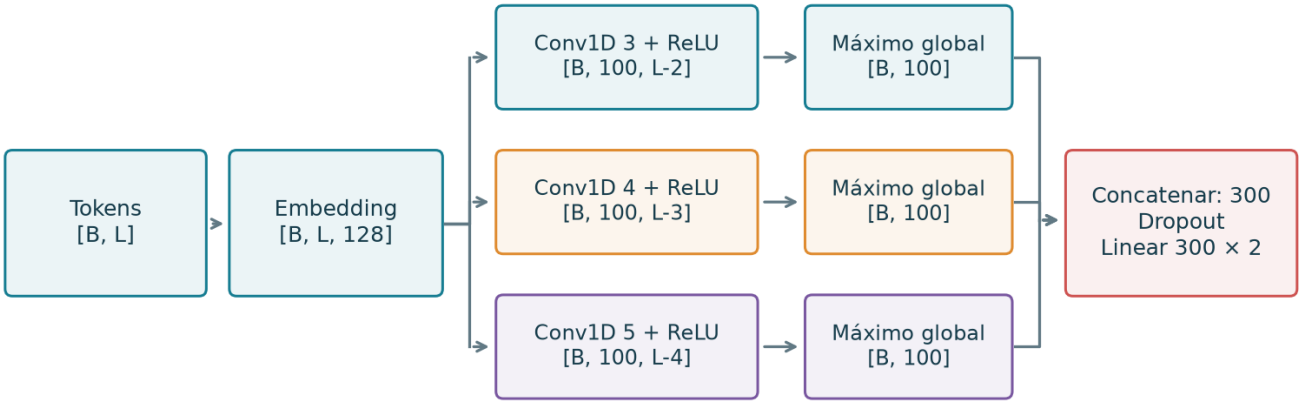
Todos os modelos recebem o mesmo prefixo de até 128 palavras separadas por espaço. A CNN e os encoders admitem no máximo 256 tokens; a truncagem adicional é medida. O TF-IDF usa o prefixo completo, sem esse limite adicional. O rótulo continua sendo o da resenha completa, mesmo quando o prefixo omite a avaliação final.

Seleção antes da auditoria

Cada treino escolhe a época com menor CE de validação. Para cada método, escolhemos a taxa que minimiza a média dessas perdas nas três sementes. Congelamos código, revisões, pesos, taxas e épocas antes de transferir a entrada da nova auditoria para a execução.

Os relatórios originais, o estudo MLP e o steering do Qwen permanecem separados. Não misturamos métricas de testes, prefixos ou divisões diferentes.

A CNN usada neste estudo



L ≤ 256 tokens. Filtros compartilham pesos entre posições. Janelas de padding não competem pelo máximo.

A entrada é uma sequência de índices. Um embedding treinável associa a cada índice 128 números. Cada filtro combina todos esses canais em uma janela local de 3, 4 ou 5 tokens. Os mesmos pesos deslizam pelas posições. A ReLU introduz não linearidade; o máximo global retém a maior resposta de cada filtro.

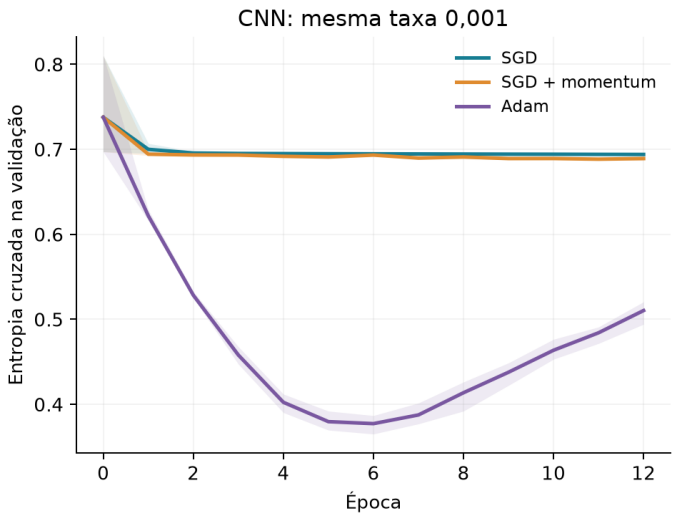
Cem filtros em cada uma das três janelas produzem 300 máximos. Concatenamos esses valores, aplicamos dropout e uma camada linear com duas saídas. O modelo principal tem **2.714.502** parâmetros treináveis, incluindo o embedding. Ele aprende do zero, sem vetores pré-treinados. A saída contém dois logits; usamos softmax para exibir probabilidades.

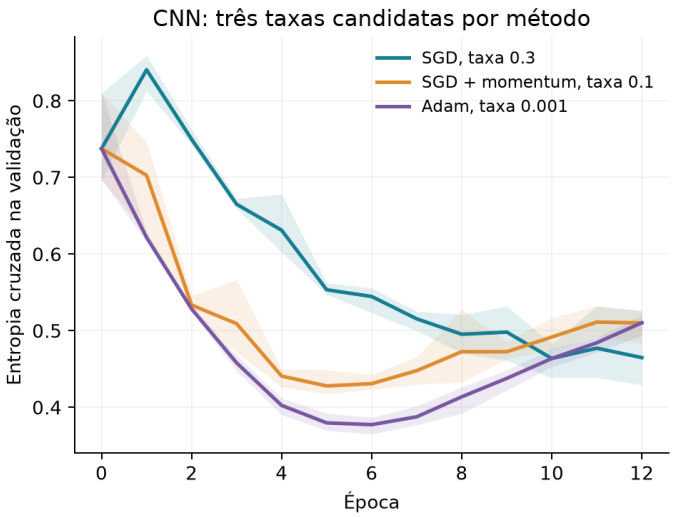
Operação	Formato por minibatch
Índices	B × L
Embedding	B × L × 128
Conv1D de janela k	B × 100 × (L-k+1)
Máximo de cada ramo	B × 100
Concatenação e saída	B × 300; depois B × 2

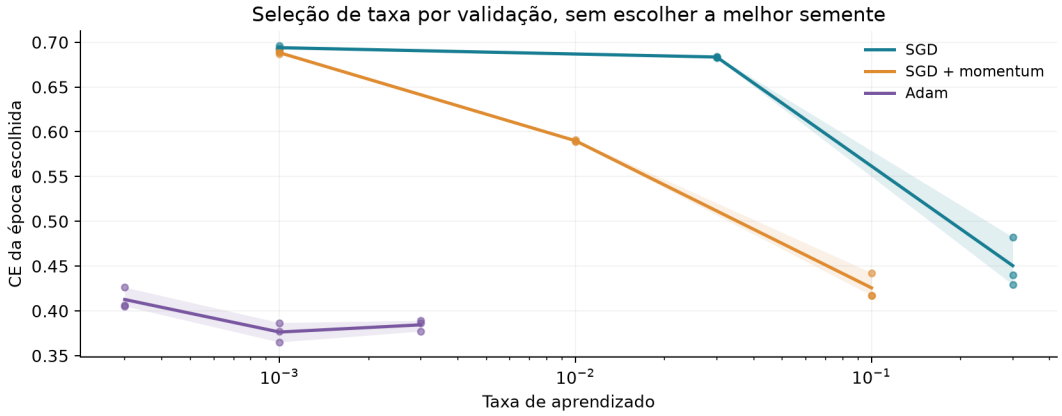
No padding, janelas inválidas não competem pelo máximo. Para entradas menores que uma janela, o código mantém uma janela mínima com zeros de padding. A convolução preserva ordem local; o máximo perde a localização exata do padrão vencedor. A rede rasa não modela todas as relações distantes do texto.

Fontes: Prince 10; Redes Convolucionais, páginas do arquivo 11-22 e 36; inspiração arquitetural em Kim (2014), sem reproduzir integralmente seu protocolo.

A taxa muda a comparação





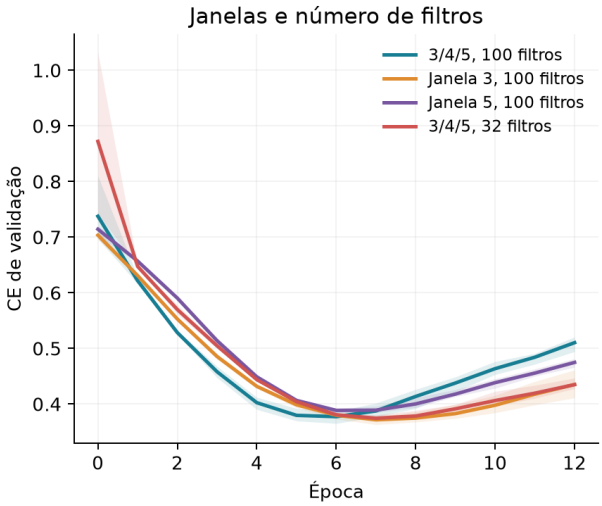


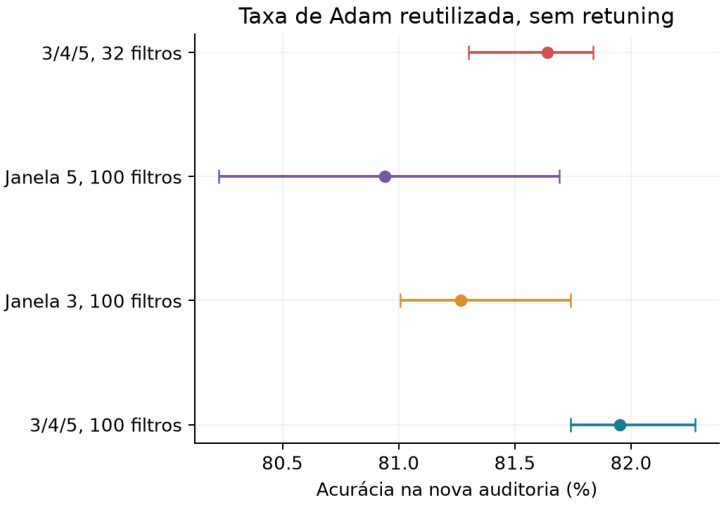
Método	Taxa escolhida	Acurácia interna	CE interna
SGD	0.3	76,53%	0.480
SGD + momentum	0.1	79,35%	0.470
Adam	0.001	81,95%	0.409

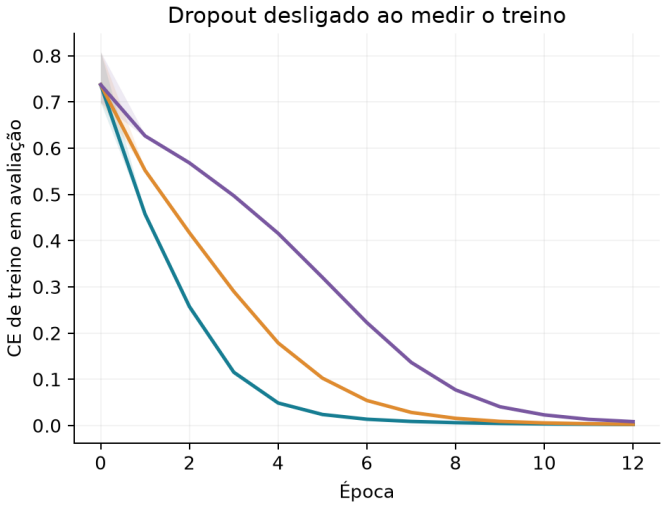
As três taxas de cada algoritmo estão fixadas no protocolo. Cada condição usa os mesmos pesos e minibatches por semente, doze épocas e clipping de norma 1. O painel com 0,001 responde o que ocorre mantendo a taxa. O outro inclui a escolha de validação, uma comparação diferente. Faixas mostram mínimo/máximo das três sementes.

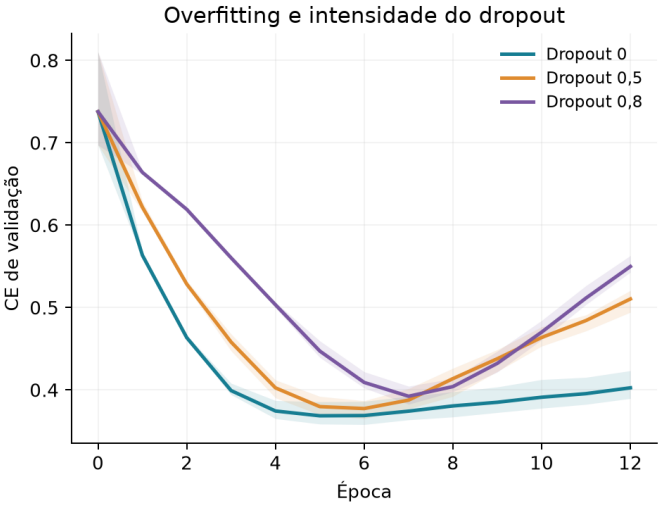
Os métodos usam escalas de atualização diferentes. Um método lento na taxa comum pode melhorar com outra taxa. Os dados descrevem este orçamento e grade; não estabelecem superioridade universal de um otimizador. Fonte: Prince 6.1-6.5 e slides Ajuste de Modelos.

Filtros e dropout na CNN









Variante de dropout	Épocas escolhidas	CE interna	Acurácia interna
Dropout 0,5	5, 6, 6	0.409	81,95%
Dropout 0	5, 6, 5	0.411	81,80%
Dropout 0,8	7, 7, 7	0.422	80,44%

A grade de arquitetura compara janelas 3, 5 ou 3/4/5 e 32 ou cem filtros por janela. Todas as variantes reutilizam a taxa de Adam escolhida para a CNN principal. O embedding ocupa grande parte dos parâmetros, por isso reduzir filtros não reduz a rede inteira na mesma proporção.

O treino continua por doze épocas para mostrar a trajetória. A avaliação usa o checkpoint escolhido pela CE de validação. Curvas de treino com dropout desligado permitem distinguir ajuste dos dados e o ruído da regularização. Fonte: Prince 8-10 e slides Regularização.

BERT, DistilBERT e ModernBERT

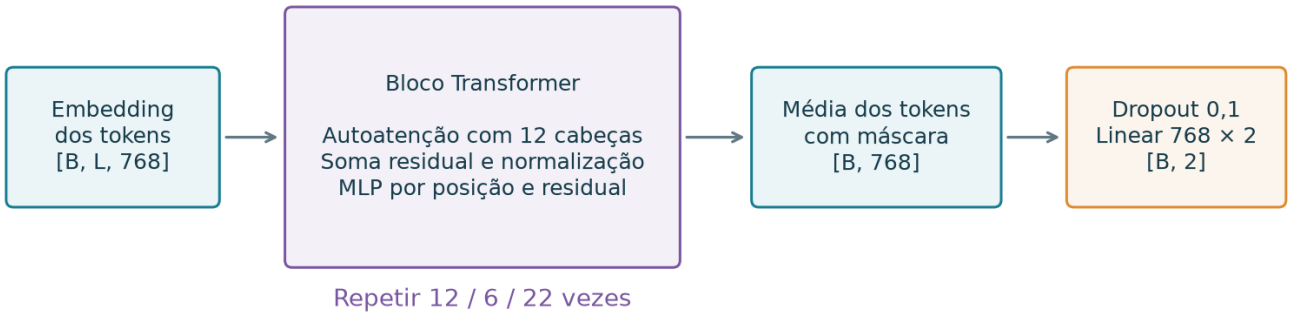


Diagrama funcional. Ordem de normalização e atenção variam. ModernBERT alterna atenção local e global e usa RoPE.

Um encoder Transformer transforma cada token usando o contexto. Na autoatenção, projeções aprendidas produzem queries, keys e values. A compatibilidade entre query e key determina os pesos da combinação dos values. Há múltiplas cabeças, transformações por posição, resíduos e normalização. A informação de posição permite distinguir ordens diferentes.

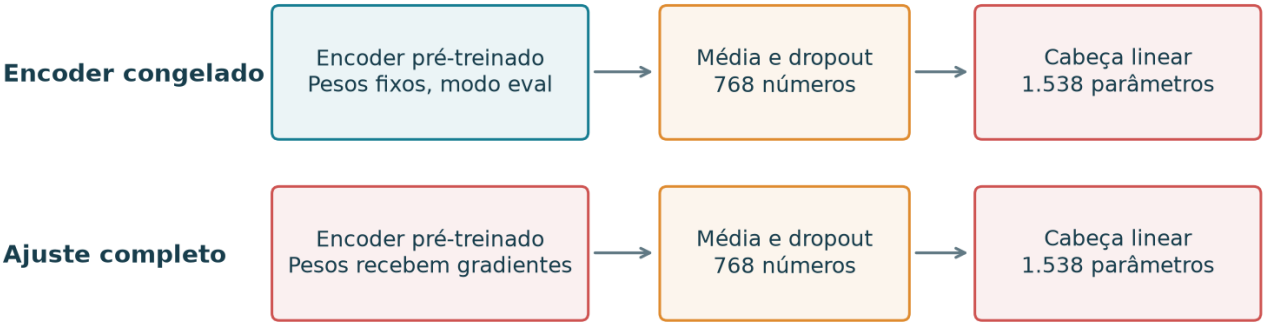
Encoder	Blocos	Dimensão / cabeças	Parâmetros do classificador completo
BERT-base	12	768 / 12	108.893.186
DistilBERT	6	768 / 12	66.364.418
ModernBERT-base	22	768 / 12	149.015.810

BERT-base usa atenção bidirecional global e posições aprendidas. DistilBERT reduz a pilha para seis blocos e incorpora destilação em seu pré-treinamento. ModernBERT-base combina 22 blocos, posições rotativas e atenção local intercalada com global. Não usamos sua capacidade máxima de contexto: todos recebem o mesmo prefixo curto neste ensaio.

A saída de cada token tem 768 dimensões. A média dos estados finais exclui padding e tokens especiais. Acrescentamos dropout 0,1 e Linear(768,2). O pooler original de BERT é removido; por isso a contagem difere de tabelas que incluem pooler ou cabeça de pré-treinamento.

O diagrama é funcional. A ordem de normalização e dos resíduos varia entre as famílias. Fontes: Prince 11-12; Transformers, páginas 7-18, 21-31 e 35-38; Devlin et al., Sanh et al. e Warner et al.

Congelar ou ajustar todos os pesos



Congelado: vetor pré-computado, treina a cabeça. Completo: backward atravessa também todos os blocos do encoder.

Regime	Pesos treináveis	Receita	Grade
Encoder congelado	Cabeça: 1.538	40 épocas, batch 128, Adam	0,001; 0,01; 0,1
Ajuste completo	Encoder e cabeça	3 épocas, batch 32, AdamW	0,00001; 0,00003

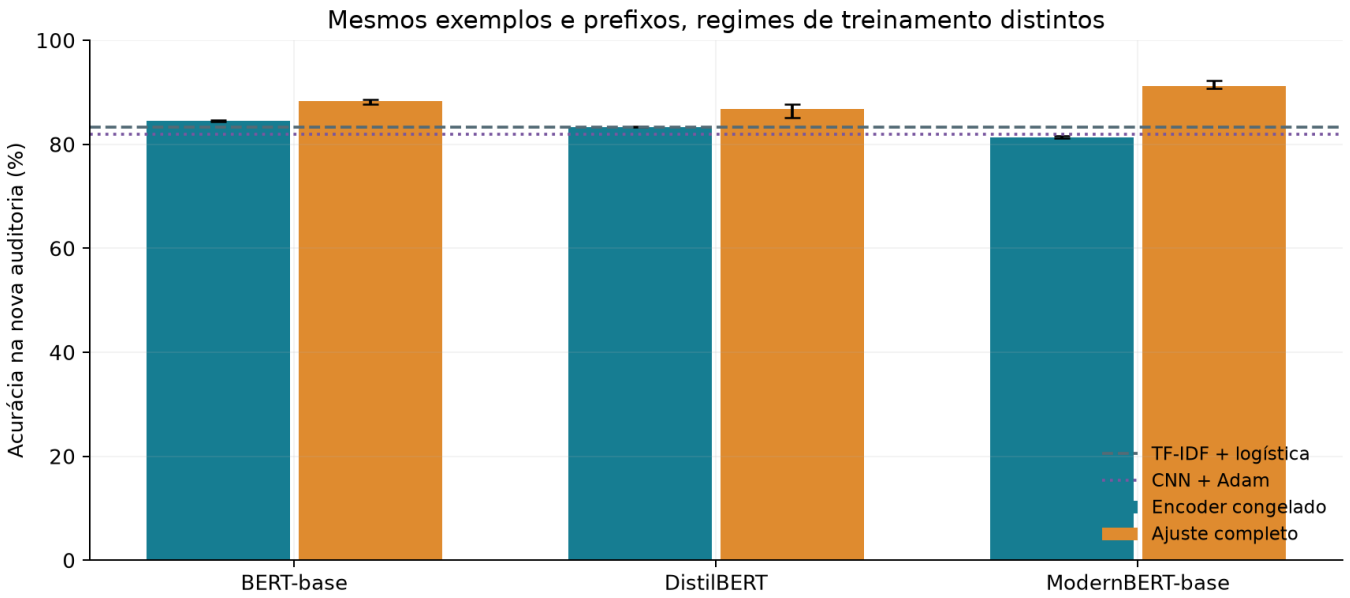
No modo congelado, o encoder fica em avaliação e gera vetores uma única vez. Nenhum gradiente atualiza seus pesos. A cabeça recebe gradientes e aprende a separar esses vetores. No ajuste completo, o backward atravessa também o encoder e adapta suas representações à tarefa.

As cabeças começam com os mesmos pesos na mesma semente. O ajuste completo usa warmup de 10%, redução linear da taxa, decaimento desacoplado de 0,01 nos pesos matriciais e clipping 1. Vieses e parâmetros de normalização ficam sem decaimento.

Esta comparação avalia duas receitas práticas. Orçamento, otimizador, dropout do encoder e atualização dos pesos mudam juntos. Portanto, não isolamos destravar o encoder como única causa de um ganho. A cabeça mantém dropout 0,1 nos dois regimes; no congelado, o encoder permanece determinístico em avaliação.

Os modelos partem de pré-treinamento público, sem checkpoints já ajustados no IMDb. Revisões e hashes estão fixados. Encoders usam BF16 com parâmetros e estado do otimizador FP32, atenção SDPA e TF32 desligado. A CNN usa FP32. Fonte: documentação oficial e protocolo executável.

Os resultados dos encoders

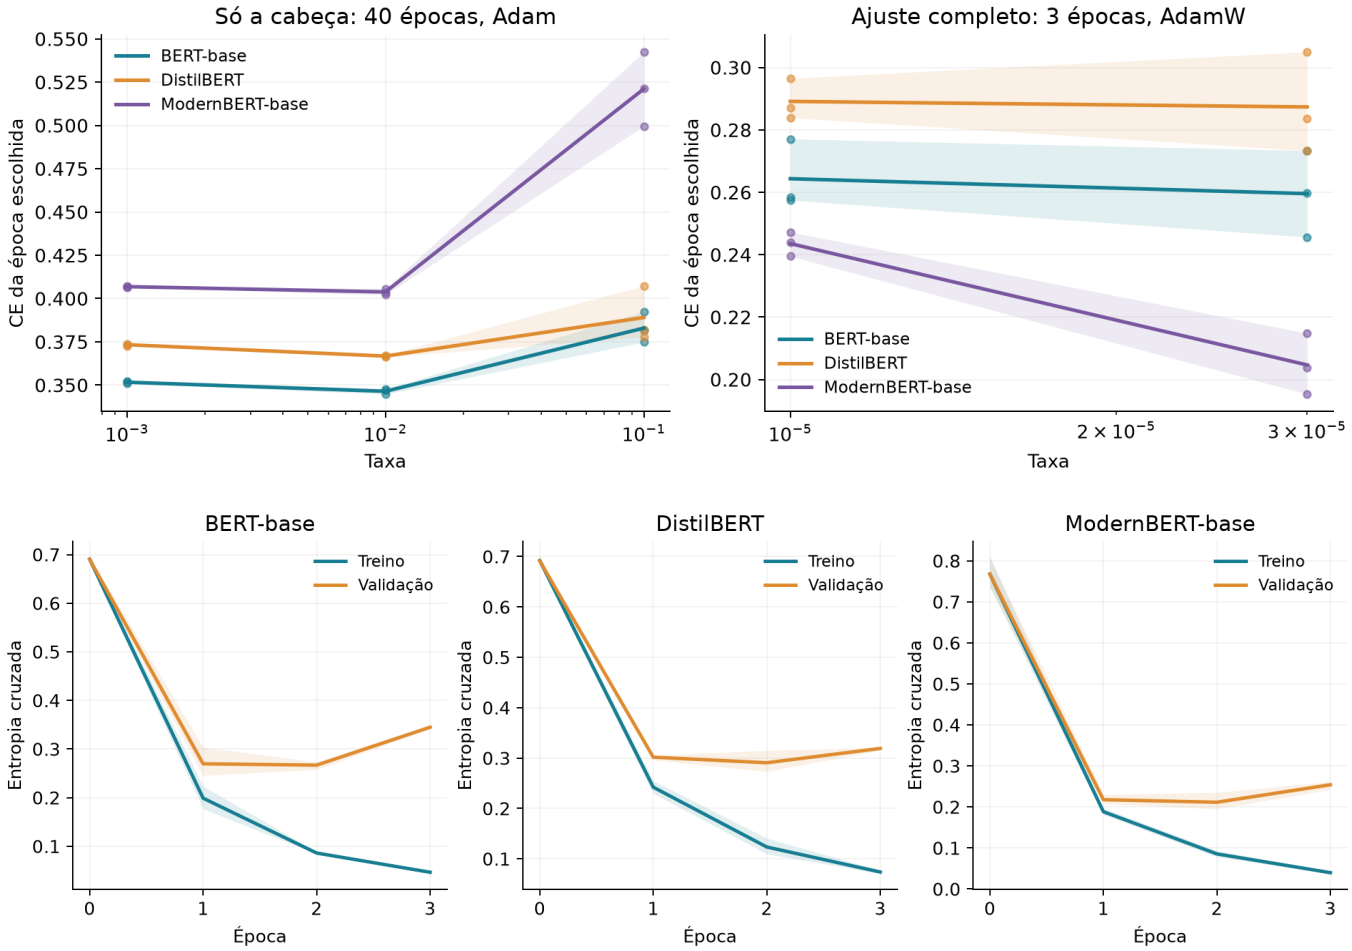


Modelo / regime	Taxa	Acurácia média	Mínimo - máximo	CE
BERT-base congelado	0.01	84,52%	84,42% - 84,62%	0.366
BERT-base completo	3e-05	88,31%	87,70% - 88,67%	0.303
DistilBERT congelado	0.01	83,35%	83,30% - 83,40%	0.384
DistilBERT completo	3e-05	86,80%	85,11% - 87,74%	0.338
ModernBERT-base congelado	0.01	81,30%	81,10% - 81,54%	0.410
ModernBERT-base completo	3e-05	91,24%	90,72% - 92,19%	0.246

No mesmo recorte, o baseline TF-IDF + logística tem acurácia 83,30% e CE 0.385. A CNN + Adam tem acurácia média 81,95%. São controles úteis para verificar se a complexidade adicional ajuda neste orçamento.

A amostra é a nova auditoria interna de 2.048 exemplos. A faixa entre três sementes não é intervalo de confiança sobre a população. A diferença entre famílias também inclui pré-treinamento, tokenização e escala. As probabilidades não foram calibradas e a CE pode divergir da acurácia.

Trajetórias e seleção na validação

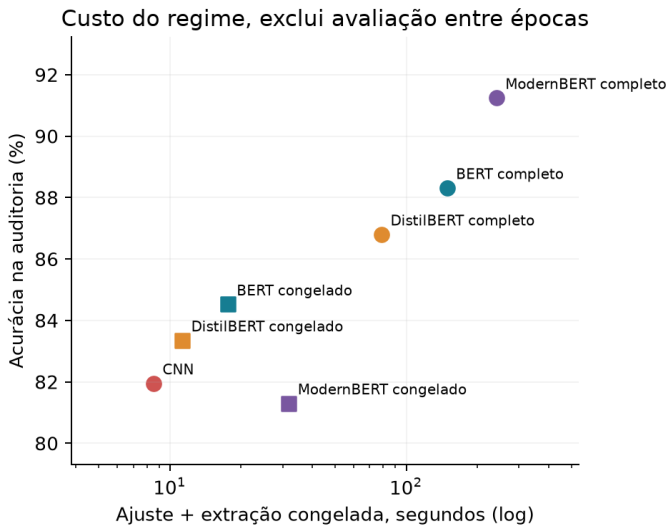


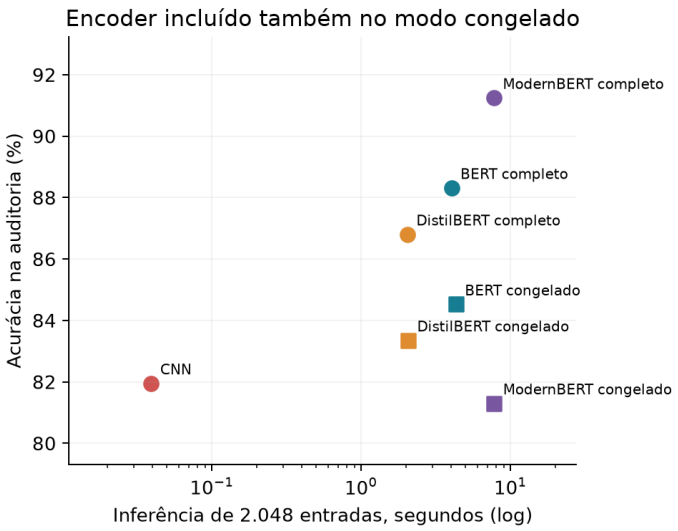
A grade congelada contém três taxas; a completa contém duas. Cada ponto usa três sementes. A escolha usa a média da CE de cada checkpoint selecionado, sem consultar a auditoria. As curvas inferiores mostram treino e validação com a taxa selecionada para o ajuste completo.

Três épocas são um orçamento, não uma prova de convergência. Um encoder pode precisar de outra taxa, regularização ou mais passos para alcançar seu melhor resultado. O objetivo é observar aprendizagem e custo com um protocolo explícito, mantendo todas as tentativas publicadas.

A curva da época zero mostra a cabeça aleatória e não participa da escolha de checkpoint. As condições congeladas não recalculam o encoder a cada época. O notebook permite consultar todas as trajetórias e taxas descartadas.

Qualidade e custo medidos juntos





Modelo / regime	Ajuste + vetores (s)	Inferência / 2.048 (s)
BERT-base congelado	17.57	4.30
BERT-base ajuste completo	148.93	4.02
DistilBERT congelado	11.28	2.06
DistilBERT ajuste completo	78.67	2.04
ModernBERT-base congelado	31.87	7.75
ModernBERT-base ajuste completo	240.99	7.72

No congelado, o ajuste inclui a extração dos vetores de treino e validação, mais a média do treino da cabeça. O ajuste completo e a CNN contam apenas os minibatches de treino. As avaliações entre épocas, o carregamento e o download ficam fora desse cronômetro. O tempo total por execução também está nos resultados.

Na inferência, somamos o encoder congelado ao custo da cabeça. Assim, não tratamos a cabeça isolada como se fosse o modelo completo. A medição usa batch 64, exclui tokenização e carregamento. Não há repetição sistemática de benchmark de latência.

A implementação usa atenção SDPA e não tenta extrair a máxima eficiência de cada arquitetura. BF16, formato de entrada e kernels afetam tempo. Valores medidos no NVIDIA GB10 não devem ser generalizados para outro hardware.

O mesmo texto em modelos diferentes

Positivo: exemplo próprio

I expected to hate this film. I was wrong. The strange opening leads to a clever story, the cast is excellent, and the ending is surprisingly warm. What looked like a disaster turned out to be a wonderful evening.

Modelo	P(positivo), sem calibração
CNN	0.838
BERT-base	0.975
DistilBERT	0.980
ModernBERT-base	0.987

Negativo: exemplo próprio

Beautiful images, a talented cast, and a memorable score are all here. Unfortunately the story is a mess. The impressive first ten minutes give way to repetitive scenes, empty speeches, and an ending that feels completely unearned. I cannot recommend it.

Modelo	P(positivo), sem calibração
CNN	0.105
BERT-base	0.002
DistilBERT	0.067
ModernBERT-base	0.039

Definimos estes textos antes de observar suas predições e os avaliamos após o congelamento, usando a semente 17 em todos os casos. Ilustram negação, reversão de expectativa e avaliação mista. A intenção do autor é uma referência didática, sem substituir um conjunto de avaliação anotado.

O notebook e o HTML mostram os quatro exemplos nos oito classificadores, além das janelas que contribuem à margem linear da CNN. Essa decomposição é exata na última camada, mas não estabelece causalidade das palavras sobre a decisão.

Ligação com a disciplina

Tema visto no curso	O que os experimentos mostram
Convolução e viés indutivo	Pesos compartilhados, janelas locais, pooling e filtros treináveis.
Gradientes e otimizadores	Taxa comum e taxa selecionada respondem perguntas diferentes.
Generalização e regularização	Curvas de validação escolhem checkpoints; dropout pode mudar o compromisso entre ajuste e generalização.
Resíduos e Transformers	Atenção e MLPs por posição usam caminhos residuais, com variantes entre famílias.
Espaço de representações	Congelar o encoder treina uma fronteira sobre vetores existentes. Ajuste integral modifica também os vetores.
Double descent e steering	Permanecem estudos separados: regressão sintética e intervenção nas ativações do Qwen, respectivamente.

Roteiro sugerido

Para uma fala curta, selecione o diagrama CNN, a comparação de otimizadores, as curvas de dropout, a distinção congelado/completo e a comparação dos encoders. Use double descent ou steering como uma demonstração adicional, conforme o tempo disponível. Os slides incluem notas e material de apoio para não transformar a fala numa lista de métricas.

Verificação e limites

O verificador reconstrói 217 métricas de treino/validação e auditoria, confirma as escolhas de taxa, as épocas e as partidas pareadas. Uma nova avaliação na GPU reconstrói os 43 checkpoints. O protocolo usa uma única divisão, três sementes e grades pequenas. Não mede superioridade universal nem isola o efeito da arquitetura do pré-treinamento. Não auditamos a presença de resenhas nos corpora de pré-treinamento.

Referências

Prince, Understanding Deep Learning, capítulos 6-12. Slides MAE5920: Redes Convolucionais, páginas do arquivo 11-22, 36 e 51-52; Transformers, páginas 7-18, 21-31 e 35-38. Os hashes do acervo ficam no catálogo de referências.

Kim (2014), ACL D14-1181. Devlin et al. (2019), ACL N19-1423. Sanh et al. (2019), arXiv:1910.01108. Warner et al. (2024), arXiv:2412.13663. Model card e implementação oficial de ModernBERT no Hugging Face. URLs no HTML e no catálogo docs/REFERENCIAS_SEQUENCIAS.json.