Do modelo aos mecanismos

Nestor, Letícia e Gabriel
Introdução a Deep Learning - extensão do projeto IMDb e Qwen3-8B.

Além de treinar classificadores, podemos perguntar por que uma configuração aprende, como uma alteração muda a trajetória e quando ajustar melhor o treino prejudica a generalização. Este suplemento transforma essas perguntas em experimentos ligados ao livro e aos slides disponíveis no acervo do grupo.

Pergunta para a apresentação	Experimento	Referência Prince
Adam é sempre melhor que SGD?	Mesma taxa e taxas escolhidas em validação	6.1-6.5
O que acontece com mais camadas?	Profundidade, atalho e escala residual	7.5; 11.1-11.3
Quando o treino começa a atrapalhar?	Dropout, L2 e parada por validação	9.1; 9.3
Mais capacidade pode voltar a ajudar?	Double descent em regressão sintética	8.4-8.5

O desenho

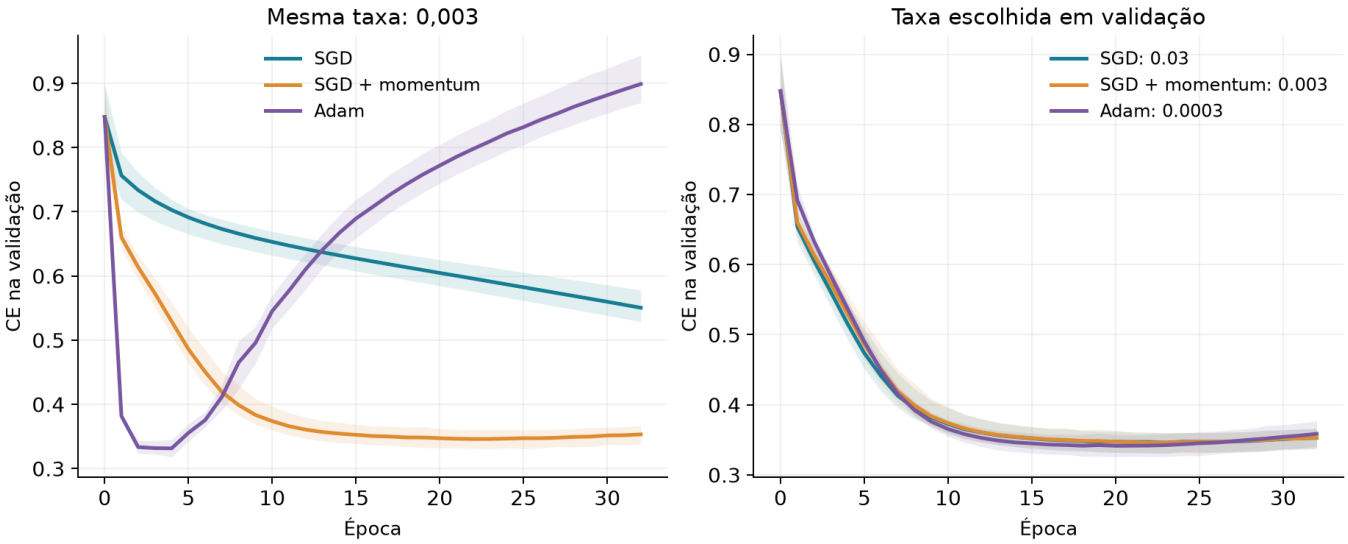
IMDb: 6.144 exemplos para ajuste, 1.536 para validação e 2.048 para auditoria interna, todos extraídos do antigo treino limpo. Vocabulário TF-IDF, IDF, SVD de 128 componentes e padronização são ajustados somente nos 6.144 exemplos. As novas redes densas compartilham essas entradas. O teste oficial do projeto não foi consultado novamente.

51 treinos e três sementes: 27 trajetórias para otimizadores, 15 para arquiteturas e nove para regularização. As escolhas e os checkpoints são congelados antes da auditoria. O exemplo sintético usa outras vinte sementes e 880 condições. Não há promessa de que o mesmo fenômeno apareça na CNN ou no Qwen.

As faixas dos gráficos IMDb são mínimo e máximo das três sementes; no exemplo sintético, mediana e intervalo interquartil. Essas faixas não são intervalos de confiança populacionais.

O algoritmo e a taxa interagem

Uma MLP de duas camadas ocultas de 64 unidades recebe os mesmos dados, pesos iniciais e minibatches por semente. O orçamento é de 32 épocas. Primeiro fixamos a taxa em 0,003 para todos; depois permitimos três candidatas por método e selecionamos pela CE final média na validação.



Método	Taxa escolhida	Acurácia na auditoria
SGD	0.03	84,11%
SGD + momentum	0.003	84,13%
Adam	0.0003	84,15%

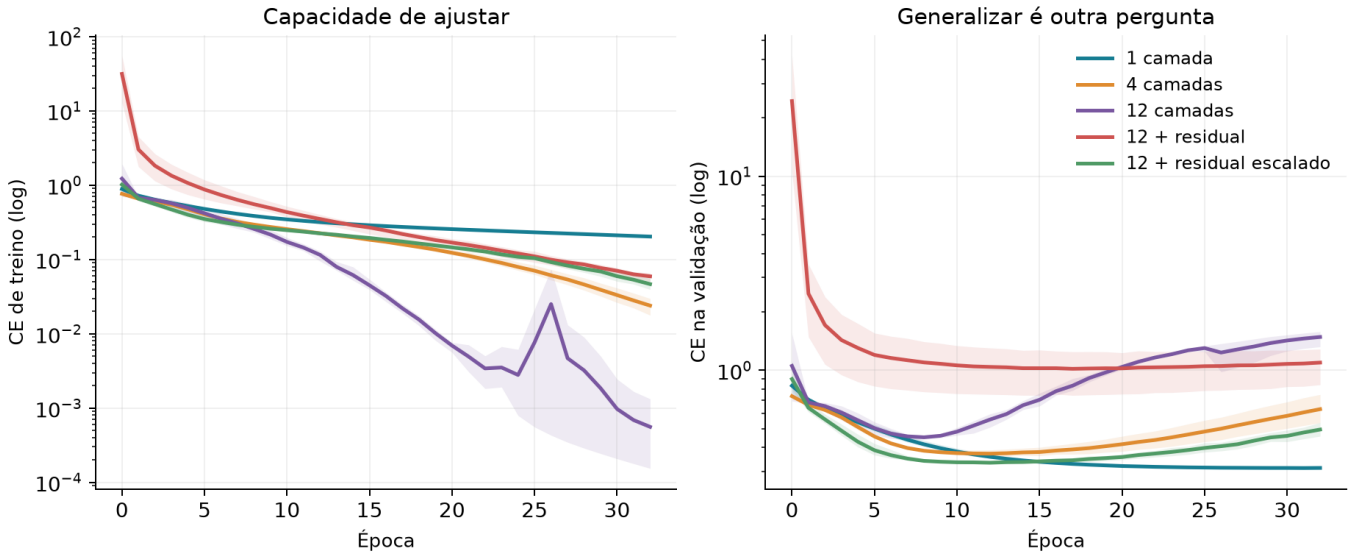
As três escolhas ficam próximas em acurácia. O resultado depende da taxa, do orçamento e do critério: uma taxa que reduz muito a perda de treino pode elevar a CE de validação por excesso de confiança. O ensaio não estabelece superioridade universal de um otimizador.

Momentum: a implementação PyTorch usa v = 0,9v + g e passo proporcional a v. A convenção de média móvel normalizada usada em algumas derivações difere por um fator constante na taxa.

O notebook também mostra a perda quadrática com autovalores 0,5 e 20. Nela, GD é estável somente com taxa entre 0 e 0,1; a trajetória acima desse limite é preservada. É um exemplo determinístico de geometria, separado do SGD em minibatches.

Fontes: Prince 6.1-6.5; slides Ajuste de Modelos, páginas do arquivo 26-39; Kingma e Ba (Adam).

Profundidade, identidade e escala



Arquitetura	Parâmetros	Acurácia interna
1 camada	8.386	85,77%
4 camadas	20.866	82,42%
12 camadas	54.146	78,11%
12 + residual	54.146	65,64%
12 + residual escalado	54.146	83,15%

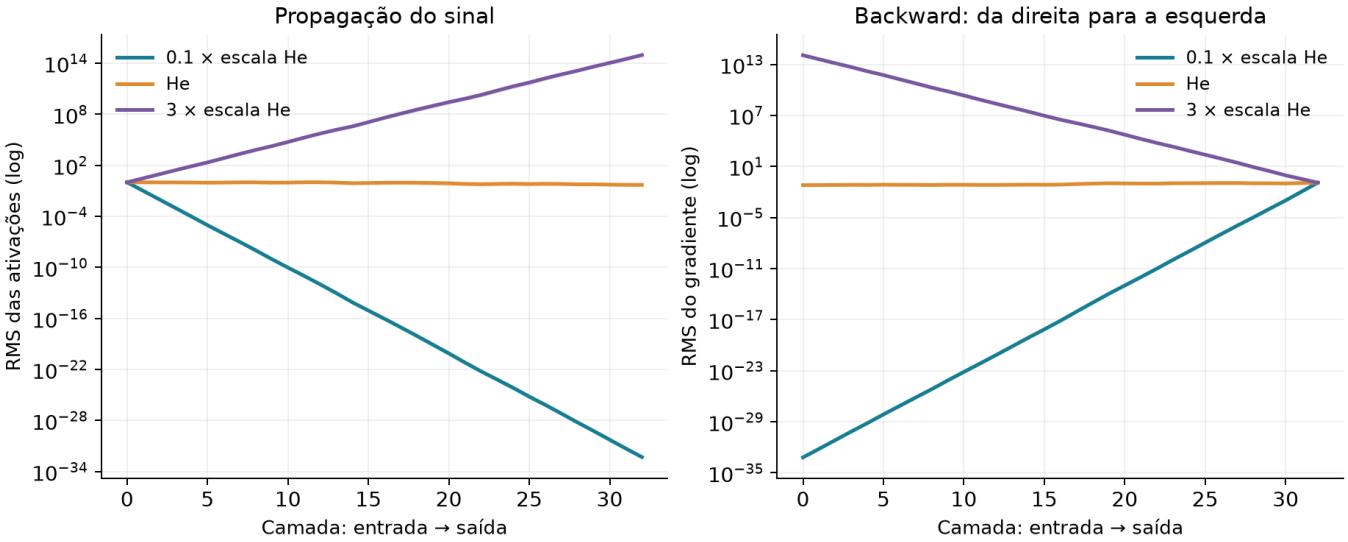
As três redes com 12 camadas possuem 54.146 parâmetros, os mesmos pesos iniciais e os mesmos minibatches. O atalho altera h = f(ReLU(h)) para h = h + s f(ReLU(h)). Com s=1, isolamos a soma identidade; com s=1/raiz(11), estudamos também o controle da escala residual. Não acrescentamos normalização.

A maior profundidade ajustou mais o treino, mas também elevou a CE de validação. Portanto, o efeito dominante observado aqui inclui overfitting; não podemos chamar esse resultado simplesmente de falha em otimizar. A variante residual escalada melhora em relação ao residual sem escala, mas não supera automaticamente a rede rasa.

A taxa Adam é a já escolhida no experimento anterior, sem retuning por arquitetura. Trata-se de uma ablação sob orçamento fixo, não do melhor desempenho possível de cada arquitetura.

Fontes: Prince 11.1-11.3; slides Redes Residuais, páginas do arquivo 5-18.

O sinal precisa sobreviver à profundidade



Este é um diagnóstico sintético sem treinamento: 32 camadas ReLU de largura 64, entradas gaussianas e uma sonda linear fixa na saída. Para cada semente, os três ganhos reutilizam as mesmas matrizes gaussianas de base. A variância dos pesos é g^2 vezes 2/64; g=1 corresponde à escala He.

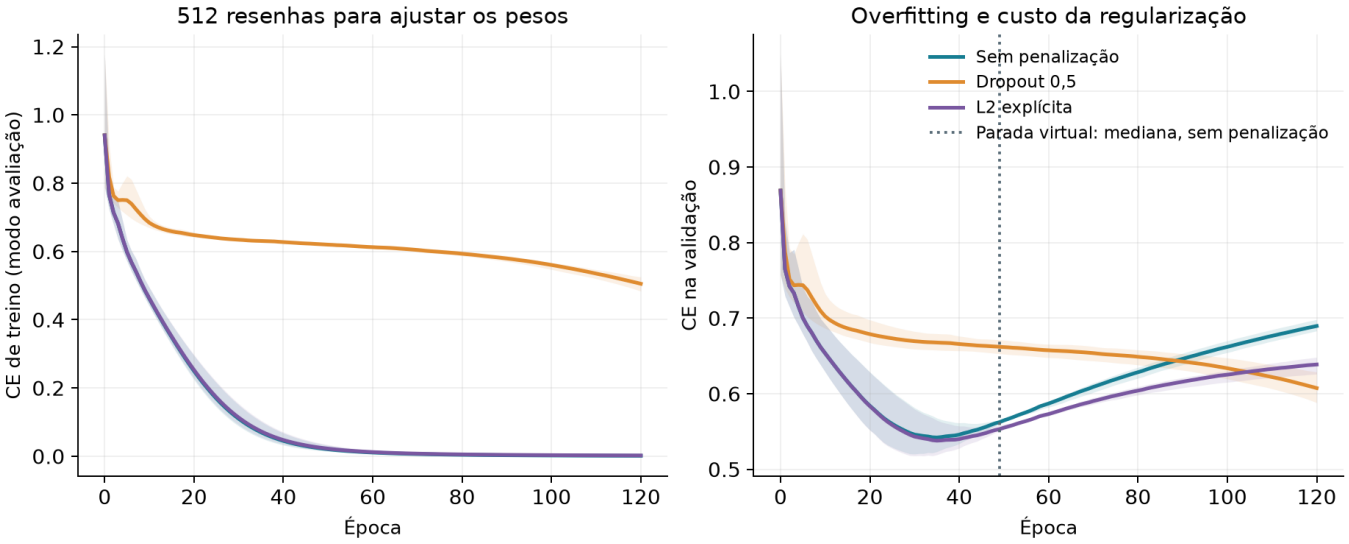
Com ganho menor, as ativações se atenuam ao atravessar as camadas; com ganho maior, amplificam-se. No backward, a leitura segue da direita para a esquerda. Os eixos logarítmicos tornam visíveis as diferenças de muitas ordens de magnitude.

O verificador confere a homogeneidade positiva da ReLU neste caso sem vieses: na camada k, o sinal escala como g elevado a k e o gradiente como g elevado a (32-k). Essa identidade é específica do diagnóstico construído; não descreve toda a dinâmica de uma rede treinada.

He busca preservar a escala sob hipóteses de independência e simetria. Numa realização finita, a variância pode oscilar; a linha central não precisa ser perfeitamente horizontal. Conexões residuais também exigem atenção à escala da soma.

Fontes: Prince 7.5; slides Gradientes e Inicialização, páginas do arquivo 31-42; conexão com Prince 11.3.

Treinar mais pode piorar a confiança



Reduzimos a supervisão para 512 exemplos e usamos uma MLP de três camadas de 128 unidades por 120 épocas. A representação continua sendo aquela aprendida, sem rótulos, nos 6.144 exemplos comuns. Comparamos ausência de penalização, dropout 0,5 e L2 explícita. As curvas medem CE em modo avaliação, com dropout desligado, e excluem a penalização.

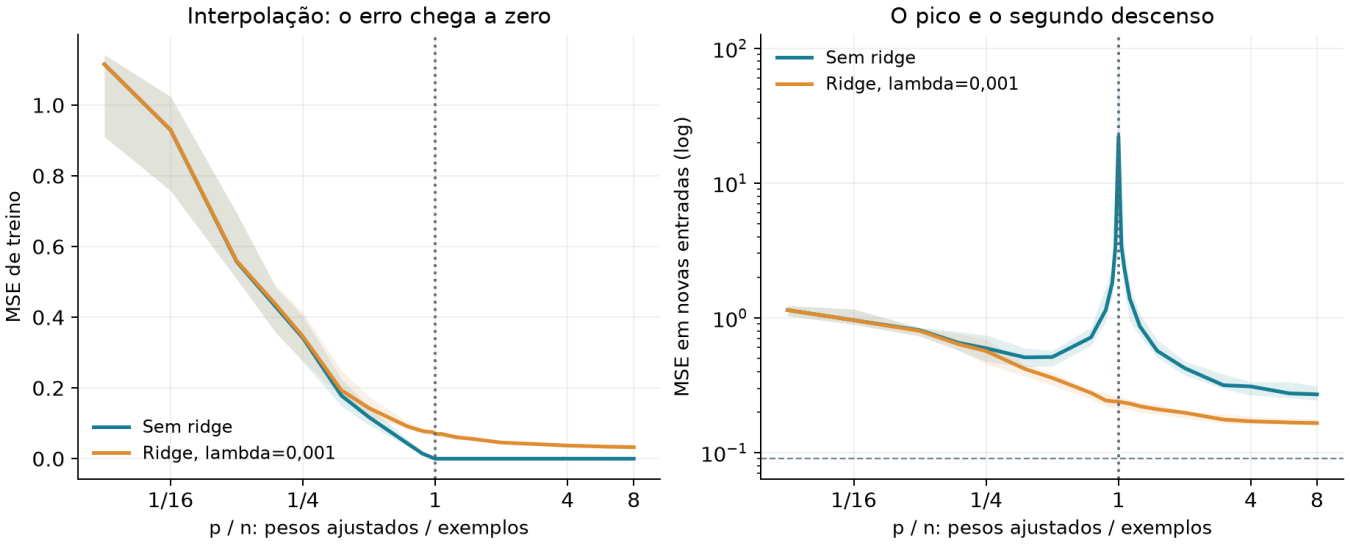
Variante	CE: parada	CE: final	Acurácia: parada / final
Sem penalização	0.565	0.755	72,22% / 75,46%
Dropout 0,5	0.611	0.611	71,84% / 71,84%
L2 explícita	0.561	0.699	72,46% / 76,14%

A parada virtual usa paciência 15 e melhora mínima de 0,0001 na CE de validação. O checkpoint é retido quando essa regra para de observar melhora; o treino continua apenas para revelar a trajetória contrafactual. Não medimos economia real de tempo.

Parar pela CE reduz a CE interna, mas pode reduzir a acurácia: perda probabilística e acerto no limiar respondem a objetivos diferentes. Dropout subajusta neste orçamento e L2 não garante melhoria em toda métrica. A penalização é explícita, lambda/2 vezes a soma dos pesos ao quadrado, excluindo vieses; Adam usa weight_decay=0.

Fontes: Prince 9.1 e 9.3; slides Regularização, páginas do arquivo 7-17 e 29-36.

Double descent em um caso controlado



Mudamos explicitamente para regressão sintética: n=64 exemplos de treino, 2.048 novas entradas e ruído gaussiano de desvio 0,3. Uma camada ReLU aleatória fica congelada. Ajustamos somente p coeficientes de saída por mínimos quadrados de norma mínima ou ridge. O eixo p/n conta esses coeficientes ajustados, não os pesos congelados.

p	MSE de treino: mediana	MSE de teste: mediana
24	0.178	0.508
64	9.96e-29	22.091
512	1.1e-29	0.270

Na interpolação, a mediana do MSE de teste sem ridge é 22.09; com lambda=0,001, 0.238. Ao aumentar a largura para 512, a curva sem ridge desce novamente. O notebook liga o pico ao aumento da norma dos coeficientes e mostra os graus de liberdade efetivos.

Todas as vinte sementes e as 880 condições são preservadas. Mediana e intervalo interquartil são usados porque os erros perto da interpolação têm caudas fortes. O experimento é uma demonstração com características aleatórias congeladas; não estabelece double descent na CNN do IMDb e não reproduz integralmente a rede treinada do livro.

Fontes: Prince 8.4-8.5; slides Desempenho e Generalização, páginas do arquivo 30-37; Belkin et al. (2019).

Quatro perguntas para uma fala de 8-10 minutos

Tempo sugerido	Gráfico e pergunta	Conclusão que os dados permitem
2 minutos	Otimização: e se mantivermos a mesma taxa?	A taxa integra a comparação; taxas escolhidas tornam os métodos próximos neste ensaio.
2 minutos	Arquitetura e inicialização: mais camadas ajudam?	Capacidade, overfitting e escala têm papéis distintos; o atalho não garante o melhor resultado.
2 minutos	Regularização: quando parar?	CE e acurácia podem discordar; regularização também pode subajustar.
2 minutos	Double descent: mais parâmetros voltam a ajudar?	O fenômeno aparece no exemplo controlado; o mecanismo e seus limites ficam explícitos.

Ponte com o restante do projeto

O relatório principal continua mostrando TF-IDF, CNN e BERT. O suplemento usa redes densas com uma representação comum para isolar alterações menores. O Qwen3-8B e o steering continuam no relatório próprio: eles ilustram uma intervenção nas ativações de um modelo congelado, distinta de trocar o otimizador ou a arquitetura no treinamento.

O que pode ser compartilhado

Este PDF, o notebook conexoes_disciplina.ipynb e os gráficos PNG/SVG em results/didactic/figures. O HTML correspondente é autocontido. Código, dados vetoriais selecionados, trajetórias, pesos pequenos e verificadores permitem conferir os resultados sem carregar o Qwen.

Evite transformar a fala numa competição de métricas. A contribuição didática é formular uma hipótese, controlar o que muda e observar onde a explicação encontra limites. As referências localizam cada tema no material disponível ao grupo.

Evidência, limites e referências

Verificação

Os testes cobrem partições disjuntas, ablações com parâmetros iguais, L2 sem vieses, regra causal de parada, minibatches pareados e solução ridge/norma mínima. O verificador científico reconstrói probabilidades dos 42 checkpoints, confere as 51 trajetórias e repete os 880 cálculos sintéticos.

Uma verificação independente detectou inicialmente uma diferença entre a precisão do treino e a da avaliação na GPU. A política foi uniformizada com TF32 desligado; a execução foi repetida com as mesmas configurações e sementes. A correção e a comparação dos parâmetros repetidos estão documentadas em numerical_audit_correction.json. Não houve retuning por causa da auditoria.

Limites

As redes IMDb usam TF-IDF/SVD, não embeddings de um LLM, e compartilham uma única divisão interna. Três sementes de inicialização não abrangem toda a incerteza amostral. As taxas de arquitetura e regularização não foram ajustadas separadamente. O diagnóstico de inicialização e o double descent são sintéticos. A disponibilidade dos slides não comprova que cada página foi ministrada.

Referências

Prince, Simon J. D. Understanding Deep Learning. Versão local com 541 páginas: seções 6.1-6.5, 7.5, 8.4-8.5, 9.1, 9.3 e 11.1-11.3. Site: udlbook.github.io/udlbook/.

Slides MAE5920 do acervo fornecido: Ajuste de Modelos (pp. 26-39); Gradientes e Inicialização (pp. 31-42); Desempenho e Generalização (pp. 30-37); Regularização (pp. 7-17 e 29-36); Redes Residuais (pp. 5-18). Localizadores são páginas do arquivo PDF.

Kingma, D. P.; Ba, J. Adam: A Method for Stochastic Optimization. arXiv:1412.6980. Belkin, M. et al. Reconciling modern machine learning practice and the bias-variance trade-off. PNAS, 2019; arXiv:1812.11118.

Os hashes das fontes estão em source_references.json. Todas as figuras deste suplemento foram produzidas pelos experimentos; páginas e figuras dos PDFs de referência não são redistribuídas. Para conferir: **python verify_didactic.py**.