MAE5920 · INTRODUÇÃO A DEEP LEARNING

O que a CNN lê em uma resenha?

Classificação de sentimento e tokenização no IMDb

Nestor, Letícia e Gabriel

Resumo

Classificamos resenhas do IMDb em positivas e negativas com regressão logística sobre TF-IDF, uma CNN com embeddings aprendidos e encoders pré-treinados. O experimento original avalia os modelos no teste oficial. Ensaios internos com três sementes separam escolhas de otimizador, arquitetura e tokenização. Na comparação pareada, BPE reduziu tokens desconhecidos de 3,27% para zero e a acurácia média passou de 82,00% para 81,41%. Em um par sintético com as mesmas palavras, as duas CNNs mudaram de classe quando trocamos a ordem dos adjetivos. Os seis checkpoints inverteram a interpretação prevista para as duas frases. Um controle com as mesmas janelas convolucionais produziu logits idênticos em cada checkpoint. Esses exemplos ajudam a localizar o que a arquitetura consegue distinguir, mesmo quando o desempenho agregado parece semelhante.

1 Ordem e sentimento

Considere duas resenhas que só trocam os lugares de *terrible* e *wonderful*. A oração após *but* expressa a avaliação final.

A *I thought this movie was terrible, but it was wonderful.*

B *I thought this movie was wonderful, but it was terrible.*

As duas sequências têm a mesma contagem de cada palavra. Um modelo que recebe apenas unigramas vê o mesmo vetor para A e B. Os bigramas mudam, portanto o TF-IDF de referência deste trabalho, que inclui bigramas, pode separá-las. A CNN também pode responder de modo diferente, pois aplica filtros a janelas ordenadas de embeddings. A questão empírica é se ela atribui o sentimento à oração que encerra o contraste.

Investigamos essa questão em três escalas. Primeiro, medimos desempenho em resenhas reservadas. Depois, alteramos componentes da CNN sob controles de treino e avaliamos palavras contra subpalavras. Por fim, consultamos pesos congelados com pares sintéticos para verificar sensibilidade à ordem e construir um limite exato da arquitetura.

Código, notebook executado e resultados por execução. Repositório do projeto.

2 Dados e protocolo de avaliação

O Large Movie Review Dataset contém 25.000 avaliações rotuladas no treino oficial e 25.000 no teste [1]. A tarefa usa o texto em inglês e dois rótulos, $y = 0$ para negativo e $y = 1$ para positivo. Decodificamos entidades HTML, removemos tags e normalizamos espaços. A identificação de duplicatas usa o hash do texto limpo com *casefold*.

Papéis das amostras

Papel	Original	Ensaios internos	Uso
Treino	19.823	6.144	Ajustar representação, vocabulário e pesos.
Validação	2.478	1.536	Escolher hiperparâmetros e época.
Calibração	2.478	–	Ajustar temperatura após a seleção original.
Teste/auditoria	25.000	2.048	Avaliar a configuração já escolhida.

Tabela 1. O número 2.048 se refere à auditoria de cada extensão. CNN/encoders, palavras/BPE e MLP usam amostras internas distintas.

No preparo original, removemos do treino textos com hash presente no teste, duplicatas internas e conflitos de rótulo. A comparação de hashes usa os textos do teste para excluir duplicatas, com rótulos reservados à avaliação. Os registros distinguem 123 linhas do treino que coincidiam com o teste e 98 duplicatas internas do treino. O teste oficial conserva 201 ocorrências duplicadas. A auditoria detecta igualdade normalizada, de modo que paráfrases e possíveis exposições no pré-treinamento continuam como fontes de incerteza.

As extensões partem do treino limpo. CNN/encoders e palavras/BPE compartilham treino e validação e recebem prefixos de até 128 palavras. Cada rede pode usar até 256 tokens. A auditoria BPE exclui também os papéis da extensão sequencial. A entrada de cada auditoria ficou reservada até o congelamento dos pesos e das escolhas. Os resultados de teste oficial vêm da execução original. Manifesto original. Protocolo sequencial. Protocolo BPE.

Dicionário resumido

Campo	Significado
`id`	Identificador derivado da divisão oficial e da posição na fonte.
`label`	Classe binária usada na função de perda e na avaliação.
`clean_text`	Texto após decodificação de HTML e normalização de espaços.
`word_count`	Número de segmentos separados por espaço no texto limpo.
`text_sha256`	Impressão do texto normalizado usada para verificar duplicações.

Tabela 2. O texto é a entrada do classificador. ID, rótulo e hash têm papéis de preparação ou avaliação. Dicionário completo.

Métricas

Acurácia conta a proporção de classificações corretas. F1 macro calcula o F1 de cada classe e faz a média com pesos iguais. A entropia cruzada binária, $\mathrm{CE} = -n^{-1} \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$, avalia o escore p_i atribuído ao sentimento positivo. Ela aumenta quando a classe observada recebe probabilidade baixa. Na execução original, o cálculo salvo limita as probabilidades a $[10^{-7}, 1 - 10^{-7}]$. Os ensaios internos calculam CE diretamente dos logits.

3 Tokenização e arquitetura

Duas unidades de entrada

Palavras. Convertemos o prefixo limpo para minúsculas. A expressão `[a-z]+(?:'[a-z]+)?|\d+` preserva palavras, contrações e números. O vocabulário contém os 19.998 itens mais frequentes no treino, além de `<pad>` (ID 0) e `<unk>` (ID 1). A frequência determina a ordem, com desempate lexical. A posição de cada ID é preservada na sequência. Palavras de negação como *not* seguem para o modelo.

BPE. Mantemos a normalização lexical e separamos palavras com `WhitespaceSplit`. O BPE de caracteres aprende uniões de pares frequentes com os 6.144 textos de treino, frequência mínima 2 e vocabulário de 20.000 itens. O marcador `</w>` identifica o fim de palavra. O tokenizer é congelado antes do treino supervisionado da CNN. O procedimento adapta BPE para unidades de texto [3].

Entrada	*The pallbearer scene was unexpectedly moving.*
Palavras	`the <unk> scene was unexpectedly moving`
BPE	`the</w> p all bearer</w> scene</w> was</w> unexpectedly</w> moving</w>`

Tabela 3. Saída dos tokenizadores congelados. `pallbearer` tem um ID desconhecido com palavras e três peças com BPE.

Convolução sobre embeddings

Cada ID acessa um vetor de 128 dimensões aprendido com a tarefa. O filtro de largura k lê k tokens vizinhos e usa os mesmos pesos em todas as posições. Aplicamos três grupos paralelos de convoluções de larguras 3, 4 e 5, com cem filtros por largura. A ReLU deixa respostas positivas passarem. O máximo global seleciona a maior ativação por filtro. A topologia segue a família de CNNs para classificação de sentenças [2, 4].

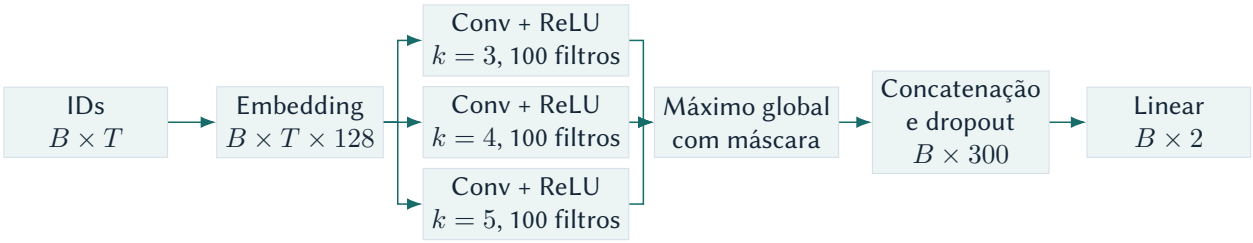


Figura 1. TextCNN do projeto. B é o tamanho do minibatch e T é o comprimento após padding. A camada linear produz logits negativo e positivo.

Se e_t é o embedding na posição t, o filtro f resume a entrada por

$$m_f = \max_{t \in \mathcal{V}_k} \mathrm{ReLU}(\langle W_f, [e_t, \ldots, e_{t+k-1}] \rangle + b_f) \,.$$

$\mathcal{V}_k$ exclui as janelas que avançam sobre padding em entradas com pelo menos k tokens. Para sequências mais curtas, a implementação mantém a primeira janela com padding. A concatenação dos 300 máximos passa por dropout de 0,5 no treino e uma camada $\mathrm{Linear}(300, 2)$.

Na CNN principal, $20.000 \times 128 = 2.560.000$ parâmetros pertencem aos embeddings. As convoluções somam $100 \sum_{k \in \{3,4,5\}} (128k + 1) = 153.900$. A saída soma $2(300 + 1) = 602$, totalizando **2.714.502 parâmetros**. A mesma largura em tokens pode abranger menos palavras quando BPE fragmenta uma palavra. Implementação.

4 Treinamento e escolha dos hiperparâmetros

O forward produz dois logits. A entropia cruzada compara esses logits com o rótulo, e o *backward* calcula gradientes para embeddings, filtros e saída. Limitamos a norma global a 1 antes do passo do otimizador. Os embeddings começam com distribuição normal de desvio 0,1 e linha de padding zero. Os filtros usam inicialização de He, e a saída usa Xavier. A escolha de inicialização, taxa e regularização liga o experimento aos capítulos de otimização e generalização de Prince [4].

Grade da CNN sequencial

Otimizador	Taxas testadas	Taxa escolhida
SGD	0,001 0,03 0,3	0,3
SGD com momentum 0,9	0,001 0,01 0,1	0,1
Adam	0,0003 0,001 0,003	0,001

Tabela 4. Três sementes por célula. CNN base com janelas 3/4/5 e cem filtros por largura, dropout 0,5, batch 64 e orçamento de 12 épocas.

Dentro de cada semente, comparamos os otimizadores com as mesmas matrizes iniciais e a mesma ordem de minibatches. Escolhemos a época de menor CE de validação em cada execução. Em seguida, escolhemos a taxa com menor média dessas perdas nas sementes 17, 29 e 43. A época zero mostra a inicialização e fica fora da seleção.

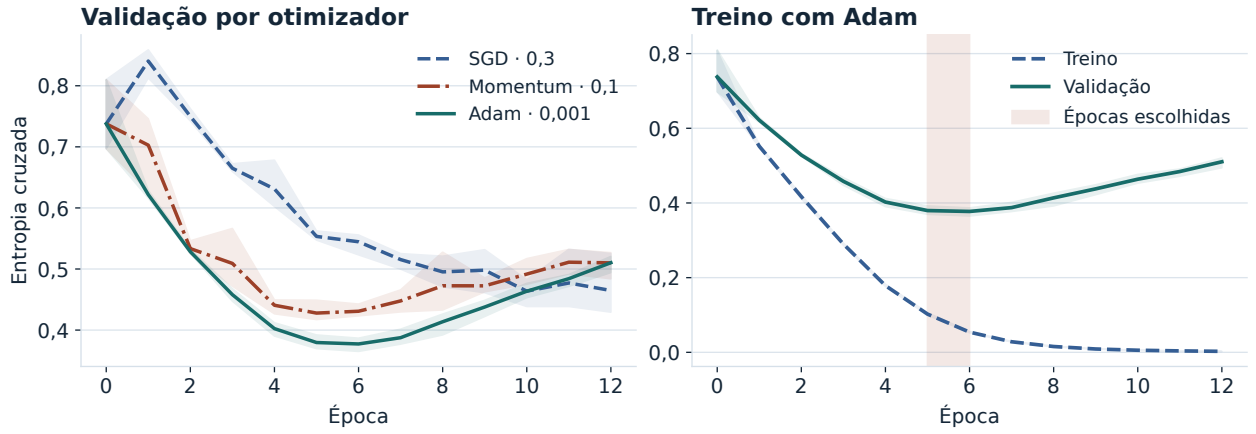


Figura 2. Médias de três sementes. As áreas mostram mínimo e máximo. À esquerda, cada otimizador usa sua taxa selecionada. À direita, as épocas 5 e 6 contêm os checkpoints escolhidos para Adam.

Capacidade e regularização

Além dos 27 ajustes de otimizador e taxa, fizemos nove treinos para janelas 3 e 5 isoladas e janelas 3/4/5 com 32 filtros por largura. Seis treinos adicionais variaram dropout entre 0 e 0,8. As variantes reutilizam a taxa de Adam da CNN base. São **42 treinos de CNN** no estudo sequencial. Na auditoria desse estudo, a CNN base obteve 81,95%, a variante de 32 filtros 81,64% e dropout 0,8 obteve 80,44%. Os números descrevem cada variante sob a receita fixada.

Na curva de Adam, o erro de treino segue caindo depois das épocas escolhidas enquanto a CE de validação aumenta. O checkpoint selecionado corresponde ao critério de generalização estabelecido antes da auditoria. Grades e controles. Históricos de treino.

5 Resultados de classificação

Treino, validação e teste oficial

O baseline ajusta TF-IDF de unigramas e bigramas no treino e seleciona a regularização da regressão logística na validação. Ele recebe o texto completo. A CNN original usa até 400 tokens. O BERT recebe até 192 WordPieces e passa por ajuste dos pesos [5]. Esses comprimentos e o pré-treinamento fazem parte de cada receita.

Divisão	Modelo	Acurácia	F1 macro	CE bruta
Treino	TF-IDF + logística	99,72%	0,9972	0,0973
Treino	CNN	94,95%	0,9494	0,1567
Treino	BERT	96,32%	0,9632	0,1138
Validação	TF-IDF + logística	91,53%	0,9152	0,2255
Validação	CNN	87,97%	0,8796	0,2877
Validação	BERT	91,28%	0,9128	0,2404
Teste	TF-IDF + logística	90,14%	0,9014	0,2531
Teste	CNN	86,78%	0,8678	0,3040
Teste	BERT	90,94%	0,9094	0,2433

Tabela 5. Probabilidades antes da calibração. Treino com 19.823 resenhas, validação com 2.478 e teste oficial com 25.000. A Tabela 1 descreve a divisão de calibração. CSV das divisões.

No teste oficial, o baseline tem 90,14% de acurácia, a CNN 86,78% e BERT 90,94%. Na CNN, a diferença entre acurácia de treino e teste acompanha a mudança de CE. A análise por comprimento e a calibração na Seção 7 ajudam a interpretar o erro além da acurácia.

Auditoria interna do estudo sequencial

Comparamos CNN e encoders nos mesmos prefixos de até 128 palavras, em 2.048 resenhas reservadas. Os encoders produzem estados contextuais. Usamos a média dos estados finais com máscara de padding e tokens especiais, seguida de uma cabeça linear de dois logits. Em um regime, apenas a cabeça é ajustada. No outro, os pesos do encoder também são atualizados.

Modelo	Acurácia	F1 macro	CE
TF-IDF + logística	83,30%	0,8330	0,3849
CNN + Adam	81,95%	0,8194	0,4094
BERT-base ajuste completo	88,31%	0,8831	0,3027
DistilBERT ajuste completo	86,80%	0,8678	0,3382
ModernBERT-base ajuste completo	91,24%	0,9124	0,2458

Tabela 6. Baseline determinístico e médias das três sementes nas redes. Encoders na tabela com ajuste completo. Os escores dessa auditoria usam o softmax sem calibração de temperatura.

Nos encoders congelados, as acurácias de BERT, DistilBERT e ModernBERT foram 84,52%, 83,35% e 81,30%. Cada receita tem seu orçamento e sua taxa selecionada. Os 27 treinos da cabeça congelada e os 18 ajustes completos, somados às 42 CNNs e às três CNNs BPE, perfazem 90 ajustes neurais. A mesma amostra permite comparar receitas, com efeitos de tokenização, pré-treinamento, capacidade e ajuste combinados. Métricas, sementes e configurações.

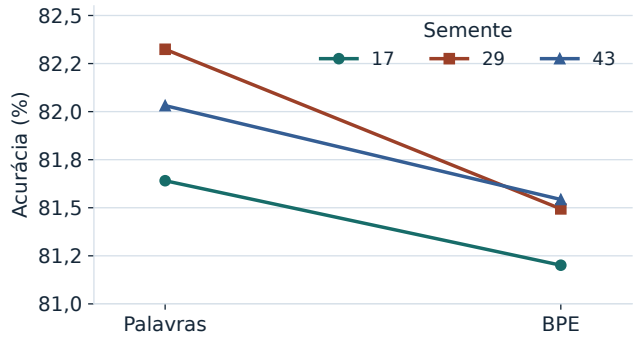
6 Palavras, subpalavras e ordem

Comparação pareada de tokenizadores

Mantivemos arquitetura, dimensões, dropout, inicialização numérica, minibatches e orçamento. Treinamos três CNNs com BPE e reutilizamos três checkpoints por palavras. Ambas as receitas usam Adam a 0,001, escolhido antes no estudo por palavras. Cada execução seleciona a época na validação. O pareamento controla os pesos iniciais como matrizes numéricas. As linhas de embedding correspondem a unidades distintas em cada vocabulário.

Tokenizer	Acurácia	F1 macro	CE	UNK	Tokens médios
Palavras	82,00%	0,8200	0,3964	3,27%	121,3
BPE 20 mil	81,41%	0,8140	0,4052	0,00%	129,1

Tabela 7. Nova auditoria interna, com 2.048 resenhas. Métricas médias de três sementes. UNK conta a proporção de tokens desconhecidos.



A diferença média é de $-0,59$ ponto percentual para BPE. A cobertura melhorou e a sequência ficou mais longa. Um filtro de cinco tokens pode cobrir menos palavras, o que muda o contexto que ele observa. Esta comparação estima o desempenho sob a taxa herdada e as larguras fixas.

Figura 3. Cada linha une a mesma semente sob as duas tokenizações. Eixo vertical ampliado. Métricas por execução.

Pares sintéticos com a mesma contagem de palavras

Escrevemos quatro pares antes da inferência e congelamos a lista em `seminario/casos.json`. Verificamos a igualdade dos unigramas e calculamos janelas de IDs de larguras 3, 4 e 5 com cada tokenizer. Os seis checkpoints escolhidos no protocolo BPE foram executados em CPU. Os números abaixo são médias de escores positivos antes de calibração.

	Palavras		BPE		
Par	A	B	A	B	Trocas P/B
Contraste depois de but	1,0%	89,9%	1,2%	83,7%	3/3 e 3/3
Escopo de not	48,4%	10,3%	53,1%	15,5%	2/3 e 1/3
Sentimento por aspecto	29,9%	0,3%	20,0%	0,4%	0/3 e 0/3
Troca de blocos com as mesmas janelas	88,4%	88,4%	73,6%	73,6%	0/3 e 0/3

Tabela 8. Trocas de classe entre A e B em três sementes para palavras e BPE. Aspectos e troca de blocos têm leitura mista. Os escores por semente, IDs, janelas e hashes estão em `dados/pares_resultados.json`.

Em *The movie is good, not bad*, a troca de *good* e *bad* reduz o escore positivo médio nos dois tokenizadores. Na semente 17, a própria frase A recebe 53,7% com palavras e 47,5% com BPE. O limiar 0,5 dá classes diferentes para o mesmo texto nas duas receitas treinadas. No par da Seção 1, a troca muda a classe em todas as sementes e inverte a leitura esperada. A Seção 8 explica como o controle com janelas iguais separa a reação local de um limite estrutural.

7 Calibração, comprimento e custo

Confiança no teste oficial

Se z é a margem entre os logits positivo e negativo, ajustamos uma temperatura $T > 0$ por CE na amostra de calibração. A probabilidade passa de $\sigma(z)$ a $\sigma(z/T)$. Como a temperatura preserva o sinal da margem, o limiar 0,5 preserva acurácia e F1 macro.

Modelo	Acurácia	F1 macro	CE calibrada
TF-IDF + logística	90,14%	0,9014	0,2396
CNN	86,78%	0,8678	0,3037
BERT	90,94%	0,9094	0,2278

Tabela 9. Teste oficial, $n = 25.000$, com temperatura escolhida em 2.478 resenhas reservadas. Compare a CE bruta com a Tabela 5.

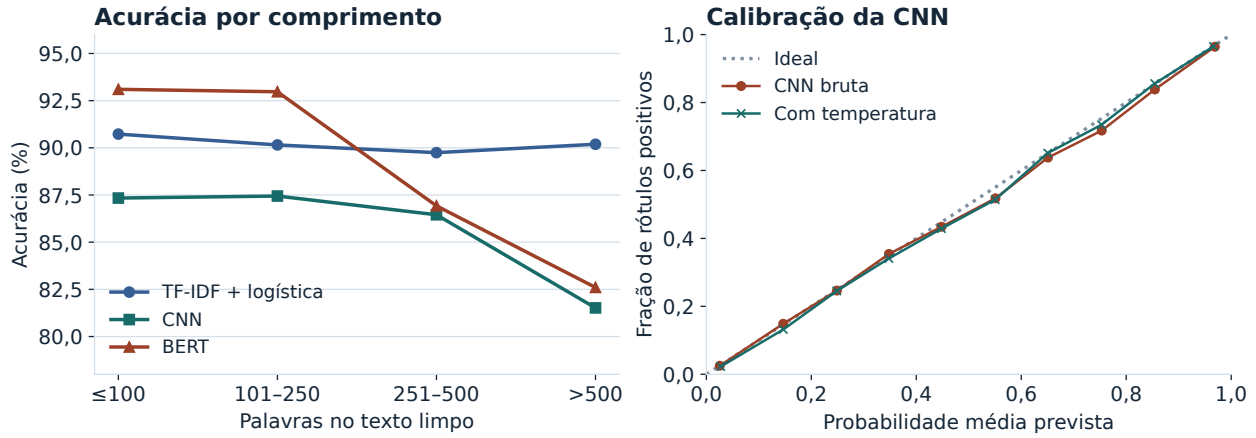


Figura 4. À esquerda, as quatro faixas de comprimento contêm 3.246, 14.624, 5.285 e 1.845 resenhas, respectivamente. À direita, médias de probabilidade e frequência positiva em dez faixas.

A temperatura teve efeito pequeno na CNN, com CE de 0,3040 para 0,3037. No comprimento, sua acurácia foi de 87,34% até cem palavras e 81,52% acima de 500. O BERT também cai na faixa longa, enquanto o TF-IDF com texto completo varia menos. Comprimento, conteúdo e recorte mudam juntos nessa análise descritiva. Métricas por comprimento.

Custo computacional da execução original

Modelo	Dispositivo	Ajuste (s)	Inferência (s)
TF-IDF + logística	CPU do Apple M1	13,1	0,15
CNN	Apple M1 (MPS)	139,6	20,72
BERT	NVIDIA GB10 (CUDA)	446,4	149,91

Tabela 10. Tempos registrados para as receitas originais. A inferência soma as quatro divisões. O ajuste do baseline inclui TF-IDF e a seleção de regularização. As medições usam dispositivos e orçamentos diferentes.

Ensaios complementares

O suplemento de MLPs reúne 51 treinos, com otimização, profundidade, atalhos residuais e regularização. Double descent aparece no ensaio sintético de regressão com 880 condições. O Qwen3-8B congelado foi avaliado separadamente na classificação e em intervenções nas ativações. O guia de mecanismos e o protocolo Qwen reúnem esses resultados.

8 Quando o modelo de aprendizagem profunda falha?

O contraste troca a decisão, mas a leitura fica invertida

Na frase A, a opinião final é *wonderful*. Na B, é *terrible*. As médias de escore positivo da CNN por palavras foram 1,0% e 89,9%, respectivamente. Com BPE, foram 1,2% e 83,7%. Todos os checkpoints classificaram A como negativa e B como positiva. O par isola a ordem das palavras na entrada e revela uma falha de interpretação da concessão. O escore de um caso mede a resposta do checkpoint àquela frase. As métricas reservadas medem desempenho agregado.

O máximo global apaga a posição entre janelas

Para o controle, intercalamos as frases *I loved the acting* e *I hated the ending* com a mesma sequência de palavras. Repetimos o separador no início, no meio e no fim. Ele é longo o suficiente para que cada janela de até cinco tokens veja no máximo um dos dois trechos. Trocar os trechos preserva as janelas internas e as que cruzam suas fronteiras.

Verificamos igualdade dos multiconjuntos de janelas de IDs para $k = 3, 4, 5$ nas duas tokenizações. A convolução com pesos compartilhados atribui a mesma ativação a janelas iguais. Ao aplicar o máximo global, cada filtro retorna o mesmo valor nos dois textos. O vetor concatenado e a saída linear coincidem. A diferença máxima observada de logit foi **zero** nos seis checkpoints. A construção mostra por que o modelo perde a ordem relativa de padrões quando as suas janelas locais permanecem iguais.

Cobertura, escopo e evidência fora do prefixo

BPE separa palavras raras em unidades conhecidas. A cobertura mede a proporção de tokens presentes no vocabulário. No ensaio pareado, mais cobertura veio acompanhada de sequências maiores e acurácia ligeiramente menor. No teste original, os textos longos também trazem a possibilidade de que a avaliação decisiva esteja além do prefixo. Os erros individuais e as análises por negação e contraste estão registrados com as previsões. Exemplos de erro.

Um teste de seguimento pode variar a distância entre avaliação inicial e final, preservar as palavras e usar rótulos definidos antes da inferência. Uma segunda comparação pode alterar o pooling e manter os embeddings e as janelas. Isso separaria a capacidade de detectar um padrão da capacidade de situá-lo no texto.

Referências

[1] Maas, A. L. et al. *Learning Word Vectors for Sentiment Analysis.* ACL, 2011. ACL Anthology.
[2] Kim, Y. *Convolutional Neural Networks for Sentence Classification.* EMNLP, 2014. ACL Anthology.
[3] Sennrich, R., Haddow, B. e Birch, A. *Neural Machine Translation of Rare Words with Subword Units.* ACL, 2016. ACL Anthology.
[4] Prince, S. J. D. *Understanding Deep Learning.* MIT Press, 2023. Caps. 6, 8, 9 e 10. Livro e materiais.
[5] Devlin, J. et al. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.* NAACL, 2019. ACL Anthology.