MAE5920 · INTRODUÇÃO A DEEP LEARNING

O que a CNN lê em uma resenha?

Classificação de sentimento e tokenização no IMDb

Nestor, Letícia e Gabriel

1 Duas frases, dois finais

Leia as frases como duas micro-resenhas. Em qual delas você recomendaria o filme? As palavras são as mesmas. A troca coloca um elogio ou uma crítica depois de *but*, onde lemos o veredito.

A / leitura positiva

*I thought this movie was terrible, but it was **wonderful**.*

Termina com elogio.

B / leitura negativa

*I thought this movie was wonderful, but it was **terrible**.*

Termina com crítica.

Cada palavra aparece o mesmo número de vezes. Um modelo que só conta palavras isoladas recebe a mesma entrada. O TF-IDF do estudo inclui bigramas, que podem mudar com a troca. A CNN também recebe informação de ordem dentro de cada janela. A Seção 7 mostra o que cada treino fez com os dois finais.

Resumo

No teste oficial do IMDb, com 25.000 resenhas, TF-IDF com regressão logística, TextCNN e BERT ajustado atingiram 90,14%, 86,78% e 90,94% de acurácia. Em uma auditoria pareada separada, BPE reduziu a taxa de tokens desconhecidos de 3,27% para zero, com acurácia média de 81,41% ante 82,00% com palavras. No par acima, os três treinos de cada tokenização atribuíram classe negativa a A e positiva a B. Um segundo par preservou as janelas e produziu logits iguais para as duas frases em cada checkpoint. Guardar dois picos por filtro em ordem de posição separou esse segundo par sem melhorar o acerto nos pares editados por pessoas.

Percurso de leitura

Da preparação das resenhas à decisão do modelo, nas Seções 2–3. Dos resultados médios à troca de duas palavras e ao ensaio de posição, nas Seções 5–7.

Código, notebook executado e métricas por execução. Repositório do projeto.

2 Dados e protocolo de avaliação

O Large Movie Review Dataset contém 25.000 avaliações rotuladas no treino oficial e 25.000 no teste [1]. Reservar um papel para cada grupo permite escolher o modelo, ajustar os escores e medir o resultado em amostras distintas. A tarefa usa o texto em inglês e dois rótulos, $y = 0$ para negativo e $y = 1$ para positivo. Decodificamos entidades HTML, removemos tags e normalizamos espaços. A identificação de duplicatas usa o hash do texto limpo com *casefold*.

Papéis das amostras

Papel	Original	Ensaios internos	Uso
Treino	19.823	6.144	Ajustar representação, vocabulário e pesos.
Validação	2.478	1.536	Escolher hiperparâmetros e época.
Calibração	2.478	–	Ajustar temperatura após a seleção original.
Teste/auditoria	25.000	2.048	Avaliar a configuração já escolhida.

Tabela 1. O número 2.048 se refere à auditoria de cada extensão. CNN/encoders, palavras/BPE e MLP usam amostras internas distintas.

No preparo original, removemos do treino textos com hash presente no teste, duplicatas internas e conflitos de rótulo. A comparação de hashes usa os textos do teste para excluir duplicatas, com rótulos reservados à avaliação. Os registros distinguem 123 linhas do treino que coincidiam com o teste e 98 duplicatas internas do treino. O teste oficial conserva 201 ocorrências duplicadas. A auditoria detecta igualdade normalizada, de modo que paráfrases e possíveis exposições no pré-treinamento continuam como fontes de incerteza.

As extensões partem do treino limpo. CNN/encoders e palavras/BPE compartilham treino e validação e recebem prefixos de até 128 palavras. Cada rede pode usar até 256 tokens. A auditoria BPE exclui também os papéis da extensão sequencial. A entrada de cada auditoria ficou reservada até o congelamento dos pesos e das escolhas. Os resultados de teste oficial vêm da execução original. Manifesto original. Protocolo sequencial. Protocolo BPE.

Dicionário resumido

Campo	Significado
`id`	Identificador derivado da divisão oficial e da posição na fonte.
`label`	Classe binária usada na função de perda e na avaliação.
`clean_text`	Texto após decodificação de HTML e normalização de espaços.
`word_count`	Número de segmentos separados por espaço no texto limpo.
`text_sha256`	Impressão do texto normalizado usada para verificar duplicações.

Tabela 2. O texto é a entrada do classificador. ID, rótulo e hash têm papéis de preparação ou avaliação. Dicionário completo.

Métricas

A acurácia conta decisões corretas. O F1 macro dá o mesmo peso às duas classes, tomando a média de seus F1. A entropia cruzada binária (CE) usa o escore inteiro, antes de convertê-lo em classe. Se o rótulo é positivo, um escore de 90% contribui com $-\log(0{,}9)$. Um escore de 10% contribui com $-\log(0{,}1)$, uma perda maior. Para n resenhas,

$$\mathrm{CE} = -\frac{1}{n}\sum_{i}\left[y_i \log p_i + (1 - y_i)\log(1 - p_i)\right].$$

Aqui p_i é o escore atribuído ao sentimento positivo. Na execução original, o cálculo salvo limita as probabilidades a $[10^{-7}, 1 - 10^{-7}]$. Os ensaios internos calculam CE diretamente dos logits.

3 Da resenha aos dois logits

Imagine 300 detectores que percorrem a resenha. Cada um reage a um padrão local e entrega sua maior resposta. A camada final aprende quanto cada resposta conta a favor de cada classe. Essa é a TextCNN usada nos ensaios por palavras e por BPE [2, 4].

De palavras a IDs

O tokenizador por palavras preserva contrações, números e negações como *not*. O vocabulário reserva 19.998 lugares aos itens mais frequentes do treino, além de <pad> e <unk>. O BPE aprende fusões de pares de caracteres frequentes nos 6.144 textos de treino, com frequência mínima 2 e vocabulário de 20 mil itens. O marcador </w> indica o fim de palavra [3]. Normalização e vocabulários.

Quando uma palavra vira três peças *The pallbearer scene was unexpectedly moving.*

Palavras `<unk>` BPE `p all bearer</w>`

Uma janela de largura 3 pode cobrir as três peças de uma única palavra.

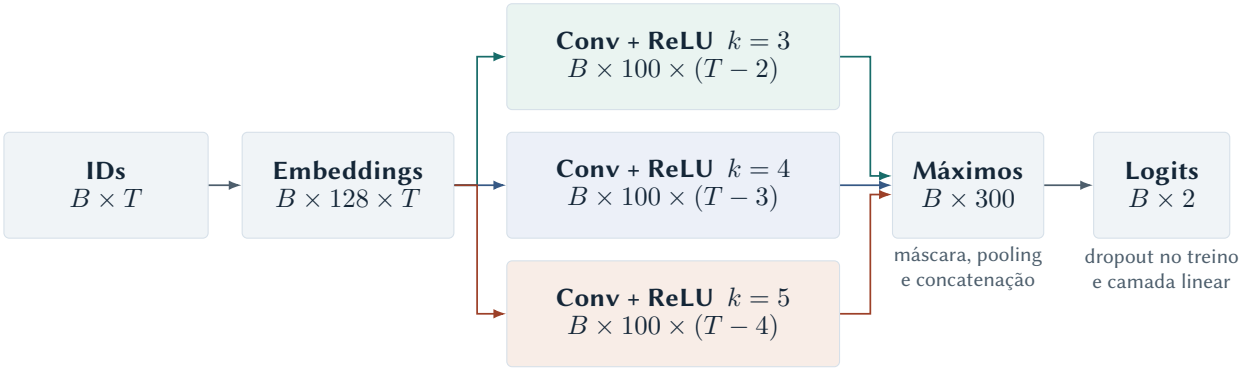


Figura 1. Fluxo da TextCNN. B é o número de resenhas no minibatch e T é o comprimento com padding. As dimensões representam tensores. Os trechos abaixo levam às linhas da implementação.

A mesma conta em cada janela

A sequência de IDs consulta vetores de 128 coordenadas aprendidas no treino. Após a transposição, os 128 canais entram na convolução. Para um filtro f de largura k, a mesma matriz W_f e o mesmo viés b_f são usados em todas as posições. Se e_t é o embedding na posição t, temos

$$a_{f,t} = \max(0,\, \langle W_f, [e_t, \ldots, e_{t+k-1}] \rangle + b_f)\,, \qquad m_f = \max_{t \in \mathcal{V}_k} a_{f,t}.$$

A ReLU põe respostas negativas em zero. O máximo m_f guarda a força do melhor encaixe. Para uma sequência de L tokens, a máscara mantém $\max(1, L - k + 1)$ posições iniciais. Se $L < k$, fica uma janela com padding. `embedding`, `conv`, `masked_fill`.

Do pico à classe

Os máximos formam um vetor m de 300 componentes. No treino, passa-se por dropout de 0,5 antes da camada linear. Na inferência, a saída é $z = Wm + b$, com dois logits, z_- e z_+. A margem $\Delta = z_+ - z_-$ expressa a diferença entre os votos das duas classes. O softmax binário dá $p(+) = \sigma(\Delta)$. Uma margem positiva corresponde a $p(+) > 0{,}5$. Na frase A da semente 17 por palavras, $z_- \approx 2{,}259$ e $z_+ \approx -2{,}863$ dão $p(+) \approx 0{,}59\%$. A entropia cruzada do treino recebe os dois logits diretamente. `classifier`.

Onde estão os 2.714.502 parâmetros da CNN por palavras?

$20.000 \times 128 = 2.560.000$ nos embeddings. $100 \sum_{k \in \{3,4,5\}} (128k + 1) = 153.900$ nas convoluções. $2(300 + 1) = 602$ na saída.

4 O que mudou durante o treino

Em cada minibatch, a rede produz dois logits por resenha e a entropia cruzada mede a perda frente ao rótulo. O *backward* calcula os gradientes dos embeddings, filtros e saída. Limitamos sua norma global a 1 antes da atualização. Os embeddings começam com distribuição normal de desvio 0,1 e linha de padding zero. Os filtros usam inicialização de He e a saída, Xavier [4].

Como escolhemos a taxa e a época

Otimizador	Taxas testadas	Escolhida
SGD	0,001 0,03 0,3	0,3
SGD com momentum 0,9	0,001 0,01 0,1	0,1
Adam	0,0003 0,001 0,003	0,001

Tabela 3. Três sementes por célula (17, 29 e 43), minibatches de 64 e orçamento de 12 épocas. A CNN base tem larguras 3/4/5, cem filtros por largura e dropout de 0,5.

Na mesma semente, fixamos pesos iniciais e ordem dos minibatches. Salvamos a época de menor CE de validação de cada treino e escolhemos a taxa com a menor média dessa perda entre sementes. A época zero é a inicialização.

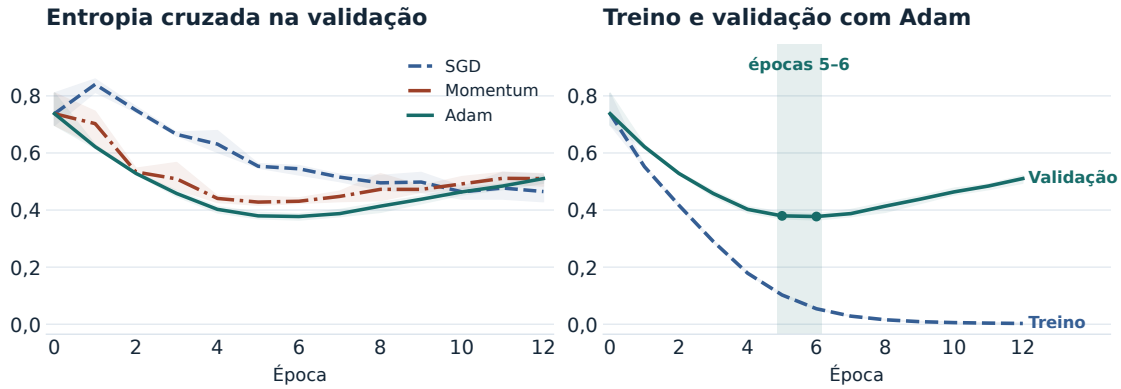


Figura 2. As linhas são médias e as faixas cobrem mínimo e máximo entre sementes. À esquerda, cada otimizador usa sua taxa escolhida. À direita, a perda de treino com Adam continua caindo depois da melhor região de validação. Os checkpoints de Adam vêm das épocas 5 e 6.

Largura, número de filtros e dropout

Fizemos 42 treinos de CNN. Além dos 27 acima, nove variaram largura ou número de filtros e seis variaram dropout. Na auditoria sequencial, larguras 3 e 5 isoladas (100 filtros) chegaram a 81,27% e 80,94% de acurácia. A combinação 3/4/5 chegou a 81,95% com 300 filtros e a 81,64% com 96. Com dropout de 0,8, a acurácia foi 80,44%. Grade e métricas por semente.

Palavras e BPE no mesmo experimento

As duas tokenizações usam Adam a 0,001, as mesmas dimensões, dropout, minibatches e orçamento. Escolhemos a época na validação. Na mesma semente, a matriz inicial é igual, e suas linhas representam unidades diferentes.

Tokenizer	Acurácia	F1 macro	CE	UNK	Tokens médios
Palavras	82,00%	0,8200	0,3964	3,27%	121,3
BPE 20 mil	81,41%	0,8140	0,4052	0,00%	129,1

Tabela 4. Médias de três sementes em 2.048 resenhas. UNK é a fração de tokens desconhecidos. Com BPE, a acurácia caiu nas três sementes e 0,59 ponto percentual em média. Métricas por execução.

5 O teste oficial e as resenhas que dividem os modelos

O baseline usa TF-IDF de unigramas e bigramas, regressão logística e texto completo. A CNN original recebe até 400 tokens. BERT recebe até 192 WordPieces e tem seus pesos ajustados para a tarefa [5]. Cada linha mede o resultado da receita inteira, com seu recorte, representação e regime de treino.

Divisão	Modelo	Acurácia	F1 macro	CE bruta
Treino	TF-IDF + logística	99,72%	0,9972	0,0973
Treino	CNN	94,95%	0,9494	0,1567
Treino	BERT	96,32%	0,9632	0,1138
Validação	TF-IDF + logística	91,53%	0,9152	0,2255
Validação	CNN	87,97%	0,8796	0,2877
Validação	BERT	91,28%	0,9128	0,2404
Teste	TF-IDF + logística	90,14%	0,9014	0,2531
Teste	CNN	86,78%	0,8678	0,3040
Teste	BERT	90,94%	0,9094	0,2433

Tabela 5. Escores antes da calibração. Treino com 19.823 resenhas, validação com 2.478 e teste oficial com 25.000. Resultados originais.

Quem acertou quando o outro errou?

Cruzamos as previsões da CNN e do TF-IDF pelo ID das 25.000 resenhas. Apenas o TF-IDF acertou 1.715 e apenas a CNN acertou 875. Ambos acertaram 20.821 e ambos erraram 1.589. A fração de acertos exclusivos do TF-IDF foi 10,87% no grupo em que a CNN teve recorte, ante 6,29% no grupo sem recorte. Para a CNN, as duas frações foram 3,53% e 3,50%. Esse cruzamento compara grupos de textos diferentes. Para ver o efeito da entrada em um mesmo caso, repetimos as previsões da resenha longa.

Resenha longa / 780 tokens / rótulo negativo

A crítica explícita aparece depois do limite de 400 tokens. Mantivemos os pesos e passamos o prefixo e o texto inteiro aos dois modelos.

	TF-IDF $p(+)$	CNN $p(+)$
Primeiros 400 tokens	71,7%	94,7%
Texto inteiro	6,5%	12,1%

Com limiar de 50%, a classe dos dois muda de positiva para negativa. No texto inteiro, janelas como *hate to waste* empurram a margem da CNN para o negativo.

Resenha curta / 61 tokens / rótulo positivo

Ambos leem o texto inteiro. A CNN dá 96,6% de escore positivo e o TF-IDF, 45,5%. Na CNN, *part is brilliant* soma $+0{,}257$ à margem e *the ending doesn't make much* soma $-0{,}167$. No TF-IDF, *brilliant* soma $+0{,}503$ e o bigrama *not one* soma $-0{,}337$, embora esse bigrama esteja numa comparação de enredos.

Os escores dos dois casos usam as temperaturas originais. As contribuições acima são para as margens brutas, antes da temperatura. Na CNN, cada contribuição é o máximo de um filtro vezes o peso desse filtro na diferença entre os logits. No TF-IDF, é o valor da feature vezes o coeficiente da regressão. Decomposição e contagens completas.

Encoders na auditoria sequencial

Com os mesmos prefixos de até 128 palavras em 2.048 resenhas, fazemos a média dos estados finais do encoder, excluindo padding e tokens especiais, e aplicamos uma cabeça linear. Congelados, BERT, DistilBERT e ModernBERT atingiram 84,52%, 83,35% e 81,30%. Com ajuste completo, chegaram a 88,31%, 86,80% e 91,24%. A CNN e o TF-IDF tiveram 81,95% e 83,30%. CE, F1 e configurações por execução.

6 Confiança, comprimento e custo

O escore muda. A classe fica.

Ajustamos uma temperatura $\tau > 0$ na amostra de calibração, minimizando a CE. Com margem $\Delta = z_+ - z_-$, o escore passa de $\sigma(\Delta)$ a $\sigma(\Delta/\tau)$. A transformação mantém o sinal de Δ, de modo que a classe e as métricas de classificação permanecem iguais no limiar de 50%.

Modelo	Acurácia	F1 macro	CE calibrada
TF-IDF + logística	90,14%	0,9014	0,2396
CNN	86,78%	0,8678	0,3037
BERT	90,94%	0,9094	0,2278

Tabela 6. Teste oficial, $n = 25.000$, com temperatura escolhida em 2.478 resenhas reservadas. A CE bruta está na Tabela 5.

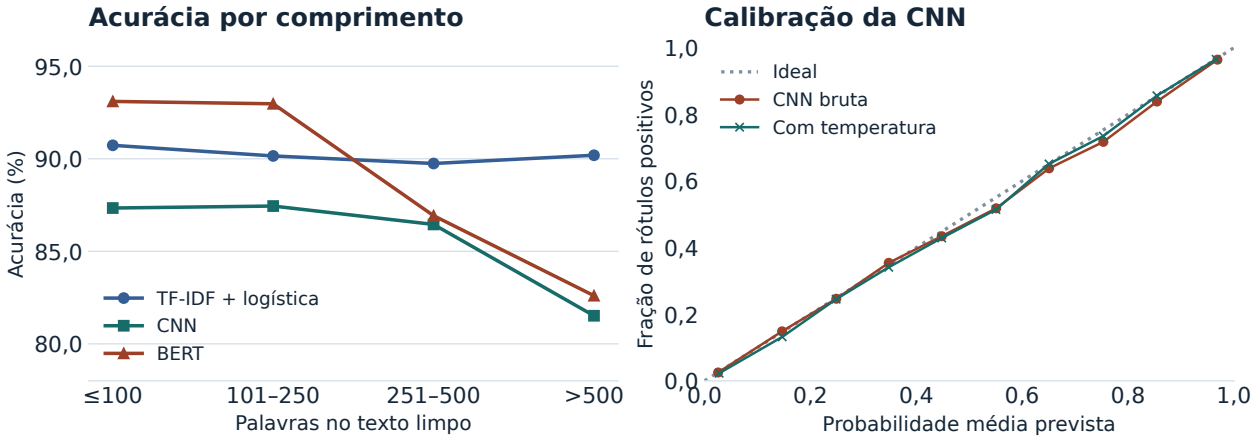


Figura 3. À esquerda, as faixas de comprimento têm 3.246, 14.624, 5.285 e 1.845 resenhas. À direita, o eixo horizontal mostra a probabilidade média prevista e o vertical mostra a fração de positivos observada entre resenhas na mesma faixa de probabilidade. A diagonal indica coincidência entre as duas medidas.

A temperatura mudou pouco a CE da CNN, de 0,3040 para 0,3037. A acurácia da CNN cai de 87,34% nas resenhas de até cem palavras a 81,52% acima de 500. BERT também cai na faixa longa. O TF-IDF recebe o texto completo e varia menos. Comprimento, conteúdo e recorte variam juntos. Métricas por faixa.

O custo das três receitas originais

Modelo	Dispositivo	Ajuste (s)	Inferência (s)
TF-IDF + logística	CPU do Apple M1	13,1	0,15
CNN	Apple M1 (MPS)	139,6	20,72
BERT	NVIDIA GB10 (CUDA)	446,4	149,91

Tabela 7. A inferência soma as quatro divisões. O ajuste do baseline inclui TF-IDF e seleção da regularização. Cada tempo vale para o dispositivo e o orçamento da receita medida.

Ensaios complementares

Em 64 enredos, o Qwen3-8B recebeu uma intervenção no bloco 28, após o marcador de opinião. O próprio modelo reconheceu os dois tons-alvo em 55 enredos. Os resumos factuais coincidiram, mas uma opinião acrescentou um cenário ausente da fonte [8]. Protocolo de geração. O suplemento reúne 51 treinos de MLP e 880 condições sintéticas para estudar *double descent*. Guia dos mecanismos.

7 Quando o modelo de aprendizagem profunda falha?

As duas frases e os seis votos

A / leitura positiva

*I thought this movie was terrible, but it was **wonderful**.*

Termina com elogio.

B / leitura negativa

*I thought this movie was wonderful, but it was **terrible**.*

Termina com crítica.

Cada linha é um checkpoint, os pesos salvos de um treino. Palavras e BPE têm três sementes cada (17, 29 e 43). O círculo marca o escore positivo de A, e o losango, o de B. Os seis treinos deram classe negativa a A e positiva a B. A leitura adotada segue a oração depois de *but*.

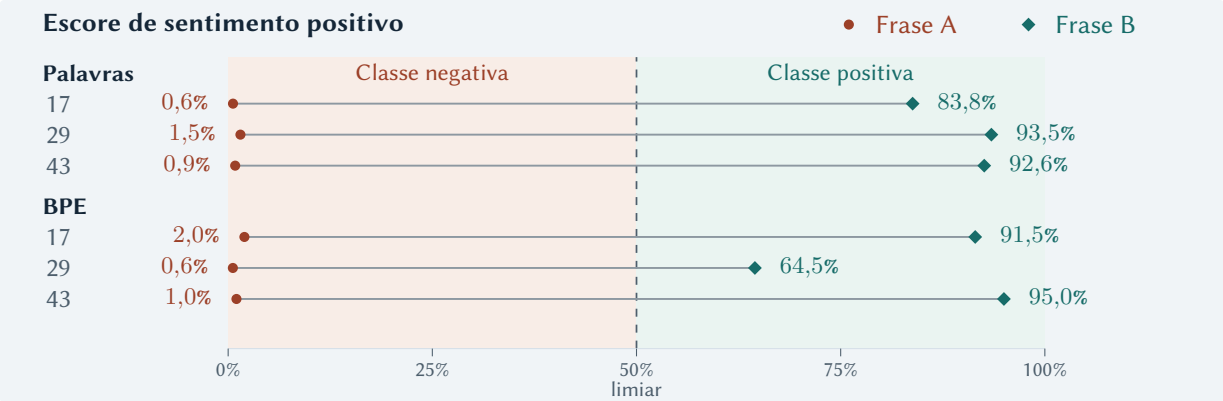


Figura 4. Escores sem calibração, por checkpoint. Da frase A para B, a média sobe de 1,0% para 89,9% com palavras, e de 1,2% para 83,7% com BPE. Escores e logits por treino.

O que o filtro 89 viu

Na CNN por palavras da semente 17, o filtro 89 lê três tokens por vez. Em A, o pico está em *movie was terrible*, antes de *but*. Em B, aparece em *it was terrible*, no fim. O máximo global envia apenas a altura do pico. A camada linear combina essa altura com as dos outros 299 filtros.

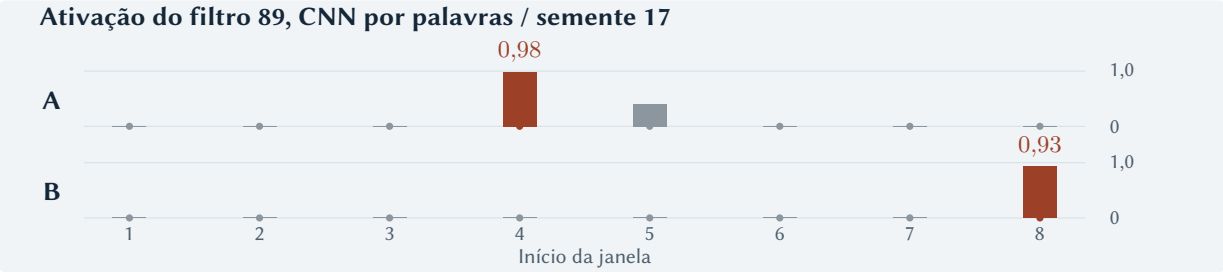


Figura 5. Ativações após a ReLU nas oito janelas de cada frase. Em A, a primeira janela *i thought this* vai de −0,42 a 0. Com passo 2, só são visitadas as janelas 1, 3, 5 e 7. O pico da janela 4 fica de fora e o máximo passa de 0,98 a 0,40. Ativações registradas.

Efeito do passo. O passo s faz a janela começar em $0, s, 2s, \ldots$. Para $L \geq k$, há $1 + \lfloor (L-k)/s \rfloor$ janelas completas. Nas mesmas 2.048 resenhas da auditoria BPE e com os pesos congelados das três CNNs por palavras, a acurácia média foi 82,00%, 81,45% e 80,97% nos passos 1, 2 e 3. O passo 2 conservou 50,2% das janelas e o passo 3, 33,6%. Resultados por passo.

Na página 8, trocamos trechos preservando as janelas para isolar a perda de posição.

Um controle que preserva as janelas

Montamos os dois textos abaixo. O separador S é a frase *I have a few thoughts about this movie.*

A `S` `I loved the acting` `S` `I hated the ending` `S`

B `S` `I hated the ending` `S` `I loved the acting` `S`

O separador impede que uma janela de até cinco tokens alcance os dois trechos. Verificamos que A e B contêm as mesmas janelas de IDs, com as mesmas multiplicidades, para $k = 3, 4, 5$ nas duas tokenizações. Cada filtro recebe o mesmo conjunto de ativações e devolve o mesmo máximo. Os dois logits coincidiram em cada checkpoint. As duas versões expressam opiniões mistas. Par e predições.

Dois picos por filtro separam o par. Eles ajudam no contraste?

Congelamos embeddings e filtros das três CNNs por palavras. Para cada largura, dividimos as janelas válidas em duas metades (o excedente fica na primeira) e extraímos os máximos u e v, com $v = 0$ se a segunda metade estiver vazia. Reajustamos regressões logísticas em 6.144 resenhas e escolhemos $C \in \{10^{-3}, 10^{-2}, 10^{-1}, 1, 10\}$ por CE na validação de 1.536 resenhas. As duas versões de 600 valores usam os mesmos picos. Ordenar pelo valor, $(\min(u, v), \max(u, v))$, descarta a metade de origem. Ordenar pela posição, (u, v), a preserva.

Saída por filtro	Auditoria	Pares sintéticos	Pares editados
Máximo, cabeça original	82,00%	40,23%	40,21%
Máximo, cabeça reajustada	81,90%	39,19%	40,02%
Dois picos por valor	82,28%	39,32%	39,83%
Dois picos por posição	82,29%	39,97%	39,15%

Tabela 8. Média de três sementes. A auditoria mede acurácia por texto em 2.048 resenhas. Nas outras colunas, o par conta como acerto se as duas versões forem classificadas corretamente.

Os 256 pares sintéticos cruzam quatro moldes e dois conjuntos de oito adjetivos. Dos 488 pares editados do IMDb Contrast Set [6], excluímos 144 com entrada de IDs já vista no treino ou na validação. Oito dos 344 pares restantes ficam idênticos após o recorte, com rótulos opostos. No par de controle, só a cabeça com posição deu margens diferentes para A e B nas três sementes. Nos pares editados, ela acertou 39,15%, ante 39,83% com dois picos por valor. Nos dois moldes sintéticos com veredito depois do contraste, todas as cabeças ficaram em 0 de 128 pares por semente. Métricas e margens por semente.

Fora do IMDb

Em 1.000 frases de Amazon, palavras e BPE tiveram 68,10% e 69,97% de acurácia média. Nas 1.000 de Yelp, tiveram 69,43% e 69,67%. Cada fonte contém 500 exemplos por classe [7]. Aplicamos os mesmos seis checkpoints. Entre cinco comentários de trailers, o elogio entre aspas seguido de *No one* recebeu classe positiva de todos os treinos. Os comentários servem de leitura qualitativa. F1, CE e escores por semente.

Referências

[1] Maas, A. L. et al. *Learning Word Vectors for Sentiment Analysis.* ACL, 2011. ACL Anthology.
[2] Kim, Y. *Convolutional Neural Networks for Sentence Classification.* EMNLP, 2014. ACL Anthology.
[3] Sennrich, R., Haddow, B. e Birch, A. *Neural Machine Translation of Rare Words with Subword Units.* ACL, 2016. ACL Anthology.
[4] Prince, S. J. D. *Understanding Deep Learning.* MIT Press, 2023. Caps. 6, 8, 9 e 10. Livro e materiais.
[5] Devlin, J. et al. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.* NAACL, 2019. ACL Anthology.
[6] Gardner, M. et al. *Evaluating Models' Local Decision Boundaries via Contrast Sets.* Findings of EMNLP, 2020. ACL Anthology.
[7] Kotzias, D. et al. *From Group to Individual Labels Using Deep Features.* KDD, 2015. Artigo. Coleção UCI.
[8] Yang, A. et al. *Qwen3 Technical Report*, 2025. arXiv.