MAE5920 · INTRODUÇÃO A DEEP LEARNING

O que a CNN lê em uma resenha?

Classificação de sentimento e tokenização no IMDb

Nestor, Letícia e Gabriel

Resumo

No teste oficial de 25.000 resenhas, TF-IDF, TextCNN e BERT ajustado atingiram 90,14%, 86,78% e 90,94% de acurácia. Em uma auditoria separada, BPE reduziu a taxa de tokens desconhecidos de 3,27% para zero, com acurácia média de 81,41% ante 82,00% com palavras. Em um par sintético que troca elogio e crítica, as seis CNNs seguiram a polaridade da primeira oração. Em outro par, as mesmas janelas em ordem diferente produziram logits iguais. Guardar dois picos na ordem do texto distinguiu os escores desse controle, com acerto semelhante nos pares editados por pessoas.

1 Introdução

Classificamos resenhas de filmes do IMDb como positivas ou negativas. Comparamos TF-IDF com regressão logística, uma TextCNN treinada do zero e BERT ajustado. O objetivo didático é entender como tokenização, janelas de convolução e máximo global condicionam as decisões da CNN. Além das métricas médias, usamos alterações controladas de texto e exemplos de outros domínios para investigar seus limites.

Duas frases, dois finais

As micro-resenhas abaixo usam as mesmas palavras. A troca coloca um elogio ou uma crítica depois de *but*, onde lemos o veredito.

A / leitura positiva

*I thought this movie was terrible, but it was **wonderful**.*

Termina com elogio.

B / leitura negativa

*I thought this movie was wonderful, but it was **terrible**.*

Termina com crítica.

Cada palavra aparece o mesmo número de vezes. Um modelo que só conta palavras isoladas recebe a mesma entrada. O TF-IDF do estudo inclui bigramas, que podem mudar com a troca. A CNN também recebe informação de ordem dentro de cada janela. A Seção 5 mostra o que cada treino fez com os dois finais.

Uso de ferramentas de IA

Usamos o Codex, da OpenAI, na implementação de código, execução e análise dos experimentos e elaboração e revisão de textos, figuras e slides. O Qwen3-8B foi empregado como modelo experimental. Os resultados quantitativos provêm das execuções registradas no repositório. A revisão final e a responsabilidade pelo conteúdo cabem aos autores.

Código, notebook executado e métricas por execução. Repositório do projeto.

2 Dados e protocolo de avaliação

O Large Movie Review Dataset contém 25.000 resenhas em inglês no treino oficial e 25.000 no teste [1]. Os rótulos são 0 para negativo e 1 para positivo. A limpeza aplica regras fixas a cada resenha, decodificando HTML, removendo tags e normalizando espaços. A busca de duplicatas usa SHA-256 do texto limpo após normalizar maiúsculas e minúsculas (*casefold*).

Papéis das amostras

Papel	Original	Ensaios internos	Uso
Treino	19.823	6.144	Ajustar representação, vocabulário e pesos.
Validação	2.478	1.536	Escolher hiperparâmetros e época.
Calibração	2.478	–	Ajustar temperatura após a seleção original.
Teste/auditoria	25.000	2.048	Avaliar a configuração já escolhida.

Tabela 1. CNN/encoders, palavras/BPE e MLP usam auditorias distintas de 2.048 resenhas.

CNN/encoders e palavras/BPE partem do treino limpo e compartilham treino e validação. Recebem até 128 palavras e até 256 tokens. A auditoria BPE exclui também os papéis sequenciais. Cada auditoria foi aberta após congelar pesos e escolhas. Protocolos sequencial e BPE.

Análise de possíveis vazamentos de informação

No preparo original, removemos 123 linhas do treino com hash presente no teste e 98 duplicatas internas. A comparação acessou os textos do teste para excluir duplicatas, com os rótulos reservados à avaliação. Os quatro conjuntos finais têm zero hashes compartilhados entre papéis. O teste oficial conserva 201 ocorrências duplicadas. Manifesto original.

TF-IDF, vocabulário da CNN e fusões do BPE foram ajustados apenas no treino. A checagem cobre igualdade de texto após normalização. Paráfrases e possível exposição ao IMDb no pré-treinamento seguem como limitações. A análise de erros e a extensão do Qwen sobre o IMDb reutilizam o teste em caráter exploratório.

Dicionário de dados resumido

Campo	Significado
`id`	Identificador derivado da divisão oficial e da posição na fonte.
`label`	Classe binária usada na função de perda e na avaliação.
`clean_text`	Texto após decodificação de HTML e normalização de espaços.
`word_count`	Número de segmentos separados por espaço no texto limpo.
`text_sha256`	Impressão do texto normalizado usada para verificar duplicações.

Tabela 2. O texto é a entrada do classificador. ID, rótulo e hash têm papéis de preparação ou avaliação. Dicionário completo.

Métricas

A acurácia conta decisões corretas. O F1 macro dá o mesmo peso às duas classes, tomando a média de seus F1. A entropia cruzada binária (CE) usa o escore inteiro, antes de convertê-lo em classe. Se o rótulo é positivo, um escore de 90% contribui com $-\log(0{,}9)$. Um escore de 10% contribui com $-\log(0{,}1)$, uma perda maior. Para n resenhas,

$$\mathrm{CE} = -\frac{1}{n}\sum_{i}\left[y_i \log p_i + (1-y_i)\log(1-p_i)\right].$$

Aqui p_i é o escore atribuído ao sentimento positivo. Na execução original, o cálculo salvo limita as probabilidades a $[10^{-7}, 1-10^{-7}]$. Os ensaios internos calculam CE diretamente dos logits.

3 Arquitetura da TextCNN

A TextCNN usada nos ensaios por palavras e por BPE reúne 300 filtros [2, 4]. Cada filtro entrega a maior resposta entre suas janelas. Filtros diferentes podem atingir o máximo em trechos diferentes. A camada final aprende quanto cada uma das 300 respostas conta para cada classe.

De palavras a IDs

O tokenizador por palavras preserva contrações, números e negações como *not*. O vocabulário reserva 19.998 lugares aos itens mais frequentes do treino, além de `<pad>` e `<unk>`. O BPE aprende fusões de pares de caracteres frequentes nos 6.144 textos de treino, com frequência mínima 2 e vocabulário de 20 mil itens. O marcador `</w>` indica o fim de palavra [3]. Normalização e vocabulários.

Quando uma palavra vira três peças *The pallbearer scene was unexpectedly moving.*

Palavras `<unk>` BPE `p` `all` `bearer</w>`

Uma janela de largura 3 pode cobrir as três peças de uma única palavra.

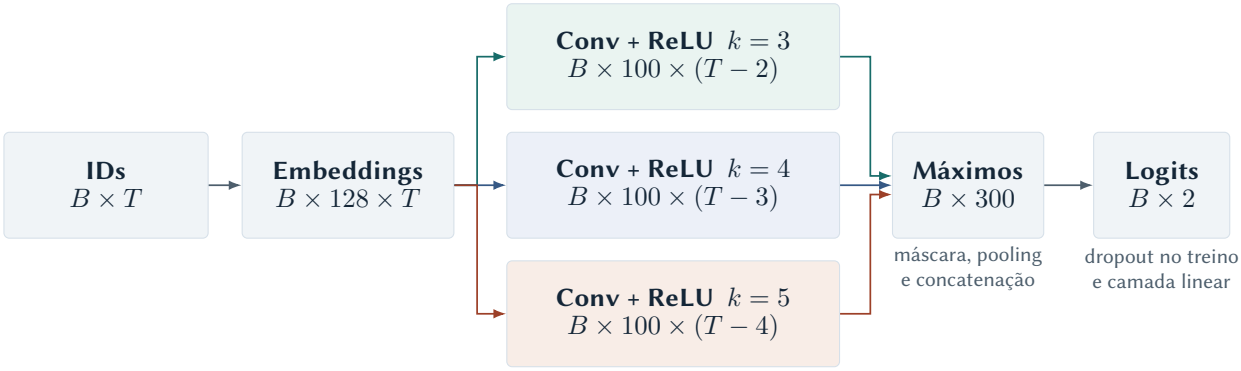


Figura 1. Fluxo da TextCNN. B é o número de resenhas no minibatch e T é o comprimento com padding. As dimensões representam tensores. Os trechos abaixo levam às linhas da implementação.

A mesma conta em cada janela

A tabela de embeddings tem 20.000×128 valores. Um lote de $B \times T$ IDs gera $B \times T \times 128$. A transposição põe os 128 canais antes de T. Cada filtro de largura k lê k tokens consecutivos em ordem. Usamos larguras 3, 4 e 5. O filtro f reaplica os pesos W_f e o viés b_f em cada janela. Se e_t é o embedding na posição t, temos

$$a_{f,t} = \max(0,\, \langle W_f, [e_t, \ldots, e_{t+k-1}] \rangle + b_f)\,, \qquad m_f = \max_{t \in \mathcal{V}_k} a_{f,t}.$$

A ReLU põe respostas negativas em zero. O máximo m_f guarda a altura do pico e descarta sua posição. Para uma sequência de L tokens, a máscara mantém $\max(1, L - k + 1)$ posições iniciais. Se $L < k$, fica uma janela com padding. `embedding`, `conv`, `masked_fill`.

Do pico à classe

Os máximos formam um vetor m de 300 componentes. No treino, passa-se por dropout de 0,5 antes da camada linear. Na inferência, a saída é $z = Wm + b$, com dois logits, z_- e z_+. A margem $\Delta = z_+ - z_-$ expressa a diferença entre os votos das duas classes. O softmax binário dá $p(+) = \sigma(\Delta)$. Uma margem positiva corresponde a $p(+) > 0{,}5$. Na frase A da semente 17 por palavras, $z_- \approx 2{,}259$ e $z_+ \approx -2{,}863$ dão $p(+) \approx 0{,}59\%$. A entropia cruzada do treino recebe os dois logits diretamente. `classifier`.

Onde estão os 2.714.502 parâmetros da CNN por palavras?

$20.000 \times 128 = 2.560.000$ nos embeddings. $100 \sum_{k \in \{3,4,5\}} (128k + 1) = 153.900$ nas convoluções. $2(300 + 1) = 602$ na saída.

4 Experimentos e resultados

Otimização e seleção de época

Em cada minibatch, a rede produz dois logits por resenha e a entropia cruzada mede a perda frente ao rótulo. O *backward* calcula os gradientes dos embeddings, filtros e saída. Limitamos sua norma global a 1 antes da atualização. Os embeddings começam com distribuição normal de desvio 0,1 e linha de padding zero. Os filtros usam inicialização de He e a saída, Xavier [4].

Otimizador	Taxas testadas	Escolhida
SGD	0,001 0,03 0,3	0,3
SGD com momentum 0,9	0,001 0,01 0,1	0,1
Adam	0,0003 0,001 0,003	0,001

Tabela 3. Três sementes por célula (17, 29 e 43), minibatches de 64 e orçamento de 12 épocas. A CNN base tem larguras 3/4/5, cem filtros por largura e dropout de 0,5.

Na mesma semente, fixamos pesos iniciais e ordem dos minibatches. Salvamos a época de menor CE de validação de cada treino e escolhemos a taxa com a menor média dessa perda entre sementes. A época zero é a inicialização.

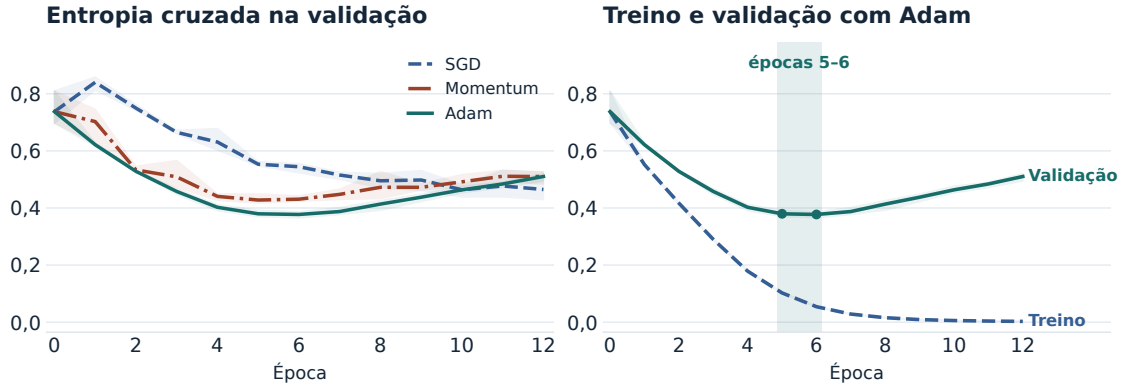


Figura 2. As linhas são médias e as faixas cobrem mínimo e máximo entre sementes. À esquerda, cada otimizador usa sua taxa escolhida. À direita, a perda de treino com Adam continua caindo depois da melhor região de validação. Os checkpoints de Adam vêm das épocas 5 e 6.

Largura, número de filtros e dropout

Dos 42 treinos de CNN, nove variaram largura ou número de filtros e seis variaram dropout. Com o mesmo recorte e 100 filtros, as larguras 3 e 5 deram 81,27% e 80,94% de acurácia na auditoria sequencial. Combinar 3/4/5 também mudou o total de filtros, com 81,95% usando 300 e 81,64% usando 96. Com dropout de 0,8, a acurácia foi 80,44%. Métricas por semente. Código dos treinos.

Palavras e BPE no mesmo experimento

As duas tokenizações usam Adam a 0,001, as mesmas dimensões, dropout, minibatches e orçamento. Escolhemos a época na validação. Na mesma semente, a matriz inicial é igual, e suas linhas representam unidades diferentes.

Tokenizer	Acurácia	F1 macro	CE	UNK	Tokens médios
Palavras	82,00%	0,8200	0,3964	3,27%	121,3
BPE 20 mil	81,41%	0,8140	0,4052	0,00%	129,1

Tabela 4. Médias de três sementes em 2.048 resenhas. UNK é a fração de tokens desconhecidos. Com BPE, a acurácia caiu nas três sementes e 0,59 ponto percentual em média. Métricas por execução.

Resultados no teste oficial do IMDb

O baseline pondera as frequências de palavras e pares consecutivos (bigramas) na resenha inteira. Os pares captam ordem local. O vetor agrega as ocorrências sem registrar suas posições, e a regressão logística combina os valores de TF-IDF. A CNN original lê até 400 tokens do início. BERT recebe até 192 WordPieces e tem pesos ajustados para a tarefa [5]. A tabela compara as receitas completas. Código do baseline.

Divisão	Modelo	Acurácia	F1 macro	CE bruta
Treino	TF-IDF + logística	99,72%	0,9972	0,0973
Treino	CNN	94,95%	0,9494	0,1567
Treino	BERT	96,32%	0,9632	0,1138
Validação	TF-IDF + logística	91,53%	0,9152	0,2255
Validação	CNN	87,97%	0,8796	0,2877
Validação	BERT	91,28%	0,9128	0,2404
Teste	TF-IDF + logística	90,14%	0,9014	0,2531
Teste	CNN	86,78%	0,8678	0,3040
Teste	BERT	90,94%	0,9094	0,2433

Tabela 5. Escores antes da calibração. Treino com 19.823 resenhas, validação com 2.478 e teste oficial com 25.000. Resultados originais.

Discordâncias entre TF-IDF e CNN e efeito do recorte

Cruzamos as previsões da CNN e do TF-IDF pelo ID das 25.000 resenhas. Apenas o TF-IDF acertou 1.715 e apenas a CNN acertou 875. Ambos acertaram 20.821 e ambos erraram 1.589. O recorte de 400 tokens afetou 3.118 resenhas (12,5%) e descartou 10,4% dos tokens do teste. Entre as recortadas e as demais, os acertos exclusivos foram 10,87% e 6,29% para o TF-IDF e 3,53% e 3,50% para a CNN. Com os mesmos pesos, ler o texto inteiro elevou a acurácia de 82,33% a 86,31% nas recortadas e de 86,78% a 87,28% no teste. Comparação pareada.

Resenha longa / 780 tokens / rótulo negativo

A frase "*I had to leave because it was so bad.*" aparece depois do limite de 400 tokens. Passamos o prefixo e o texto inteiro aos mesmos modelos. Com a entrada maior, a CNN percorre mais janelas com os mesmos filtros.

	TF-IDF $p(+)$	CNN $p(+)$
Primeiros 400 tokens	71,7%	94,7%
Texto inteiro	6,5%	12,1%

Com limiar de 50%, a classe dos dois muda de positiva para negativa. No texto inteiro, janelas como *hate to waste* empurram a margem da CNN para o negativo.

Resenha curta / 61 tokens / rótulo positivo

Ambos leem o texto inteiro. A CNN dá 96,6% de escore positivo e o TF-IDF, 45,5%. Na CNN, *part is brilliant* soma $+0{,}257$ à margem e *the ending doesn't make much* soma $-0{,}167$. No TF-IDF, *brilliant* soma $+0{,}503$ e o bigrama *not one* soma $-0{,}337$, embora esse bigrama esteja numa comparação de enredos.

Os escores dos dois casos usam as temperaturas originais. As contribuições acima são para as margens brutas, antes da temperatura. Na CNN, cada contribuição é o máximo de um filtro vezes o peso desse filtro na diferença entre os logits. No TF-IDF, é o valor da feature vezes o coeficiente da regressão. Decomposição e contagens completas. Código da comparação.

Encoders na auditoria sequencial

Com os mesmos prefixos de até 128 palavras em 2.048 resenhas, fazemos a média dos estados finais do encoder, excluindo padding e tokens especiais, e aplicamos uma cabeça linear. Congelados, BERT, DistilBERT e ModernBERT atingiram 84,52%, 83,35% e 81,30%. Com ajuste completo, chegaram a 88,31%, 86,80% e 91,24%. A CNN e o TF-IDF tiveram 81,95% e 83,30%. CE, F1 e configurações por execução.

Calibração e desempenho por comprimento

Ajustamos uma temperatura $\tau > 0$ na amostra de calibração, minimizando a CE. Com margem $\Delta = z_+ - z_-$, o escore passa de $\sigma(\Delta)$ a $\sigma(\Delta/\tau)$. A transformação mantém o sinal de Δ, de modo que a classe e as métricas de classificação permanecem iguais no limiar de 50%.

Modelo	Acurácia	F1 macro	CE calibrada
TF-IDF + logística	90,14%	0,9014	0,2396
CNN	86,78%	0,8678	0,3037
BERT	90,94%	0,9094	0,2278

Tabela 6. Teste oficial, $n = 25.000$, com temperatura escolhida em 2.478 resenhas reservadas. A CE bruta está na Tabela 5.

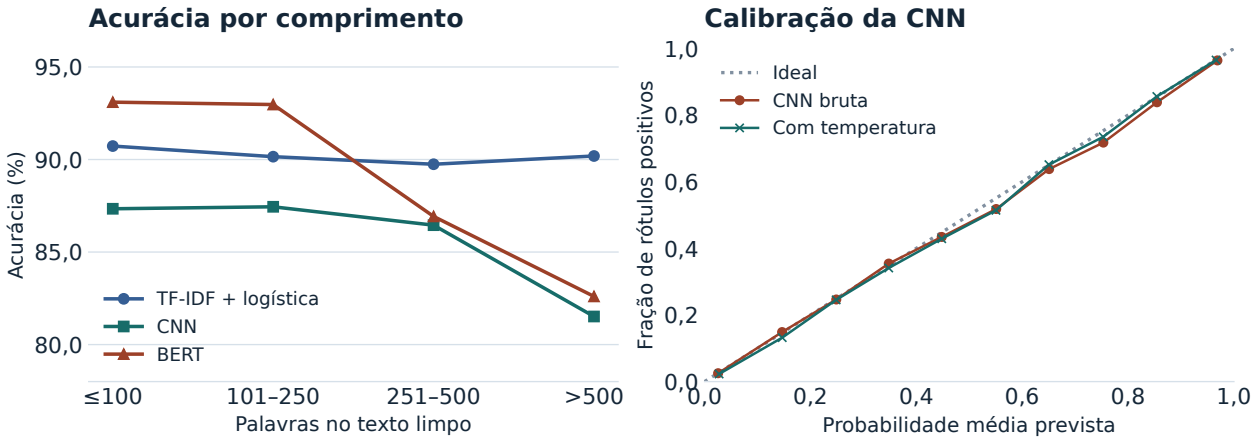


Figura 3. As faixas de comprimento por contagem de palavras têm 3.246, 14.624, 5.285 e 1.845 resenhas. Na calibração, a diagonal indica coincidência entre o escore médio e a fração observada de positivos.

A temperatura mudou pouco a CE da CNN, de 0,3040 para 0,3037. A acurácia da CNN cai de 87,34% nas resenhas de até cem palavras a 81,52% acima de 500. BERT também cai na faixa longa. O TF-IDF recebe o texto completo e varia menos. Comprimento, conteúdo e recorte variam juntos. Métricas por faixa.

Custo computacional

Modelo	Dispositivo	Ajuste (s)	Inferência (s)
TF-IDF + logística	CPU do Apple M1	13,1	0,15
CNN	Apple M1 (MPS)	139,6	20,72
BERT	NVIDIA GB10 (CUDA)	446,4	149,91

Tabela 7. A inferência soma as quatro divisões. O ajuste do baseline inclui TF-IDF e seleção da regularização. Cada tempo vale para o dispositivo e o orçamento da receita medida.

Avaliação fora do IMDb

Em 1.000 frases balanceadas por fonte, a acurácia média das CNNs por palavras e BPE foi 68,10% e 69,97% na Amazon e 69,43% e 69,67% no Yelp [7]. Em um dos cinco comentários do YouTube, o elogio seguido de *No one* recebeu classe positiva dos seis treinos. Escores. Em dois comentários, o mesmo Qwen gerou os mesmos rótulos diretamente e após um bloco de raciocínio. Código.

Ensaios complementares

Em 64 enredos, o Qwen3-8B recebeu uma intervenção no bloco 28, após o marcador de opinião. O próprio modelo reconheceu os dois tons-alvo em 55 enredos. Os resumos factuais coincidiram, mas uma opinião acrescentou um cenário ausente da fonte [8]. Protocolo de geração. O suplemento reúne 51 treinos de MLP e 880 condições sintéticas para estudar *double descent*. Guia dos mecanismos.

5 Quando o modelo de aprendizagem profunda falha?

A mesma troca no TF-IDF e na CNN

A / leitura positiva

*I thought this movie was terrible, but it was **wonderful**.*

Termina com elogio.

B / leitura negativa

*I thought this movie was wonderful, but it was **terrible**.*

Termina com crítica.

As contagens de palavras isoladas são iguais. O TF-IDF conta o bigrama *terrible but* em A e *wonderful but* em B. O escore positivo bruto passa de 47,93% para 47,86%, com classe negativa nas duas frases. Escores do baseline.

Cada linha da figura representa um treino de CNN. Nas três sementes por palavras e nas três com BPE, a CNN deu negativa a A e positiva a B. A leitura adotada segue a oração depois de *but*.

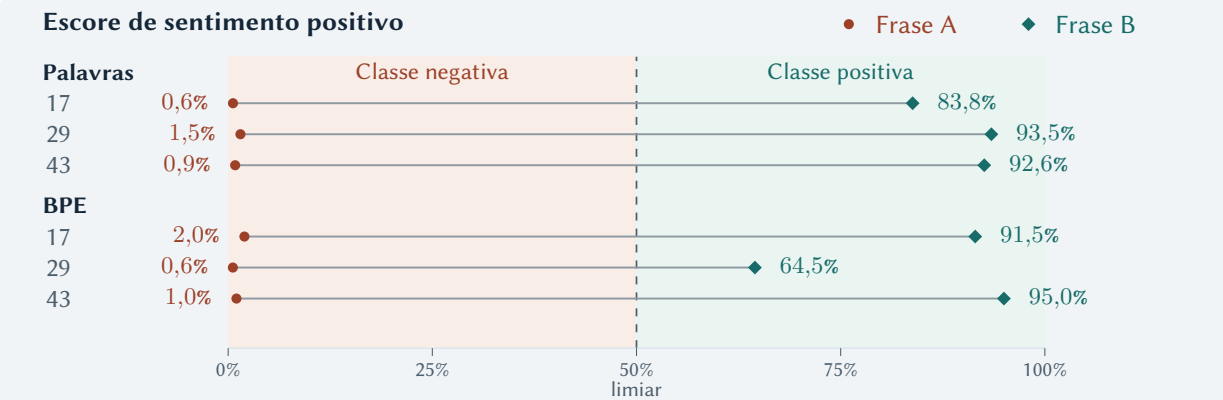


Figura 4. Escores sem calibração, por checkpoint. Da frase A para B, a média sobe de 1,0% para 89,9% com palavras, e de 1,2% para 83,7% com BPE. Escores e logits por treino. Código dos pares.

O que o filtro 89 viu

Na CNN por palavras da semente 17, o filtro 89 lê três tokens por vez. Em A, o pico está em *movie was terrible*, antes de *but*. Em B, aparece em *it was terrible*, no fim. O máximo global envia apenas a altura do pico. A camada linear combina essa altura com as dos outros 299 filtros.

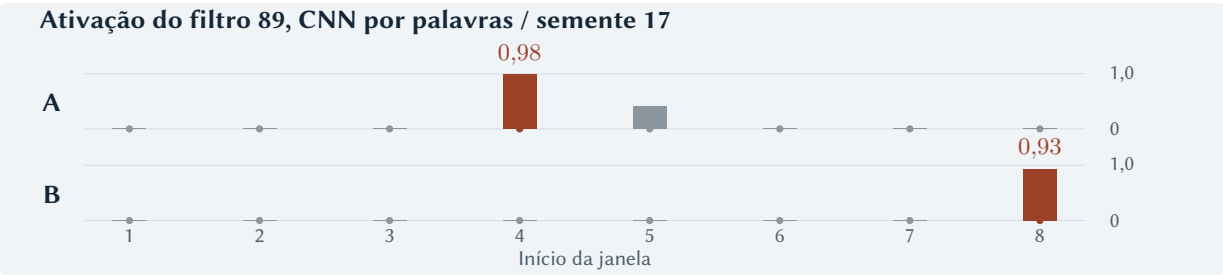


Figura 5. Ativações após a ReLU nas oito janelas de cada frase. Em A, a primeira janela *i thought this* vai de −0,42 a 0. Com passo 2, só são visitadas as janelas 1, 3, 5 e 7. O pico da janela 4 fica de fora e o máximo passa de 0,98 a 0,40. Ativações registradas.

Efeito do passo. O passo s faz a janela começar em $0, s, 2s, \ldots$. Para $L \geq k$, há $1 + \lfloor (L-k)/s \rfloor$ janelas completas. Nas mesmas 2.048 resenhas da auditoria BPE e com os pesos congelados das três CNNs por palavras, a acurácia média foi 82,00%, 81,45% e 80,97% nos passos 1, 2 e 3. O passo 2 conservou 50,2% das janelas e o passo 3, 33,6%. Resultados por passo.

Nos dois tokenizadores, a janela de cinco tokens já inclui *terrible but it was wonderful*. Sete tokens ampliariam o contexto para incluir *movie was*. A troca dos adjetivos muda as janelas. As previsões refletem a rede inteira. Para isolar o efeito de perder a posição, usamos o controle da página 8.

Controle da posição com as mesmas janelas

Montamos dois textos de controle com o elogio e a crítica em ordens opostas. Repetimos S, a frase "*I have a few thoughts about this movie.*", antes, entre e depois das opiniões para manter os vizinhos de cada uma.

A `S` `I loved the acting` `S` `I hated the ending` `S`

B `S` `I hated the ending` `S` `I loved the acting` `S`

O separador de oito palavras mantém no máximo uma opinião em cada janela. Para $k = 3, 4, 5$, A e B contêm as mesmas janelas de IDs, com as mesmas multiplicidades, nas duas tokenizações. O máximo de cada filtro descarta a posição da resposta. Assim, os 300 máximos e os dois logits coincidiram nos seis treinos. Ambas as versões expressam opiniões mistas. Código. Predições.

Teste com um pico por metade

Congelamos embeddings e filtros das três CNNs por palavras. Cada filtro entrega o máximo u da primeira metade e v da segunda. A primeira recebe a janela extra se a contagem for ímpar, e $v = 0$ se a segunda for vazia. A regressão logística recebe 600 valores. Ordenar os dois picos pelo valor descarta a metade de origem. Ao fornecer (u, v), a primeira e a segunda entrada de cada par indicam as metades. Ajustamos a regressão em 6.144 resenhas e escolhemos C por CE em 1.536 de validação. Código e grade de C.

Saída por filtro	Auditoria	Pares sintéticos	Pares editados
Máximo, cabeça original	82,00%	40,23%	40,21%
Máximo, cabeça reajustada	81,90%	39,19%	40,02%
Dois picos por valor	82,28%	39,32%	39,83%
Dois picos por posição	82,29%	39,97%	39,15%

Tabela 8. Média de três sementes. A auditoria mede acurácia por texto em 2.048 resenhas. Nas outras colunas, o par conta como acerto se as duas versões forem classificadas corretamente.

Os 256 pares sintéticos cruzam quatro moldes e dois conjuntos de oito adjetivos. Dos 488 pares editados do IMDb Contrast Set [6], excluímos 144 com entrada de IDs já vista no treino ou na validação. Oito dos 344 pares restantes ficam idênticos após o recorte, com rótulos opostos. No controle, a ordem das metades produziu margens diferentes para A e B nas três sementes, com a mesma classe. Nos pares editados, o acerto foi 39,15%, ante 39,83% com os picos ordenados pelo valor. Nos moldes sintéticos com veredito no fim, todas as cabeças acertaram 0 de 128 pares por semente. Métricas e margens por semente.

Conclusão

O TF-IDF com regressão logística foi um baseline forte no teste oficial, com 90,14% de acurácia, ante 86,78% da CNN e 90,94% do BERT. A CNN respondeu à troca de adjetivos, e o controle com janelas iguais mostrou que o máximo global perde a posição das respostas. Guardar a metade de origem distinguiu os escores do controle, com acerto semelhante nos pares editados. No treino de ponta a ponta, os seis tipos de pooling acertaram 0 de 128 pares com veredito no fim em cada semente. Resultados do ensaio.

Referências

[1] Maas, A. L. et al. *Learning Word Vectors for Sentiment Analysis*. ACL, 2011. ACL Anthology.
[2] Kim, Y. *Convolutional Neural Networks for Sentence Classification*. EMNLP, 2014. ACL Anthology.
[3] Sennrich, R., Haddow, B. e Birch, A. *Neural Machine Translation of Rare Words with Subword Units*. ACL, 2016. ACL Anthology.
[4] Prince, S. J. D. *Understanding Deep Learning*. MIT Press, 2023. Caps. 6, 8, 9 e 10. Livro e materiais.
[5] Devlin, J. et al. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. NAACL, 2019. ACL Anthology.
[6] Gardner, M. et al. *Evaluating Models' Local Decision Boundaries via Contrast Sets*. Findings of EMNLP, 2020. ACL Anthology.
[7] Kotzias, D. et al. *From Group to Individual Labels Using Deep Features*. KDD, 2015. Artigo. Coleção UCI.
[8] Yang, A. et al. *Qwen3 Technical Report*, 2025. arXiv.