MAE5920 · INTRODUÇÃO A DEEP LEARNING

O que a CNN lê em uma resenha?

Sentimento e tokenização no IMDb

Nestor, Letícia e Gabriel



CLASSIFICAÇÃO DE SENTIMENTO

15 MINUTOS

Mesmas palavras. Outra conclusão.

FRASE A

I thought this movie was **terrible**, but it was **wonderful**.

FRASE B

I thought this movie was **wonderful**, but it was **terrible**.

A CNN acompanha a troca?

As duas frases têm as mesmas palavras. Mudamos a posição de *terrible* e *wonderful*. Como o baseline lê a ordem.

As resenhas do IMDb e suas divisões

	Treinar Pesos e vocabulário	**Escolher** Taxa e época	**Calibrar** Temperatura	**Medir** Avaliação final
Original	19.823	2.478	2.478	**25.000** Teste oficial
Extensões	6.144	1.536	—	**2.048** Auditoria interna

COMPRIMENTO DOS TEXTOS INTEIROS, EM PALAVRAS

	Média	Mediana	P90
Resenha no treino	231,1	173	451
Resenha no teste	226,2	170	439
Frase no teste*	18,1	16	33

*Frases estimadas por pontuação. P90 é o valor abaixo do qual ficam cerca de 90% das observações. Distribuições.

Como o BPE divide uma palavra rara

Entrada *The **pallbearer** scene was unexpectedly moving.*

Nas duas versões, a mesma regex normaliza e separa as palavras.

CARACTERES DE PARTIDA

`p a l l b e a r e r</w>`

PRIMEIRA FUSÃO

`p a l l b e a re r</w>`

APÓS SETE FUSÕES

`p all bearer</w>`

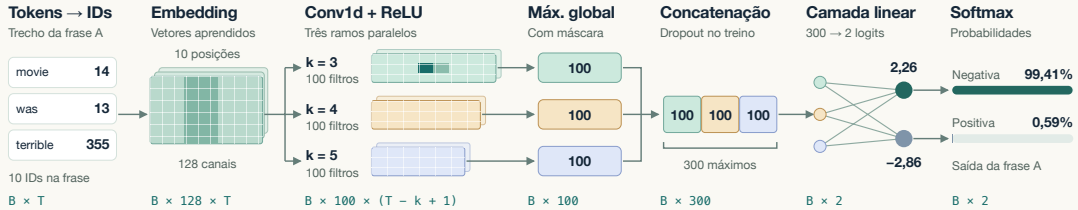
CNN POR PALAVRAS

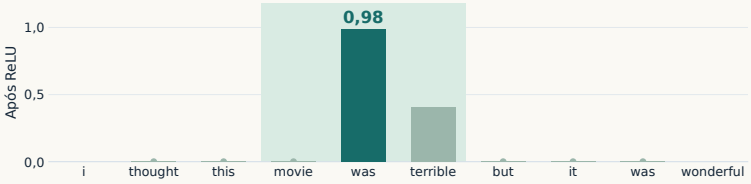
`<unk>`

pallbearer ficou fora do vocabulário.

O BPE recebe a palavra escrita e aplica fusões aprendidas no treino. Treinos separados, 20.000 IDs por vocabulário. `</w>` marca o fim da palavra. Abrir animação.

Arquitetura da TextCNN





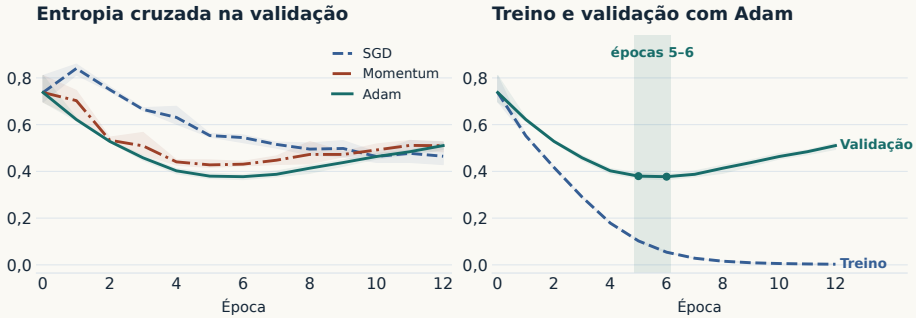
MÁXIMO DO FILTRO 89

0,98 → 0,40

O passo 2 pula a janela com o maior pico.

Frase A, semente 17. Montagem com código. Varredura.

Quando guardar os pesos?



No Adam, guardamos os pesos das épocas 5 ou 6.

Taxas escolhidas na validação: SGD 0,3 · SGD com momentum 0,1 · Adam 0,001.
CNN interna: 128 palavras, lote 64, 12 épocas. Faixas de mínimo e máximo em três sementes. Como ler as curvas.

Da resenha à previsão com TF-IDF

FRASE DE EXEMPLO

Movie was awful.

1. Contar termos

Três palavras e dois pares consecutivos. Cada termo aparece uma vez.

2. Ponderar cada termo

TF vale 1 aqui. O IDF reflete em quantas resenhas de treino aparece. Multiplicamos e dividimos todos os produtos pela mesma norma L2.

`awful` $1 \times 3{,}845 \div 8{,}525 \simeq 0{,}451$

3. Pesar, somar e aplicar a sigmoide

Termo	TF-IDF	Peso	Produto
`movie`	0,175	-1,542	-0,269
`was`	0,168	-3,724	-0,627
`awful`	0,451	-10,744	-4,846
`movie was`	0,418	-0,678	-0,284
`was awful`	0,750	-1,982	-1,487
Viés			+0,211

-7,302 → 0,067% de positivo Classe negativa

Frase ilustrativa. Valores do modelo treinado, arredondados. Probabilidade bruta. Conta completa. Versão interativa.

Por que o modelo ajusta até rótulos embaralhados?

MESMAS 19.823 RESENHAS DE TREINO, MESMOS 80.000 ATRIBUTOS

ACURÁCIA	RÓTULOS REAIS	RÓTULOS EMBARALHADOS
Treino rótulos do ajuste	**99,72%**	**99,75%**
Validação rótulos reais	**91,53%**	**50,08%**

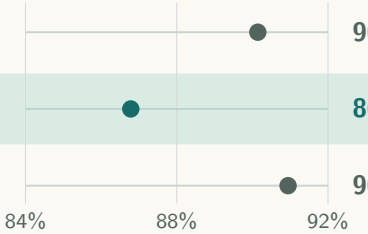
Com milhares de pesos, a regressão ajusta combinações de termos que distinguem as resenhas de treino. Com rótulos embaralhados, fica perto do acaso em textos novos.

Embaralhamos só os rótulos do treino. Regressão logística com L2 e $C = 8$ nas duas colunas. Controle.

A CNN ficou atrás no teste oficial

ESTUDO ORIGINAL · MESMAS 25.000 RESENHAS DO TESTE

MODELO E ENTRADA	ACURÁCIA	F1 MACRO	CE CAL.
TF-IDF + logística **Resenha inteira** L2, $C = 8$	90,14%	0,9014	0,2396
CNN **400 tokens por regex** 0,001 · lote 64 · 5 épocas	86,78%	0,8678	0,3037
BERT **192 WordPieces** 0,00002 · lote 32 · 2 épocas	90,94%	0,9094	0,2278



Controle de recorte do TF-IDF. Reajuste com texto inteiro **90,15%**. Com os primeiros 400 tokens por regex **89,66%**.

AdamW nas redes. 192 tokens com especiais. Hiperparâmetros. Métricas. Controle. Computação.

Desempenho por comprimento da resenha

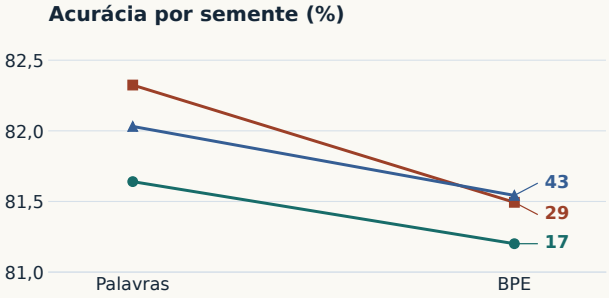
TESTE OFICIAL · ACURÁCIA / F1 MACRO EM %

Palavras na resenha	*n*	TF-IDF	CNN	BERT (192 WordPieces)
Até 100	3.246	90,7 / 90,7	87,3 / 87,2	93,1 / 93,0
101 a 250	14.624	90,2 / 90,2	87,4 / 87,4	93,0 / 93,0
251 a 500	5.285	89,7 / 89,7	86,5 / 86,4	86,9 / 86,9
Acima de 500	1.845	90,2 / 90,2	81,5 / 81,5	82,6 / 82,5

Acima de 500 palavras, com os mesmos pesos.
CNN com texto inteiro **81,52%** → **86,18%** de acurácia.
BERT com 512 tokens **82,46%** → **89,69%** de F1 macro.

O BERT ainda recebe um prefixo. Gráfico interativo. Controle do BERT.

BPE elimina os desconhecidos na auditoria



TOKENS DESCONHECIDOS

3,27% → 0%

TOKENS POR ENTRADA, EM MÉDIA

121,3 → 129,1

ACURÁCIA MÉDIA

82,00% → 81,41%

A mesma janela em tokens pode cobrir menos palavras com BPE.

Regex por palavras → BPE. Até 128 palavras, teto de 256 tokens. Mesma CNN e Adam a 0,001. Três sementes, 2.048 entradas de auditoria. Resultados.

Dois adjetivos trocam de lugar

FRASE A

I thought this movie was **terrible**,
but it was **wonderful**.
Leitura esperada **positiva**

Os seis treinos previram negativa.
CNN palavras **1,0%** CNN BPE **1,2%**

FRASE B

I thought this movie was **wonderful**,
but it was **terrible**.
Leitura esperada **negativa**

Os seis treinos previram positiva.
CNN palavras **89,9%** CNN BPE **83,7%**

Dois tokenizadores $\times$ três treinos cada $=$ seis treinos.

Escores positivos médios, sementes 17, 29 e 43 em cada tokenizador. Abrir animação. Resultados por semente.

O máximo global descarta a posição

A	Separador	I loved the acting.	Separador	I hated the ending.	Separador
B	Separador	I hated the ending.	Separador	I loved the acting.	Separador

Textos de controle A mesma frase nos três separadores *I have a few thoughts about this movie.*

JANELA COM MAIOR RESPOSTA	TOKEN INICIAL EM A E B	MÁXIMO EM A E B
`movie i loved`	8 → 20	0,47 = 0,47

Os separadores preservam as janelas de 3, 4 e 5 tokens na troca.

Os 300 máximos coincidem, e a CNN dá os mesmos escores.

Filtro 61 de largura 3, CNN por palavras, semente 17. Abrir animação. Resultados. Código.

Guardar a posição ajudou a classificar?

Para o mesmo filtro do slide anterior, guardamos o pico de cada metade.

Picos ordenados pelo valor

Texto	Pico menor	Pico maior
A	0,25	**0,47**
B	0,25	**0,47**

Picos na ordem do texto

Texto	1ª metade	2ª metade
A	**0,47**	0,25
B	0,25	**0,47**

No controle, a ordem das metades separou os escores de A e B. As classes coincidiram.

TESTE SEPARADO · 344 PARES DE RESENHAS

39,8% picos por valor **39,1%** picos por metade

Um acerto exige classificar corretamente a resenha original e a edição.

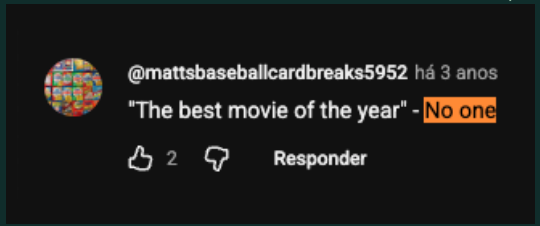
Cada regressão recebe 600 valores. Ajustamos a camada final com os filtros fixos. Código.

▷ YouTube Os modelos recebem só o comentário.

CNN e Qwen leem o YouTube

The Room

Trailer ↗



CNN **Positiva 6/6**

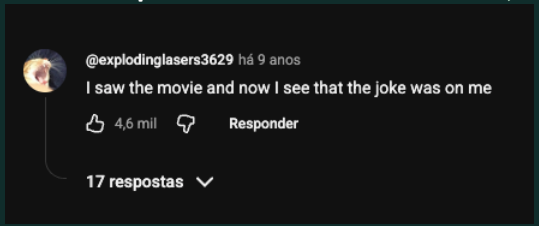
Qwen3-8B

Sem raciocínio	Com raciocínio
Positiva 3/3	Positiva 3/3

"No one" transforma o elogio em crítica.

Suicide Squad

Trailer ↗



CNN **5 pos. / 1 neg.**

Qwen3-8B

Sem raciocínio	Com raciocínio
Negativa 3/3	Negativa 3/3

"The joke was on me" sugere frustração e ecoa a música do trailer.

Seis CNNs. Três gerações do Qwen por modo. Dois casos sem rótulo de referência. CNN · Qwen · Código.

EXTENSÃO

Quanto custa treinar e adaptar?

IMDB · ESTUDO ORIGINAL

Modelo	Dispositivo	Épocas	Ajuste (s)
TF-IDF	M1 CPU	—	13,1
CNN	M1 GPU	5	139,6
BERT	GB10 GPU	2	446,4

O TF-IDF levou cerca de um décimo do tempo da CNN no mesmo Mac. O BERT rodou na DGX Spark.

BERT · AUDITORIA INTERNA NA GB10

O que aprende	Ajuste (s)	Acurácia
Só a camada linear	17,6	84,52%
Encoder e camada linear	148,9	88,31%

Mesmos 2.048 prefixos, três sementes. O tempo da cabeça inclui a extração dos vetores.

Pré-treino publicado. O BERT-base aprendeu com livros e Wikipédia, prevendo tokens mascarados e identificando trechos consecutivos. Foram quatro dias em 16 chips TPU no artigo. Partimos desses pesos.

Como medimos. Devlin et al.. Ver as duas etapas no HTML.

CONCLUSÃO

Onde a nossa CNN falhou?

86,78% com a CNN. 90,14% com TF-IDF e regressão logística.

Recorte

O texto inteiro recuperou 0,50 ponto no teste, com os mesmos pesos.

Ordem

O máximo global guarda a força do padrão e descarta onde ele apareceu.

Pré-treino

BERT e Qwen superaram o baseline neste teste, com outras receitas.

Perguntas?

FIM DA APRESENTAÇÃO

APOIO

O fim da resenha ficou fora do recorte

IMDB · TESTE OFICIAL **Rótulo negativo** 780 tokens pela contagem da CNN.

DENTRO DO RECORTE · 230–239

"This film is as crassly manipulative as it is vapid . . . "

DEPOIS DO TOKEN 400 · 716–724

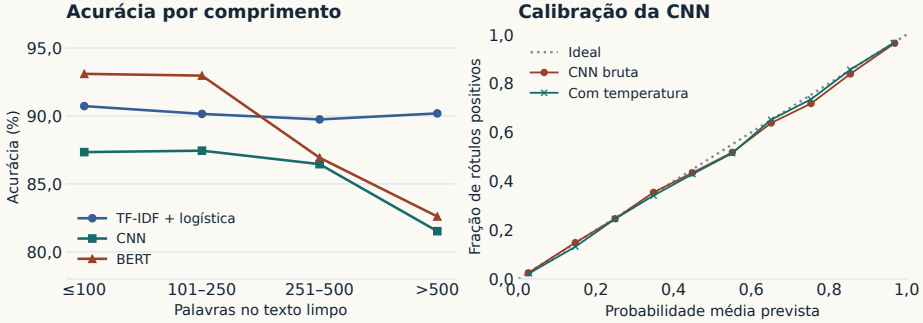
"I had to leave because it was so bad."

ESCORE POSITIVO	TF-IDF	CNN
Primeiros 400 tokens	**71,7%**	**94,7%**
Texto inteiro	**6,5%**	**12,1%**

A CNN usou 400 tokens no teste original. O TF-IDF leu a resenha inteira. Os dois acertaram quando receberam o texto inteiro com os mesmos pesos.

No teste oficial, 3.118 resenhas passaram de 400 tokens. Trechos, escores e comparação.

Confiança e acurácia respondem perguntas diferentes



A temperatura mudou a perda da CNN de **0,3040** para **0,3037**. A classe prevista ficou igual.

Teste oficial. Comprimento e calibração.

O mesmo enredo com três intervenções

Em *Signal 2040*, Bela encontra um teatro vazio e tenta montar uma apresentação com Evan.

-2	*The film's direction lacks coherence and the pacing feels disjointed.*
0	*The film's storytelling is engaging with a steady pace.*
$+2$	*The film offers a thoughtful blend of gentle storytelling and warm performances.*

Somamos αsv à ativação do bloco 28 durante a geração de `REVIEW`. O enredo e o prompt são os mesmos.

Qwen3-8B. Saídas integrais. Direção e controles.

Quanto da frase cada filtro vê?

LARGURAS TREINADAS

k tokens por janela		ACURÁCIA
3	100 filtros	**81,27%**
5	100 filtros	**80,94%**
3/4/5	300 filtros	**81,95%**

PASSOS COM PESOS CONGELADOS

s tokens a cada avanço		ACURÁCIA
1	100,0% das janelas	**82,00%**
2	50,2% das janelas	**81,45%**
3	33,6% das janelas	**80,97%**

Na frase A O filtro 89 cai de 0,98 para 0,40 ao usar passo 2.

Acurácias médias de três sementes em duas auditorias de 2.048 resenhas. Protocolos e métricas.