MAE5920 · INTRODUÇÃO A DEEP LEARNING

O que a CNN lê em uma resenha?

Sentimento e tokenização no IMDb

Nestor, Letícia e Gabriel



SEMINÁRIO

15 MINUTOS

O contraste na resenha

A *I thought this movie was* ***terrible****, but it was* ***wonderful****.*

B *I thought this movie was* ***wonderful****, but it was* ***terrible****.*

Trocamos de lugar só os dois adjetivos. A contagem de cada palavra permanece.

Qual sentimento a CNN atribui a cada frase?

Leitura planejada a partir da oração após *but*. A positiva, B negativa.

Treino, validação e avaliação

Papel	Original	Extensões	Decisão associada
Treino	19.823	6.144	Ajustar vocabulário e pesos
Validação	2.478	1.536	Escolher taxa e época
Calibração	2.478	–	Ajustar temperatura no original
Teste / auditoria	25.000	2.048	Medir a receita escolhida

No estudo sequencial, as redes recebem até 128 palavras e 256 tokens.

O teste oficial e as auditorias internas têm amostras próprias.

IMDb, Maas et al. (2011). Dados e protocolo.

Como o BPE divide uma palavra rara

Entrada *The **pallbearer** scene was unexpectedly moving.*

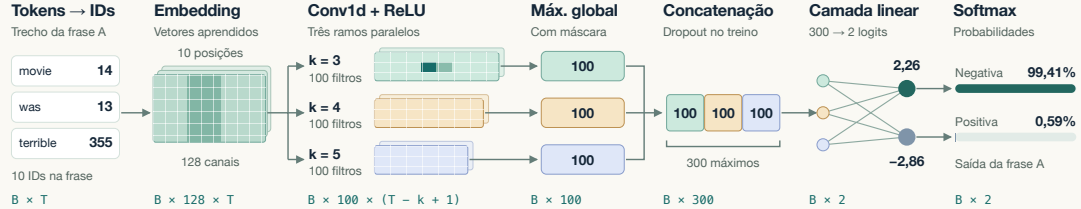
Caracteres	`p a l l b e a r e r</w>`
Fusão 1 de 7	`p a l l b e a re r</w>`
Saída BPE	`p all bearer</w>`

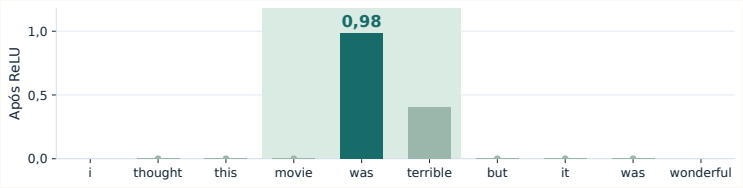
Vocabulário por palavras `pallbearer` recebe `<unk>`.

O BPE aplica pares aprendidos no treino, em ordem de prioridade.

`</w>` marca o fim da palavra. Sennrich et al. (2016). Abrir animação.

Arquitetura da TextCNN





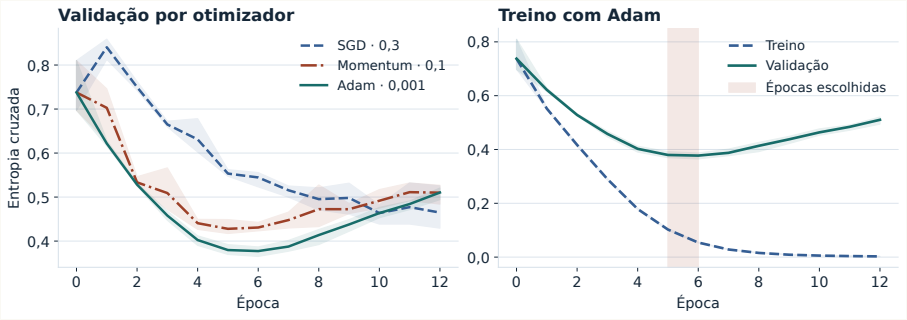
0,98 → 0,40

Máximo do filtro 89 ao mudar o passo de 1 para 2.

Na saída binária, $p_+ = \sigma(z_+ - z_-)$.

Frase A, semente 17. Mapas esquemáticos. Montagem com código. Varredura.

Escolha da taxa e da época



Três taxas por método e 12 épocas. Selecionamos pela menor CE de validação. No Adam, guardamos os pesos das épocas 5 e 6.

Média e mínimo–máximo das sementes 17, 29 e 43. Curvas salvas.

Teste oficial do IMDb

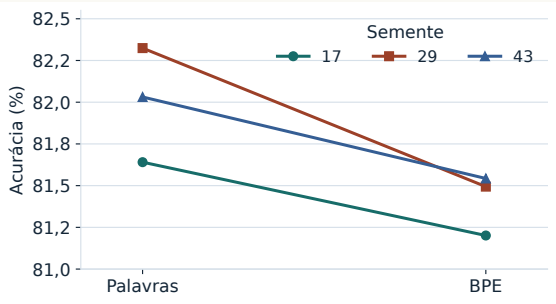
Modelo	Acurácia	F1 macro	CE calibrada
TF-IDF + logística	90,14%	0,9014	0,2396
CNN	86,78%	0,8678	0,3037
BERT	90,94%	0,9094	0,2278

O TF-IDF usa unigramas e bigramas do texto inteiro. A CNN lê até 400 tokens e o BERT até 192 WordPieces.

CNN e TF-IDF deram classes diferentes em 2.590 resenhas.

25.000 resenhas. A temperatura foi ajustada em uma divisão separada. Métricas originais. Casos de discordância.

Auditoria de palavras e BPE



3,27% → 0%
Tokens desconhecidos

82,00% → 81,41%
Acurácia média

As janelas contam tokens. Com subpalavras, podem cobrir menos palavras.

Mesma CNN, três sementes pareadas e Adam a 0,001 nas duas receitas.

Auditoria BPE de 2.048 resenhas. Eixo vertical ampliado. Resultados por semente.

Predições no par de contraste

Fim da resenha	Leitura planejada	CNN palavras	CNN BPE
A. *but it was wonderful*	Positiva	Neg. (1,0%)	Neg. (1,2%)
B. *but it was terrible*	Negativa	Pos. (89,9%)	Pos. (83,7%)

As seis CNNs mudaram de classe na direção oposta à leitura planejada.

No par com negação, houve troca de classe em duas sementes por palavras e em uma semente com BPE.

Escore positivo médio entre parênteses, com três sementes por tokenizer. Resultados dos quatro pares.

Limite do máximo global

S = I have a few thoughts about this movie.

A *S I loved the acting. S I hated the ending. S*

B *S I hated the ending. S I loved the acting. S*

O separador preserva as janelas de 3, 4 e 5 tokens quando os dois blocos trocam de lugar. Cada filtro continua vendo as mesmas janelas e retorna o mesmo máximo.

Diferença máxima de logit igual a zero nos seis checkpoints.

Controle sintético com igualdade verificada nas duas tokenizações.

Resultados e limites da CNN

A camada final recebe 300 máximos de respostas locais.

Tokenização
Palavras ou subpalavras definem o que cabe em cada janela.

Convolução
A ordem dentro da janela pode mudar a resposta de um filtro.

Pooling
O máximo guarda a resposta mais forte e descarta sua posição.

Código, notebook, relatórios e evidências.

EXTENSÃO

Ironia e sentimento em comentários do YouTube

Comentário	CNN palavras	CNN BPE
Friday *AI could never do this*	Neg. (42,0%)	Neg. (39,5%)
The Room *The trailer makes more sense than the actual film*	Pos. (67,4%)	Neg. (45,5%)
The Room *"The best movie of the year" - No one*	Pos. (80,6%)	Pos. (76,0%)

“No one” contesta o elogio entre aspas. Os seis checkpoints deram classe positiva.

Escore positivo entre parênteses, semente 17. Casos sem rótulo de referência. Cinco comentários e todas as sementes.

Encoders e geração de texto

Encoder	Cabeça treinada	Ajuste completo
BERT-base	84,52%	88,31%
DistilBERT	83,35%	86,80%
ModernBERT-base	81,30%	91,24%

Os encoders geram vetores contextuais. Uma média mascarada alimenta a cabeça linear. No ajuste completo, gradientes também chegam ao encoder.

Qwen3-8B. No ensaio de geração, o modelo escreve uma avaliação token a token. Comparamos o texto após alterar suas ativações.

Tabela com acurácia média, três sementes e 2.048 resenhas na auditoria sequencial. Encoders. Geração com o Qwen.

Quando CNN e TF-IDF discordam

1.715 Só TF-IDF acertou

875 Só CNN acertou

Resenha negativa de 780 tokens

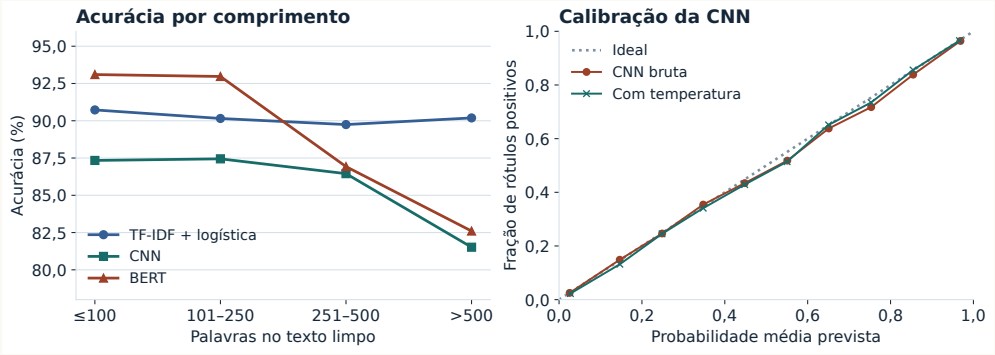
Entrada	TF-IDF	CNN
Primeiros 400 tokens	71,7%	94,7%
Texto inteiro	6,5%	12,1%

Resenha positiva de 61 tokens

A janela *part is brilliant* favorece a classe positiva da CNN. CNN 96,6% e TF-IDF 45,5%.

Escores positivos. Os dois casos usam os mesmos pesos da avaliação original. Contribuições e limites da comparação.

Comprimento e calibração



Na CNN, a CE do teste foi de 0,3040 para 0,3037 com temperatura. O limiar de classificação permaneceu em 0,5.

Apoio. Teste oficial. Comprimento e calibração.

Geração com o Qwen3-8B

Em *Signal 2040*, Bela encontra um teatro vazio e tenta organizar uma apresentação com Evan. O prompt e o resumo `FACT` ficaram iguais.

α	Opinião gerada em `REVIEW`
-2	*The film's direction lacks coherence and the pacing feels disjointed.*
0	*The film's storytelling is engaging with a steady pace.*
$+2$	*The film offers a thoughtful blend of gentle storytelling and warm performances.*

No bloco 28, somamos αsv à ativação depois do marcador `REVIEW`. Com $\alpha = 0$, a geração segue sem intervenção.

Apoio. Primeiro enredo sintético de teste. Saídas integrais. Direção e controles.

Largura e passo da janela

Larguras treinadas

k	Filtros	Acurácia
3	100	81,27%
5	100	80,94%
3/4/5	300	81,95%

k indica quantos tokens entram na janela.

Passos com pesos congelados

s	Janelas retidas	Acurácia
1	100,0%	82,00%
2	50,2%	81,45%
3	33,6%	80,97%

s indica quantos tokens a janela avança.

Na frase A, o filtro 89 passa de 0,98 para 0,40 ao pular janelas com passo 2.

Médias de três sementes em duas auditorias de 2.048 resenhas. Protocolos e métricas.