MAE5920 · INTRODUÇÃO A DEEP LEARNING

O que a CNN lê em uma resenha?

Sentimento e tokenização no IMDb

Nestor, Letícia e Gabriel



CLASSIFICAÇÃO DE SENTIMENTO

15 MINUTOS

Mesmas palavras. Outra conclusão.

FRASE A

I thought this movie was **terrible**, but it was **wonderful**.

FRASE B

I thought this movie was **wonderful**, but it was **terrible**.

A CNN acompanha a troca?

As duas frases têm as mesmas palavras. Mudamos a posição de *terrible* e *wonderful*. Como o baseline lê a ordem.

O que cada divisão decide

	Treinar Pesos e vocabulário	Escolher Taxa e época	Calibrar Temperatura	Medir Avaliação final
Original	19.823	2.478	2.478	**25.000** Teste oficial
Extensões	6.144	1.536	—	**2.048** Auditoria interna

A CNN original usa até 400 tokens. Nos ensaios internos, as primeiras 128 palavras formam o prefixo comum. O teto adicional de 256 tokens não cortou esses prefixos.

IMDb, Maas et al. (2011). Dados e protocolo das extensões.

Como o BPE divide uma palavra rara

Entrada *The **pallbearer** scene was unexpectedly moving.*

CARACTERES DE PARTIDA

`p a l l b e a r e r</w>`

PRIMEIRA FUSÃO

`p a l l b e a re r</w>`

APÓS SETE FUSÕES

`p all bearer</w>`

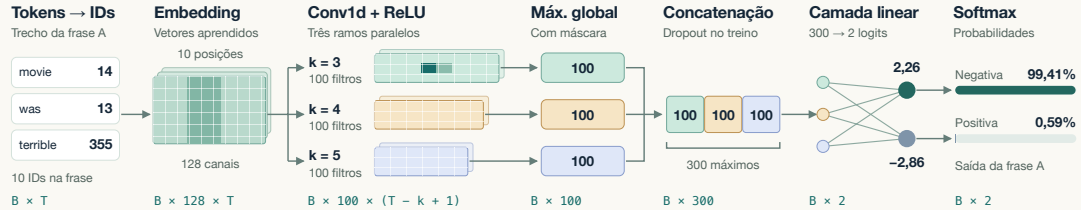
POR PALAVRAS

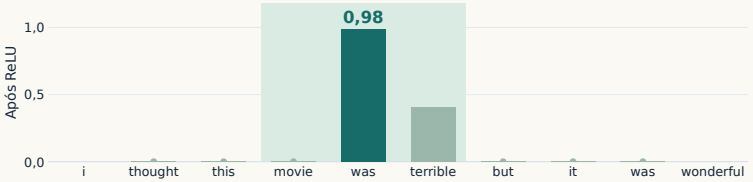
`<unk>`

pallbearer ficou fora do vocabulário.

Escolhemos 20.000 entradas em ambos para igualar a tabela de embeddings. `</w>` marca o fim da palavra. Sennrich et al. (2016). Abrir animação.

Arquitetura da TextCNN





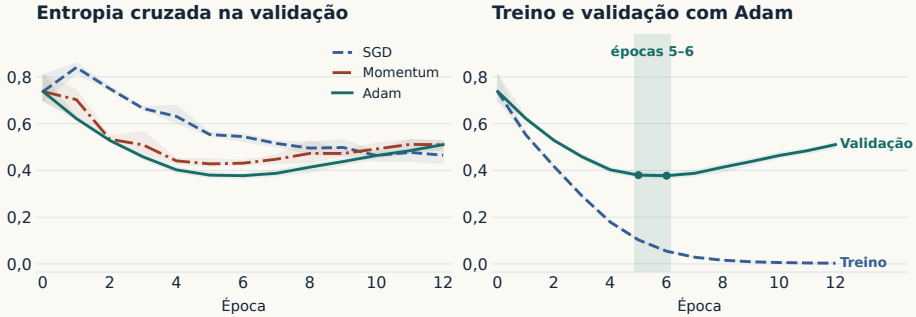
MÁXIMO DO FILTRO 89

0,98 → 0,40

O passo 2 pula a janela com o maior pico.

Frase A, semente 17. Mapas esquemáticos. Montagem com código. Varredura.

Quando guardar os pesos?



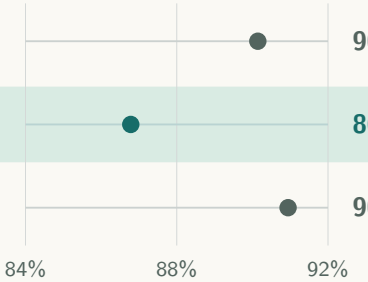
No Adam, guardamos os pesos das épocas 5 ou 6.

CNN interna: dropout 0,5 e decaimento de pesos zero. Na original, AdamW usa decaimento de 0,01. Faixas de três sementes. Curvas.

A CNN ficou atrás no teste oficial

25.000 RESENHAS · ESTUDO ORIGINAL

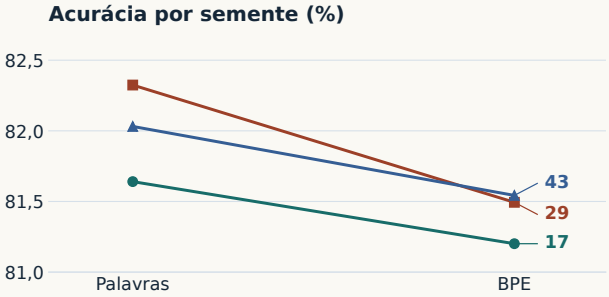
MODELO	ACURÁCIA	F1 MACRO	CE CAL.
TF-IDF + logística	90,14%	0,9014	0,2396
CNN	**86,78%**	0,8678	0,3037
BERT	90,94%	0,9094	0,2278



TF-IDF lê o texto inteiro. CNN lê até 400 tokens. BERT lê até 192 WordPieces.

Lotes de treino: CNN 64, BERT 32. A CE usa probabilidades calibradas. Métricas. Entenda o TF-IDF.

BPE cobriu mais do vocabulário



TOKENS DESCONHECIDOS

3,27% → 0%

ACURÁCIA MÉDIA

82,00% → 81,41%

A mesma largura em tokens pode cobrir menos palavras quando usamos BPE.

2.048 resenhas na auditoria BPE. Cada linha liga a mesma semente nas duas receitas. Mesma CNN e Adam a 0,001. Resultados.

Dois adjetivos trocam de lugar

FRASE A

I thought this movie was **terrible**,
but it was **wonderful**.
Leitura esperada **positiva**

Os seis treinos previram negativa.
CNN palavras **1,0%** CNN BPE **1,2%**

FRASE B

I thought this movie was **wonderful**,
but it was **terrible**.
Leitura esperada **negativa**

Os seis treinos previram positiva.
CNN palavras **89,9%** CNN BPE **83,7%**

Dois tokenizadores $\times$ três treinos cada $=$ seis treinos.

Escores positivos médios, sementes 17, 29 e 43 em cada tokenizador. Abrir animação. Resultados por semente.

O máximo global descarta a posição

A	Separador	I loved the acting.	Separador	I hated the ending.	Separador
B	Separador	I hated the ending.	Separador	I loved the acting.	Separador

Textos de controle A mesma frase nos três separadores *I have a few thoughts about this movie.*

JANELA COM MAIOR RESPOSTA	TOKEN INICIAL EM A E B	MÁXIMO EM A E B
`movie i loved`	$8 \rightarrow 20$	$0{,}47 = 0{,}47$

Os separadores preservam as janelas de 3, 4 e 5 tokens na troca.

Os 300 máximos coincidem, e a CNN dá os mesmos escores.

Filtro 61 de largura 3, CNN por palavras, semente 17. Abrir animação. Resultados. Código.

Guardar a posição ajudou a classificar?

Para o mesmo filtro do slide anterior, guardamos o pico de cada metade.

Picos ordenados pelo valor

Texto	Pico menor	Pico maior
A	0,25	**0,47**
B	0,25	**0,47**

Picos na ordem do texto

Texto	1ª metade	2ª metade
A	**0,47**	0,25
B	0,25	**0,47**

No controle, a ordem das metades separou os escores de A e B. As classes coincidiram.

TESTE SEPARADO · 344 PARES DE RESENHAS

39,8% picos por valor **39,1%** picos por metade

Um acerto exige classificar corretamente a resenha original e a edição.

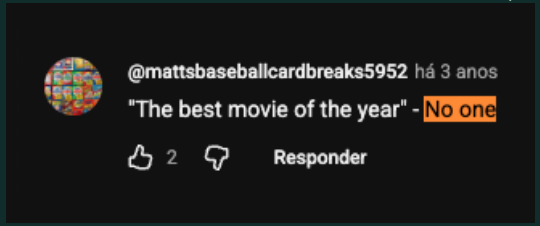
Cada regressão recebe 600 valores. Ajustamos a camada final com os filtros fixos. Código.

▷ YouTube Com raciocínio, o Qwen gera texto antes do rótulo.

CNN e Qwen leem o YouTube

The Room

Trailer ↗



CNN **Positiva** 6/6

Qwen3-8B

Sem raciocínio	Com raciocínio
Positiva 3/3	**Positiva 3/3**

"No one" transforma o elogio em crítica.

Friday

Clipe de Rebecca Black ↗



CNN **Negativa** 6/6

Qwen3-8B

Sem raciocínio	Com raciocínio
Negativa 3/3	**Negativa 3/3**

A frase admite admiração ou ironia.

Só texto. Três gerações do Qwen por modo. Dois casos qualitativos. CNN · Qwen · Código.

EXTENSÃO

Encoders em uma auditoria interna

ACURÁCIA MÉDIA EM 2.048 PREFIXOS DE 128 PALAVRAS

	SÓ A CABEÇA		AJUSTE COMPLETO
BERT-base	84,52%	⟶	**88,31%**
DistilBERT	83,35%	⟶	**86,80%**
ModernBERT-base	81,30%	⟶	**91,24%**

Na primeira coluna, só a cabeça aprende. Na segunda, ajustamos também o encoder. O BERT do slide 7 foi avaliado no teste oficial.

Qwen3-8B 95,26% no teste oficial, com pesos congelados e prompt.

Três sementes por receita interna. Lotes de treino: cabeça 128, ajuste completo 32. Encoders. Qwen.

CONCLUSÃO

Onde a nossa CNN falhou?

86,78% com a CNN. 90,14% com TF-IDF e regressão logística.

Recorte

O texto inteiro recuperou 0,50 ponto no teste, com os mesmos pesos.

Ordem

O máximo global guarda a força do padrão e descarta onde ele apareceu.

Pré-treino

BERT e Qwen superaram o baseline neste teste, com outras receitas.

Perguntas?

FIM DA APRESENTAÇÃO

APOIO

O fim da resenha ficou fora do recorte

IMDB · TESTE OFICIAL **Rótulo negativo** 780 tokens pela contagem da CNN.

DENTRO DO RECORTE · 230–239

"This film is as crassly manipulative as it is vapid . . . "

DEPOIS DO TOKEN 400 · 716–724

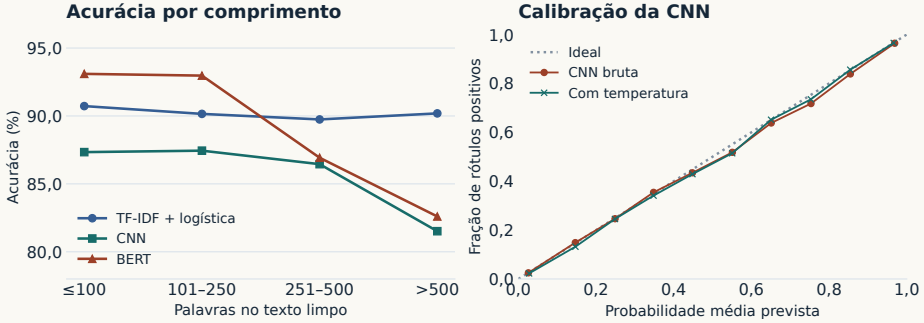
"I had to leave because it was so bad."

ESCORE POSITIVO	TF-IDF	CNN
Primeiros 400 tokens	**71,7%**	**94,7%**
Texto inteiro	**6,5%**	**12,1%**

A CNN usou 400 tokens no teste original. O TF-IDF leu a resenha inteira. Os dois acertaram quando receberam o texto inteiro com os mesmos pesos.

No teste oficial, 3.118 resenhas passaram de 400 tokens. Trechos, escores e comparação.

Confiança e acurácia respondem perguntas diferentes



A temperatura mudou a perda da CNN de **0,3040** para **0,3037**. A classe prevista ficou igual.

Teste oficial. Comprimento e calibração.

O mesmo enredo com três intervenções

Em *Signal 2040*, Bela encontra um teatro vazio e tenta montar uma apresentação com Evan.

-2	*The film's direction lacks coherence and the pacing feels disjointed.*
0	*The film's storytelling is engaging with a steady pace.*
$+2$	*The film offers a thoughtful blend of gentle storytelling and warm performances.*

Somamos αsv à ativação do bloco 28 durante a geração de `REVIEW`. O enredo e o prompt são os mesmos.

Qwen3-8B. Saídas integrais. Direção e controles.

APOIO

Quanto da frase cada filtro vê?

LARGURAS TREINADAS			PASSOS COM PESOS CONGELADOS		
k tokens por janela		ACURÁCIA	s tokens a cada avanço		ACURÁCIA
3	100 filtros	**81,27%**	**1**	100,0% das janelas	**82,00%**
5	100 filtros	**80,94%**	**2**	50,2% das janelas	**81,45%**
3/4/5	300 filtros	**81,95%**	**3**	33,6% das janelas	**80,97%**

Na frase A O filtro 89 cai de 0,98 para 0,40 ao usar passo 2.

Acurácias médias de três sementes em duas auditorias de 2.048 resenhas. Protocolos e métricas.

APOIO

Como o TF-IDF lê uma resenha

UNIGRAMAS E BIGRAMAS

`not good` ⟶ `not good` `not good`

`good not` ⟶ `not good` `good not`

As palavras são as mesmas. A ordem muda o bigrama. O vetor acumula ocorrências ao longo do texto e descarta a posição.

DA FREQUÊNCIA AO SENTIMENTO

TF-IDF

Dá peso à frequência na resenha e à raridade no treino.

Regressão logística

Aprende um coeficiente para cada termo. Soma as contribuições e aplica a sigmoide para obter $p(+)$.

99,72% no treino → 90,14% no teste 80.000 atributos e penalização L2.

Exemplo ilustrativo de bigramas. O modelo lê a resenha inteira. Implementação.