MAE5920 · INTRODUÇÃO A DEEP LEARNING

O que a CNN lê em uma resenha?

Sentimento e tokenização no IMDb

Nestor, Letícia e Gabriel



CLASSIFICAÇÃO DE SENTIMENTO

15 MINUTOS

Mesmas palavras. Outra conclusão.

FRASE A

I thought this movie was **terrible**, but it was **wonderful**.

FRASE B

I thought this movie was **wonderful**, but it was **terrible**.

A CNN acompanha a troca?

As duas frases têm as mesmas palavras. Mudamos a posição de *terrible* e *wonderful*.

O que cada divisão decide

	Treinar Pesos e vocabulário	**Escolher** Taxa e época	**Calibrar** Temperatura	**Medir** Avaliação final
Original	19.823	2.478	2.478	**25.000** Teste oficial
Extensões	6.144	1.536	—	**2.048** Auditoria interna

Nas extensões, a entrada tem até 128 palavras e 256 tokens.

IMDb, Maas et al. (2011). Dados e protocolo das extensões.

Como o BPE divide uma palavra rara

Entrada *The **pallbearer** scene was unexpectedly moving.*

CARACTERES DE PARTIDA

`p a l l b e a r e r</w>`

PRIMEIRA FUSÃO

`p a l l b e a re r</w>`

APÓS SETE FUSÕES

`p all bearer</w>`

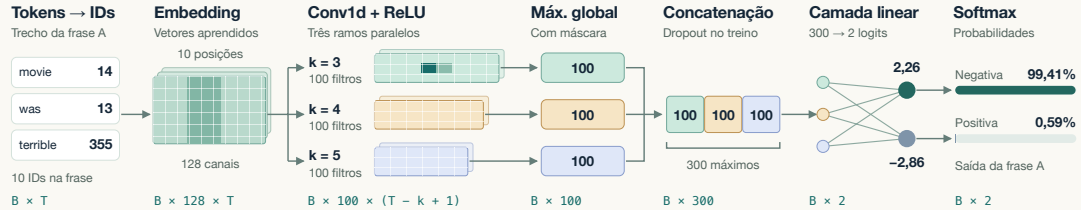
POR PALAVRAS

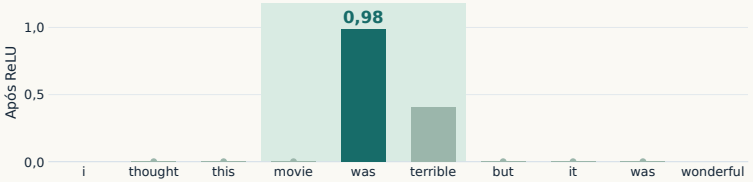
<unk>

pallbearer ficou fora do vocabulário.

O BPE aplica as fusões na ordem aprendida no treino. </w> marca o fim da palavra. Sennrich et al. (2016). Abrir animação.

Arquitetura da TextCNN





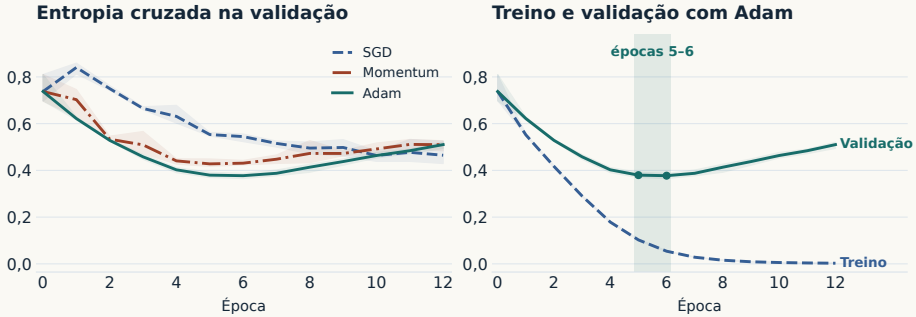
MÁXIMO DO FILTRO 89

0,98 → 0,40

O passo 2 pula a janela com o maior pico.

Frase A, semente 17. Mapas esquemáticos. Montagem com código. Varredura.

Quando guardar os pesos?

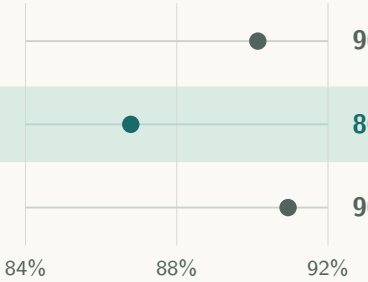


No Adam, guardamos os pesos das épocas 5 ou 6.

Três taxas por método, 12 épocas. Faixas mostram mínimo e máximo de três sementes. Curvas.

A CNN ficou atrás no teste oficial

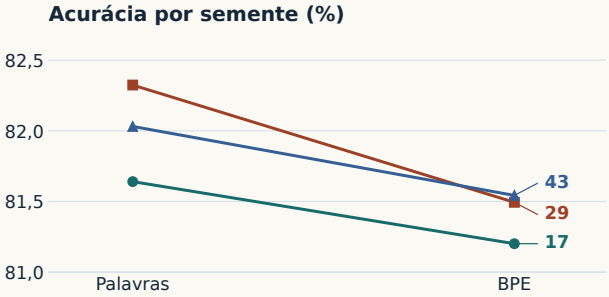
MODELO	ACURÁCIA	F1 MACRO	CE CAL.
TF-IDF + logística	90,14%	0,9014	0,2396
CNN	**86,78%**	0,8678	0,3037
BERT	90,94%	0,9094	0,2278



A CNN e o TF-IDF deram classes diferentes em **2.590 resenhas**.

25.000 resenhas. Temperatura ajustada em uma divisão separada. Métricas. Discordâncias.

BPE cobriu mais do vocabulário



TOKENS DESCONHECIDOS

3,27% → 0%

ACURÁCIA MÉDIA

82,00% → 81,41%

A mesma largura em tokens pode cobrir menos palavras quando usamos BPE.

2.048 resenhas na auditoria BPE. Cada linha liga a mesma semente nas duas receitas. Mesma CNN e Adam a 0,001. Resultados.

Dois adjetivos trocam de lugar

FRASE A

I thought this movie was **terrible**,
but it was **wonderful**.
Leitura esperada **positiva**

Os seis treinos previram negativa.
CNN palavras **1,0%** CNN BPE **1,2%**

FRASE B

I thought this movie was **wonderful**,
but it was **terrible**.
Leitura esperada **negativa**

Os seis treinos previram positiva.
CNN palavras **89,9%** CNN BPE **83,7%**

Dois tokenizadores $\times$ três treinos cada $=$ seis treinos.

Escores positivos médios, sementes 17, 29 e 43 em cada tokenizador. Abrir animação. Resultados por semente.

O pico muda de lugar. O máximo fica.

A Separador **I loved the acting.** Separador **I hated the ending.** Separador

B Separador **I hated the ending.** Separador **I loved the acting.** Separador

Controle sintético Separador de 8 palavras *I have a few thoughts about this movie.*

JANELA COM MAIOR RESPOSTA	TOKEN INICIAL EM A E B	MÁXIMO EM A E B
`movie i loved`	8 → 20	0,47 = 0,47

Os separadores preservam as janelas de 3, 4 e 5 tokens.

Mesmos 300 máximos → mesmos escores finais em A e B.

Filtro 61 de largura 3, CNN por palavras, semente 17. Abrir animação. Controle nos seis treinos.

Guardar a posição ajudou a classificar?

Dividimos as janelas em duas metades e guardamos a maior resposta de cada uma.

EXEMPLO DO SLIDE ANTERIOR · MESMO FILTRO

Sem posição

Texto	Pico menor	Pico maior
A	0,25	**0,47**
B	0,25	**0,47**

Com posição

Texto	1ª metade	2ª metade
A	**0,47**	0,25
B	0,25	**0,47**

TESTE SEPARADO · 344 PARES DE RESENHAS

39,8% sem posição **39,1%** com posição

Cada par tem uma resenha e uma edição humana que inverte o rótulo. Só conta acerto nas duas versões.

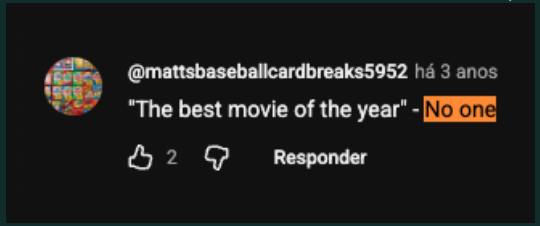
Filtros congelados. Ajustamos só a camada final. 600 entradas por modelo. Protocolo.

▷ YouTube Os dois modelos receberam só o texto de cada comentário.

CNN e Qwen leem o YouTube

The Room

Trailer ↗



CNN **Positiva** 6/6

Qwen3-8B

Sem raciocínio	Com raciocínio
Positiva 3/3	Positiva 3/3

“No one” transforma o elogio em crítica.

Friday

Clipe de Rebecca Black ↗



CNN **Negativa** 6/6

Qwen3-8B

Sem raciocínio	Com raciocínio
Negativa 3/3	Negativa 3/3

A frase admite admiração ou ironia.

CNN com dois tokenizadores e três treinos cada. Qwen gerou três respostas por modo. Casos sem rótulo de referência. CNN · Qwen.

EXTENSÃO

O que muda com vetores contextuais?

ACURÁCIA NA AUDITORIA SEQUENCIAL

	SÓ A CABEÇA		AJUSTE COMPLETO
BERT-base	84,52%	⟶	**88,31%**
DistilBERT	83,35%	⟶	**86,80%**
ModernBERT-base	81,30%	⟶	**91,24%**

Os encoders combinam informações entre tokens antes da média. No ajuste completo, o treino também altera os pesos do encoder.

Qwen3-8B Enredo ⟶ ativação interna ⟶ opinião gerada

2.048 resenhas, três sementes por receita. Encoders. Geração com o Qwen.

CONCLUSÃO

O que chega à decisão da CNN?

A camada final recebe 300 máximos de padrões locais.

Tokenização
BPE zerou os tokens desconhecidos na auditoria. A acurácia ficou próxima.

Teste oficial
A CNN fez 86,78%. TF-IDF e BERT ficaram à frente.

Posição
O máximo descarta onde o filtro respondeu. Preservar a posição mudou escores, com acerto semelhante nos pares humanos.

Perguntas?

FIM DA APRESENTAÇÃO

APOIO

O fim da resenha ficou fora do recorte

IMDB · TESTE OFICIAL **Rótulo negativo** 780 tokens pela contagem da CNN.

DENTRO DO RECORTE · 230–239

"This film is as crassly manipulative as it is vapid . . . "

DEPOIS DO TOKEN 400 · 716–724

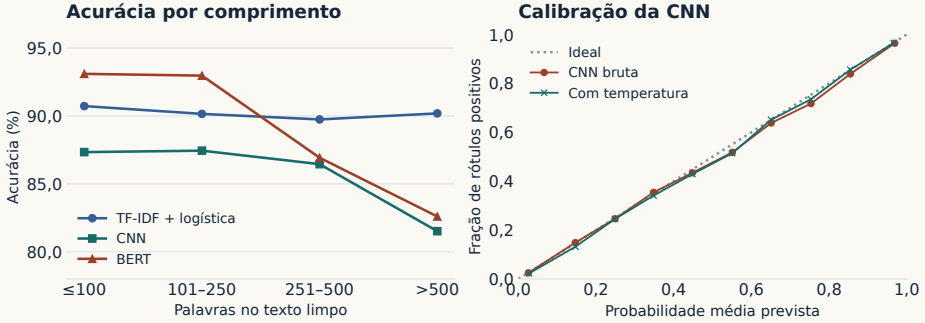
"I had to leave because it was so bad."

ESCORE POSITIVO	TF-IDF	CNN
Primeiros 400 tokens	**71,7%**	**94,7%**
Texto inteiro	**6,5%**	**12,1%**

A CNN usou 400 tokens no teste original. O TF-IDF leu a resenha inteira. Os dois acertaram quando receberam o texto inteiro com os mesmos pesos.

`imdb_test_03531`. Trechos, escores e método.

Confiança e acurácia respondem perguntas diferentes



A temperatura mudou a perda da CNN de **0,3040** para **0,3037**. A classe prevista ficou igual.

Teste oficial. Comprimento e calibração.

O mesmo enredo com três intervenções

Em *Signal 2040*, Bela encontra um teatro vazio e tenta montar uma apresentação com Evan.

-2	*The film's direction lacks coherence and the pacing feels disjointed.*
0	*The film's storytelling is engaging with a steady pace.*
$+2$	*The film offers a thoughtful blend of gentle storytelling and warm performances.*

Somamos αsv à ativação do bloco 28 durante a geração de `REVIEW`. O enredo e o prompt são os mesmos.

Qwen3-8B. Saídas integrais. Direção e controles.

APOIO

Quanto da frase cada filtro vê?

LARGURAS TREINADAS

k tokens por janela		ACURÁCIA
3	100 filtros	**81,27%**
5	100 filtros	**80,94%**
3/4/5	300 filtros	**81,95%**

PASSOS COM PESOS CONGELADOS

s tokens a cada avanço		ACURÁCIA
1	100,0% das janelas	**82,00%**
2	50,2% das janelas	**81,45%**
3	33,6% das janelas	**80,97%**

Na frase A O filtro 89 cai de 0,98 para 0,40 ao usar passo 2.

Acurácias médias de três sementes em duas auditorias de 2.048 resenhas. Protocolos e métricas.