MAE5920 · INTRODUÇÃO A DEEP LEARNING

O que a CNN lê em uma resenha?

Sentimento e tokenização no IMDb

Nestor, Letícia e Gabriel



CLASSIFICAÇÃO DE SENTIMENTO

15 MINUTOS

Mesmas palavras. Outra conclusão.

FRASE A

I thought this movie was **terrible**, but it was **wonderful**.

FRASE B

I thought this movie was **wonderful**, but it was **terrible**.

A CNN acompanha a troca?

As duas frases têm as mesmas palavras. Mudamos a posição de *terrible* e *wonderful*. Como o baseline lê a ordem.

O que cada divisão decide

	Treinar Pesos e vocabulário	**Escolher** Taxa e época	**Calibrar** Temperatura	**Medir** Avaliação final
Original	19.823	2.478	2.478	**25.000** Teste oficial
Extensões	6.144	1.536	—	**2.048** Auditoria interna

A CNN original usa até 400 tokens. Nos ensaios internos, as primeiras 128 palavras formam o prefixo comum. O teto adicional de 256 tokens não cortou esses prefixos.

IMDb, Maas et al. (2011). Dados e protocolo das extensões.

Como o BPE divide uma palavra rara

Entrada *The **pallbearer** scene was unexpectedly moving.*

CARACTERES DE PARTIDA

`p a l l b e a r e r</w>`

PRIMEIRA FUSÃO

`p a l l b e a re r</w>`

APÓS SETE FUSÕES

`p all bearer</w>`

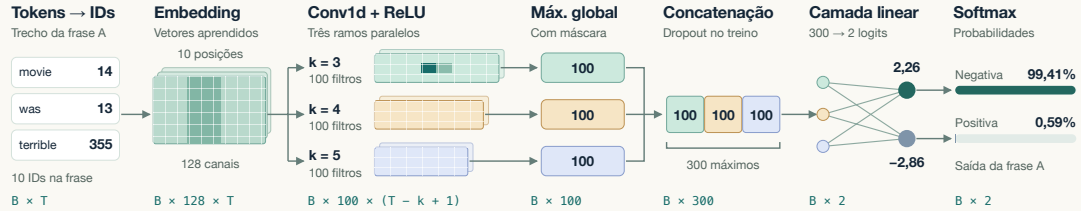
POR PALAVRAS

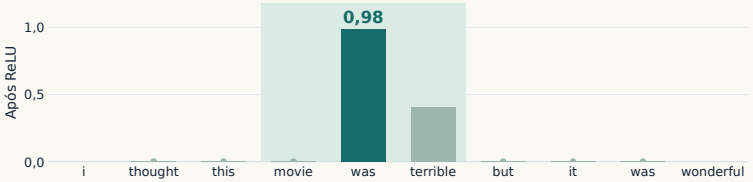
`<unk>`

pallbearer ficou fora do vocabulário.

Escolhemos 20.000 entradas em ambos para igualar a tabela de embeddings. `</w>` marca o fim da palavra. Sennrich et al. (2016). Abrir animação.

Arquitetura da TextCNN





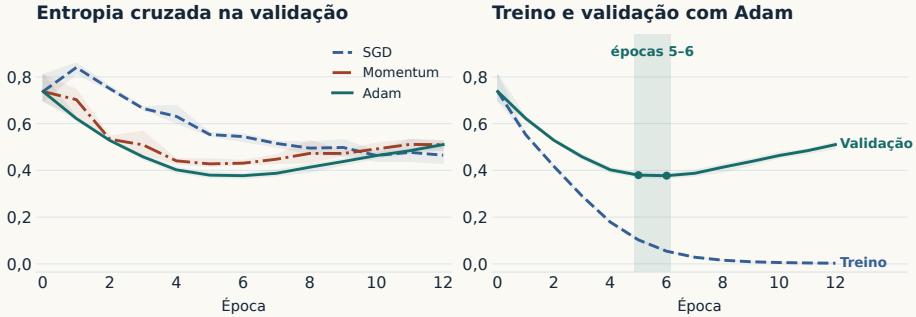
MÁXIMO DO FILTRO 89

0,98 → 0,40

O passo 2 pula a janela com o maior pico.

Frase A, semente 17. Mapas esquemáticos. Montagem com código. Varredura.

Quando guardar os pesos?



No Adam, guardamos os pesos das épocas 5 ou 6.

CNN interna: dropout 0,5 e decaimento de pesos zero. Na original, AdamW usa decaimento de 0,01. Faixas de três sementes. Curvas.

Da resenha à previsão com TF-IDF

1. Contar termos

The movie was awful.

PALAVRAS

`the, movie, was, awful`

PARES CONSECUTIVOS

`the movie`, `movie was`, `was awful`

O par guarda a ordem local. Contamos os termos no texto inteiro.

2. Ponderar (TF-IDF)

TF cresce quando o termo se repete na resenha.

RARIDADE NO TREINO (IDF)

`movie`	9 de 10 → 1,10
`awful`	2 de 10 → 2,30

Ambos ocorrem uma vez. Neste treino fictício, *awful* tem IDF maior.

3. Classificar (logística)

Soma **TF-IDF** × **coeficiente** de cada termo e o viés.

RESENHA REAL

`bad`	−0,40
`awful`	−0,25
`rules`	+0,12
Demais termos e viés	−1,39

−1,91 → **6,5% de positivo**

Valores arredondados. Aplicamos a sigmoide ao escore calibrado. Resenha e escores. Versão interativa.

Por que o modelo ajusta até rótulos embaralhados?

MESMAS 19.823 RESENHAS DE TREINO, MESMOS 80.000 ATRIBUTOS

ACURÁCIA	RÓTULOS REAIS	RÓTULOS EMBARALHADOS
Treino rótulos do ajuste	**99,72%**	**99,75%**
Validação rótulos reais	**91,53%**	**50,08%**

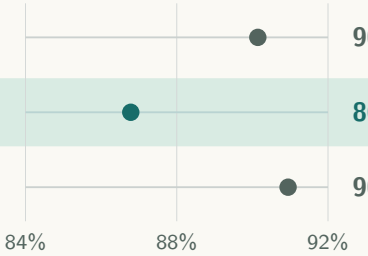
Com milhares de pesos, a regressão ajusta combinações de termos que distinguem as resenhas de treino. Com rótulos embaralhados, fica perto do acaso em textos novos.

Embaralhamos só os rótulos do treino. Regressão logística com L2 e $C = 8$ nas duas colunas. Controle.

A CNN ficou atrás no teste oficial

25.000 RESENHAS · ESTUDO ORIGINAL

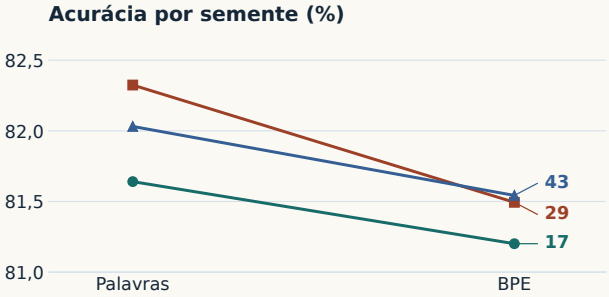
MODELO	ACURÁCIA	F1 MACRO	CE CAL.
TF-IDF + logística	90,14%	0,9014	0,2396
CNN	**86,78%**	0,8678	0,3037
BERT	90,94%	0,9094	0,2278



Com teto de 400 tokens, o TF-IDF reajustado ainda fez **89,66%**.

Entradas originais: texto inteiro no TF-IDF, 400 tokens na CNN e 192 WordPieces no BERT. Lotes: CNN 64, BERT 32. Métricas. Controle de recorte.

BPE cobriu mais do vocabulário



TOKENS DESCONHECIDOS

3,27% → 0%

ACURÁCIA MÉDIA

82,00% → 81,41%

A mesma largura em tokens pode cobrir menos palavras quando usamos BPE.

2.048 resenhas na auditoria BPE. Cada linha liga a mesma semente nas duas receitas. Mesma CNN e Adam a 0,001. Resultados.

Dois adjetivos trocam de lugar

FRASE A

I thought this movie was **terrible**,
but it was **wonderful**.
Leitura esperada **positiva**

Os seis treinos previram negativa.
CNN palavras **1,0%** CNN BPE **1,2%**

FRASE B

I thought this movie was **wonderful**,
but it was **terrible**.
Leitura esperada **negativa**

Os seis treinos previram positiva.
CNN palavras **89,9%** CNN BPE **83,7%**

Dois tokenizadores $\times$ três treinos cada $=$ seis treinos.

Escores positivos médios, sementes 17, 29 e 43 em cada tokenizador. Abrir animação. Resultados por semente.

O máximo global descarta a posição

A	Separador	I loved the acting.	Separador	I hated the ending.	Separador
B	Separador	I hated the ending.	Separador	I loved the acting.	Separador

Textos de controle A mesma frase nos três separadores *I have a few thoughts about this movie.*

JANELA COM MAIOR RESPOSTA	TOKEN INICIAL EM A E B	MÁXIMO EM A E B
`movie i loved`	8 → 20	0,47 = 0,47

Os separadores preservam as janelas de 3, 4 e 5 tokens na troca.

Os 300 máximos coincidem, e a CNN dá os mesmos escores.

Filtro 61 de largura 3, CNN por palavras, semente 17. Abrir animação. Resultados. Código.

Guardar a posição ajudou a classificar?

Para o mesmo filtro do slide anterior, guardamos o pico de cada metade.

Picos ordenados pelo valor

Texto	Pico menor	Pico maior
A	0,25	**0,47**
B	0,25	**0,47**

Picos na ordem do texto

Texto	1ª metade	2ª metade
A	**0,47**	0,25
B	0,25	**0,47**

No controle, a ordem das metades separou os escores de A e B. As classes coincidiram.

TESTE SEPARADO · 344 PARES DE RESENHAS

39,8% picos por valor **39,1%** picos por metade

Um acerto exige classificar corretamente a resenha original e a edição.

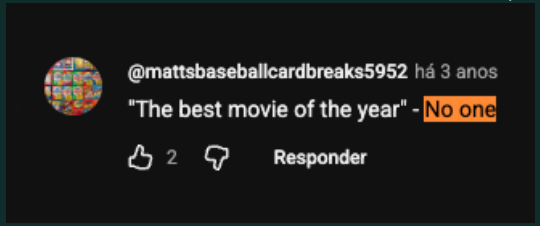
Cada regressão recebe 600 valores. Ajustamos a camada final com os filtros fixos. Código.

▷ YouTube Com raciocínio, o Qwen gera texto antes do rótulo.

CNN e Qwen leem o YouTube

The Room

Trailer ↗



CNN **Positiva** 6/6

Qwen3-8B

Sem raciocínio	Com raciocínio
Positiva 3/3	**Positiva 3/3**

"No one" transforma o elogio em crítica.

Friday

Clipe de Rebecca Black ↗



CNN **Negativa** 6/6

Qwen3-8B

Sem raciocínio	Com raciocínio
Negativa 3/3	**Negativa 3/3**

A frase admite admiração ou ironia.

Só texto. Três gerações do Qwen por modo. Dois casos qualitativos. CNN · Qwen · Código.

EXTENSÃO

Encoders em uma auditoria interna

ACURÁCIA MÉDIA EM 2.048 PREFIXOS DE ATÉ 128 PALAVRAS

	SÓ A CABEÇA		AJUSTE COMPLETO
BERT-base	84,52%	$\longrightarrow$	**88,31%**
DistilBERT	83,35%	$\longrightarrow$	**86,80%**
ModernBERT-base	81,30%	$\longrightarrow$	**91,24%**

Na primeira coluna, só a cabeça aprende. Na segunda, ajustamos também o encoder. O BERT do slide 9 foi avaliado no teste oficial.

Qwen3-8B 95,26% no teste oficial, com pesos congelados e prompt.

Três sementes por receita interna. Lotes de 128 para a cabeça e 32 para o ajuste completo. Encoders. Qwen.

CONCLUSÃO

Onde a nossa CNN falhou?

86,78% com a CNN. 90,14% com TF-IDF e regressão logística.

Recorte

O texto inteiro recuperou 0,50 ponto no teste, com os mesmos pesos.

Ordem

O máximo global guarda a força do padrão e descarta onde ele apareceu.

Pré-treino

BERT e Qwen superaram o baseline neste teste, com outras receitas.

Perguntas?

FIM DA APRESENTAÇÃO

APOIO

O fim da resenha ficou fora do recorte

IMDB · TESTE OFICIAL **Rótulo negativo** 780 tokens pela contagem da CNN.

DENTRO DO RECORTE · 230–239

"This film is as crassly manipulative as it is vapid . . . "

DEPOIS DO TOKEN 400 · 716–724

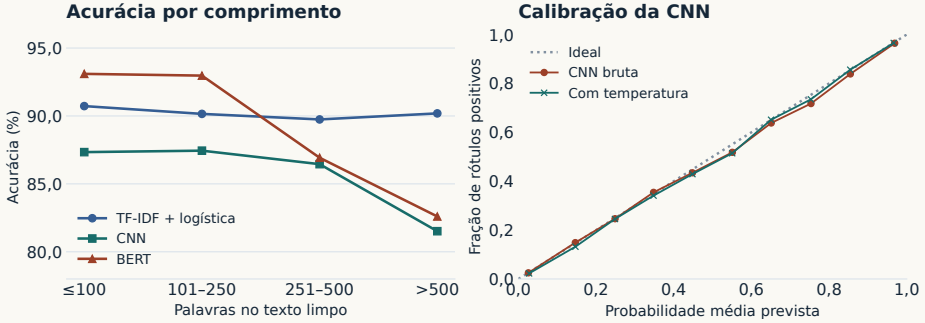
"I had to leave because it was so bad."

ESCORE POSITIVO	TF-IDF	CNN
Primeiros 400 tokens	**71,7%**	**94,7%**
Texto inteiro	**6,5%**	**12,1%**

A CNN usou 400 tokens no teste original. O TF-IDF leu a resenha inteira. Os dois acertaram quando receberam o texto inteiro com os mesmos pesos.

No teste oficial, 3.118 resenhas passaram de 400 tokens. Trechos, escores e comparação.

Confiança e acurácia respondem perguntas diferentes



A temperatura mudou a perda da CNN de **0,3040** para **0,3037**. A classe prevista ficou igual.

Teste oficial. Comprimento e calibração.

O mesmo enredo com três intervenções

Em *Signal 2040*, Bela encontra um teatro vazio e tenta montar uma apresentação com Evan.

-2	*The film's direction lacks coherence and the pacing feels disjointed.*
0	*The film's storytelling is engaging with a steady pace.*
$+2$	*The film offers a thoughtful blend of gentle storytelling and warm performances.*

Somamos αsv à ativação do bloco 28 durante a geração de `REVIEW`. O enredo e o prompt são os mesmos.

Qwen3-8B. Saídas integrais. Direção e controles.

APOIO

Quanto da frase cada filtro vê?

LARGURAS TREINADAS			PASSOS COM PESOS CONGELADOS		
k tokens por janela		ACURÁCIA	s tokens a cada avanço		ACURÁCIA
3	100 filtros	**81,27%**	**1**	100,0% das janelas	**82,00%**
5	100 filtros	**80,94%**	**2**	50,2% das janelas	**81,45%**
3/4/5	300 filtros	**81,95%**	**3**	33,6% das janelas	**80,97%**

Na frase A O filtro 89 cai de 0,98 para 0,40 ao usar passo 2.

Acurácias médias de três sementes em duas auditorias de 2.048 resenhas. Protocolos e métricas.