MAE5920 · INTRODUÇÃO A DEEP LEARNING

O que a CNN lê em uma resenha?

Sentimento e tokenização no IMDb

Nestor, Letícia e Gabriel



CLASSIFICAÇÃO DE SENTIMENTO

15 MINUTOS

Mesmas palavras. Outra conclusão.

FRASE A

I thought this movie was **terrible**, but it was **wonderful**.

FRASE B

I thought this movie was **wonderful**, but it was **terrible**.

A CNN acompanha a troca?

As duas frases têm as mesmas palavras. Mudamos a posição de *terrible* e *wonderful*.

O que cada divisão decide

	Treinar Pesos e vocabulário	**Escolher** Taxa e época	**Calibrar** Temperatura	**Medir** Avaliação final
Original	19.823	2.478	2.478	**25.000** Teste oficial
Extensões	6.144	1.536	—	**2.048** Auditoria interna

Nas extensões, a entrada tem até 128 palavras e 256 tokens.

IMDb, Maas et al. (2011). Dados e protocolo das extensões.

Como o BPE divide uma palavra rara

Entrada *The **pallbearer** scene was unexpectedly moving.*

CARACTERES DE PARTIDA

`p a l l b e a r e r</w>`

PRIMEIRA FUSÃO

`p a l l b e a re r</w>`

APÓS SETE FUSÕES

`p all bearer</w>`

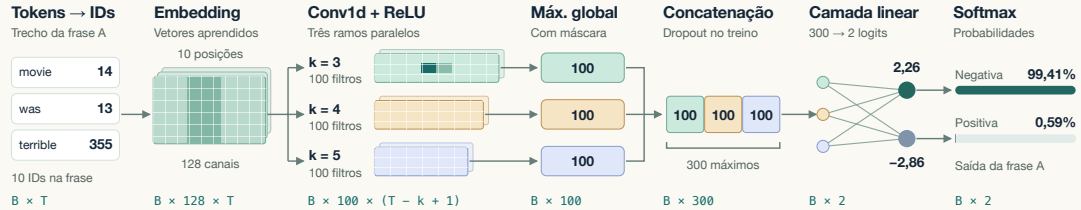
POR PALAVRAS

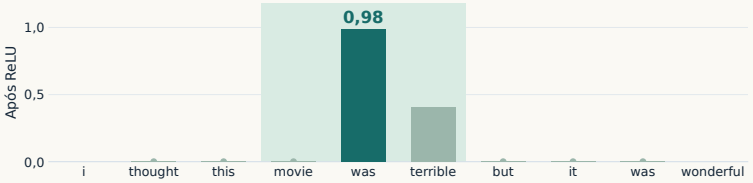
`<unk>`

pallbearer ficou fora do vocabulário.

O BPE aplica as fusões na ordem aprendida no treino. `</w>` marca o fim da palavra. Sennrich et al. (2016). Abrir animação.

Arquitetura da TextCNN





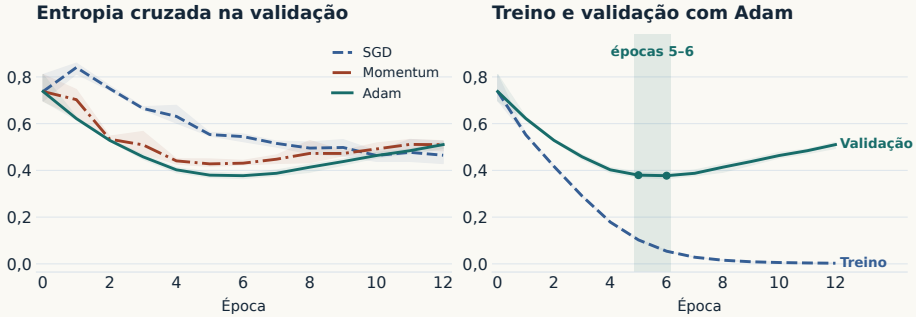
MÁXIMO DO FILTRO 89

0,98 → 0,40

O passo 2 pula a janela com o maior pico.

Frase A, semente 17. Mapas esquemáticos. Montagem com código. Varredura.

Quando guardar os pesos?

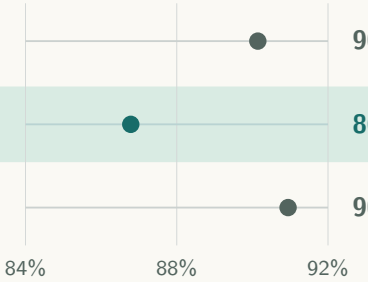


No Adam, guardamos os pesos das épocas 5 ou 6.

Três taxas por método, 12 épocas. Faixas mostram mínimo e máximo de três sementes. Curvas.

A CNN ficou atrás no teste oficial

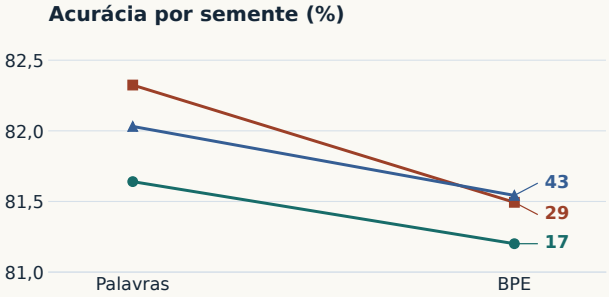
MODELO	ACURÁCIA	F1 MACRO	CE CAL.
TF-IDF + logística	90,14%	0,9014	0,2396
CNN	**86,78%**	0,8678	0,3037
BERT	90,94%	0,9094	0,2278



A CNN e o TF-IDF deram classes diferentes em **2.590 resenhas**.

25.000 resenhas. Temperatura ajustada em uma divisão separada. Métricas. Discordâncias.

BPE cobriu mais do vocabulário



TOKENS DESCONHECIDOS

3,27% → 0%

ACURÁCIA MÉDIA

82,00% → 81,41%

A mesma largura em tokens pode cobrir menos palavras quando usamos BPE.

2.048 resenhas na auditoria BPE. Cada linha liga a mesma semente nas duas receitas. Mesma CNN e Adam a 0,001. Resultados.

Dois adjetivos trocam de lugar

FRASE A

I thought this movie was **terrible**,
but it was **wonderful**.
Leitura esperada **positiva**

Os seis treinos previram negativa.
CNN palavras **1,0%** CNN BPE **1,2%**

FRASE B

I thought this movie was **wonderful**,
but it was **terrible**.
Leitura esperada **negativa**

Os seis treinos previram positiva.
CNN palavras **89,9%** CNN BPE **83,7%**

Dois tokenizadores $\times$ três treinos cada $=$ seis treinos.

Escores positivos médios, sementes 17, 29 e 43 em cada tokenizador. Abrir animação. Resultados por semente.

Quando o máximo apaga a troca

S = I have a few thoughts about this movie.

A S **I loved the acting.** S **I hated the ending.** S

B S **I hated the ending.** S **I loved the acting.** S

Mesmas janelas de 3, 4 e 5 → Mesmos máximos → **Logits idênticos**

Diferença máxima igual a zero em todos os treinos. Controle com as mesmas janelas.

Guardar a posição basta?

SEM POSIÇÃO

Menor pico | Maior pico

COM POSIÇÃO

Pico do início | Pico do fim

Em cada filtro, guardamos os mesmos dois valores e ajustamos a camada final.

ACERTO NAS DUAS VERSÕES DE CADA RESENHA

39,8% → 39,1%

344 pares editados por pessoas. Na troca de blocos, os escores diferiram e a classe ficou igual.

Três sementes, filtros congelados, 600 entradas nas duas cabeças. Experimento e controles.

A CNN leu a ironia como elogio

COMENTÁRIO NO TRAILER DE THE ROOM

"The best movie of the year" — **No one**

Classe positiva em 6 de 6 treinos

Em *Friday*, "AI could never do this" recebeu classe negativa nos seis treinos. A frase também admite uma leitura de admiração.

Comentários sem rótulo de referência. Cinco comentários e todas as sementes.

EXTENSÃO

O que muda com vetores contextuais?

ACURÁCIA NA AUDITORIA SEQUENCIAL

	SÓ A CABEÇA		AJUSTE COMPLETO
BERT-base	84,52%	⟶	**88,31%**
DistilBERT	83,35%	⟶	**86,80%**
ModernBERT-base	81,30%	⟶	**91,24%**

Os encoders combinam informações entre tokens antes da média. No ajuste completo, o treino também altera os pesos do encoder.

Qwen3-8B Enredo ⟶ ativação interna ⟶ opinião gerada

2.048 resenhas, três sementes por receita. Encoders. Geração com o Qwen.

APOIO

O fim da resenha ficou fora do recorte

1.715 Só TF-IDF acertou

875 Só CNN acertou

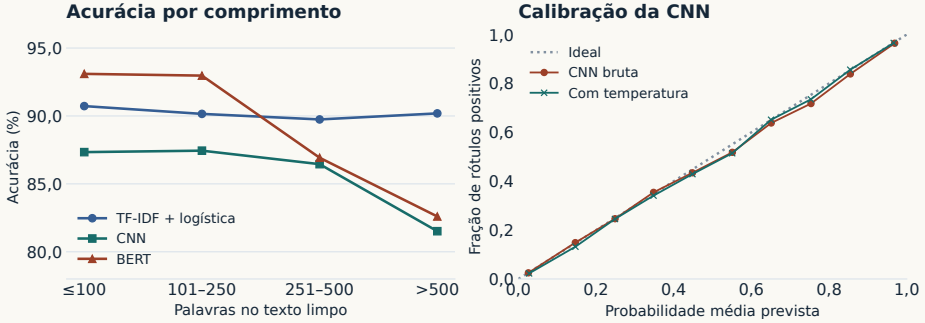
UMA RESENHA NEGATIVA DE 780 TOKENS

	TF-IDF	CNN
Primeiros 400 tokens	**71,7%**	**94,7%**
Texto inteiro	**6,5%**	**12,1%**

O trecho final muda a leitura. Com o texto inteiro, os dois escores positivos caem abaixo de 50%.

Mesmos pesos nos dois recortes. Exemplos e limites.

Confiança e acurácia respondem perguntas diferentes



A temperatura mudou a perda da CNN de **0,3040** para **0,3037**. A classe prevista ficou igual.

Teste oficial. Comprimento e calibração.

O mesmo enredo com três intervenções

Em *Signal 2040*, Bela encontra um teatro vazio e tenta montar uma apresentação com Evan.

-2	*The film's direction lacks coherence and the pacing feels disjointed.*
0	*The film's storytelling is engaging with a steady pace.*
$+2$	*The film offers a thoughtful blend of gentle storytelling and warm performances.*

Somamos αsv à ativação do bloco 28 durante a geração de `REVIEW`. O enredo e o prompt são os mesmos.

Qwen3-8B. Saídas integrais. Direção e controles.

APOIO

Quanto da frase cada filtro vê?

LARGURAS TREINADAS			PASSOS COM PESOS CONGELADOS		
k tokens por janela		ACURÁCIA	s tokens a cada avanço		ACURÁCIA
3	100 filtros	**81,27%**	**1**	100,0% das janelas	**82,00%**
5	100 filtros	**80,94%**	**2**	50,2% das janelas	**81,45%**
3/4/5	300 filtros	**81,95%**	**3**	33,6% das janelas	**80,97%**

Na frase A O filtro 89 cai de 0,98 para 0,40 ao usar passo 2.

Acurácias médias de três sementes em duas auditorias de 2.048 resenhas. Protocolos e métricas.