Sentimento em avaliações de filmes

Nestor, Letícia e Gabriel | Introdução a Deep Learning

Pergunta. Uma CNN e um BERT ajustado superam uma referência simples de TF-IDF? Em quais avaliações cometem falsos positivos e falsos negativos? Como exercício adicional, uma direção RFM/AGOP consegue controlar a saída do BERT?

Modelo	Acurácia	F1 macro	FP	FN
TF-IDF + logística	90.14%	90.14%	1234	1230
CNN	86.78%	86.78%	1818	1486
BERT-base	90.94%	90.94%	1342	922

Maior F1 macro observado no teste: BERT-base ajustado (90.94%). Diferença de acurácia BERT menos TF-IDF: +0.80 pontos percentuais. Uma execução por modelo, com limites de entrada diferentes.

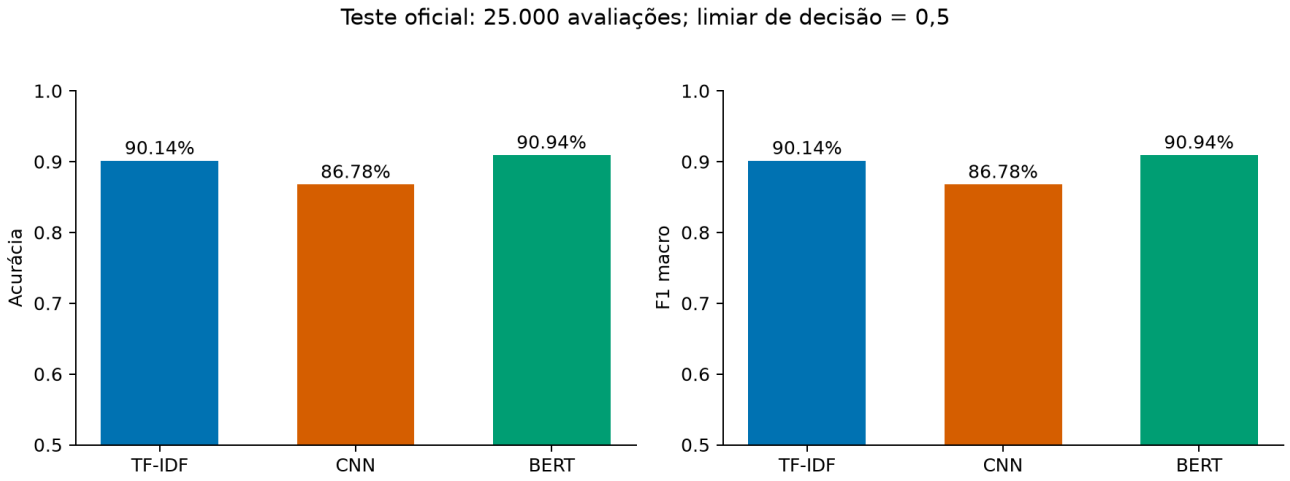


Figura 1. Teste oficial com 25.000 avaliações; limiar de decisão de 0,5.

Protocolo e integridade

Divisão	Avaliações	Papel
train	19823	Vocabulários e pesos
validation	2478	Hiperparâmetros e checkpoint
calibration	2478	Uma temperatura por modelo
test	25000	Avaliação final e análise descritiva

Fonte: stanfordnlp/imdb. Excluídas 123 linhas do treino que repetiam textos do teste e 98 repetições internas do treino. Não há texto normalizado idêntico entre divisões. O teste oficial retém 201 repetições internas.

Modelos, seleção e custo observado

Modelo	Representação e arquitetura	Escolha e orçamento
TF-IDF + logística	Unigramas e bigramas; até 80 mil características. Negação preservada.	C escolhido em 0,5 / 2 / 8: 8.0. Texto completo.
CNN	Embeddings de 128 dimensões, filtros 3/4/5, pooling com máscara de padding e dropout.	Até 400 palavras; cinco épocas; checkpoint de maior F1 na validação: época 5.
BERT-base	BERT-base-uncased pré-treinado, com ajuste integral e cabeça de duas classes.	Até 192 WordPieces; duas épocas; batch 32; lr 2e-5. Melhor época: 2.

O teste não escolhe modelos. A validação escolhe C e a época; a calibração ajusta probabilidades depois dessa escolha. Uma semente por modelo e uma busca pequena limitam as conclusões à configuração executada.

Treino e seleção

Modelo	Parâmetros ajustados	Treino (min)	Inferência* (min)	Hardware
TF-IDF + logística	80,001	0.22	0.00	Apple M1
CNN	2,714,502	2.33	0.35	Apple M1
BERT-base	109,483,778	7.44	2.50	NVIDIA GB10

*Inferência sobre as quatro divisões, com entradas já vetorizadas/tokenizadas. O tempo do TF-IDF já inclui 11.6 s de vetorização e a busca de C. Tempos de parede incluem validação no treino das redes. Os dispositivos e ambientes diferem; esta tabela não mede eficiência das arquiteturas em hardware idêntico.

Primeira época e checkpoint escolhido

Modelo	Época	Loss de treino	F1 de validação
CNN	1	0.6541	79.94%
CNN	5	0.3093	87.96%
BERT-base	1	0.3443	90.19%
BERT-base	2	0.1802	91.28%

Comparabilidade. O baseline vê a avaliação inteira; CNN e BERT veem prefixos diferentes. Diferenças de qualidade resultam também do pré-treinamento, do orçamento de entrada e da otimização. O código salva revisões de origem, configuração, pesos e previsões por exemplo.

Decisão e confiança são avaliações distintas

Ajustamos uma temperatura positiva por modelo em uma divisão separada, minimizando log loss. A transformação preserva a classe escolhida com limiar 0,5; sua finalidade é melhorar a interpretação das probabilidades.

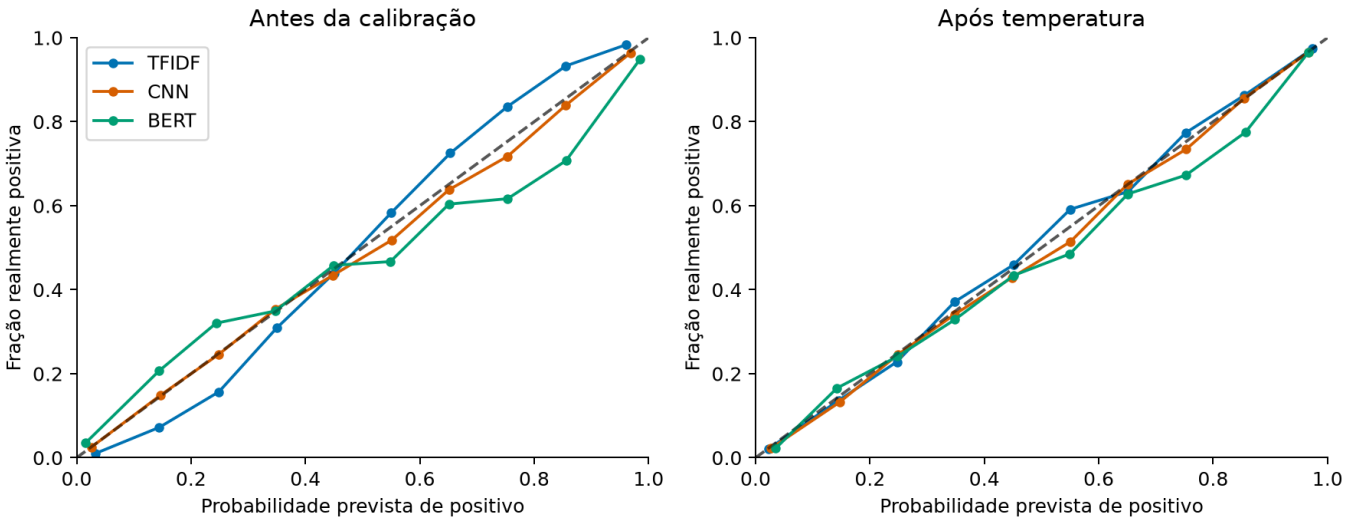


Figura 2. Confiabilidade antes e depois da temperatura; dez intervalos fixos.

Modelo	Probabilidade	Log loss	Brier	ECE (10)
TF-IDF + logística	Bruta	0.2531	0.0747	0.0428
TF-IDF + logística	Calibrada	0.2396	0.0721	0.0059
CNN	Bruta	0.3040	0.0941	0.0076
CNN	Calibrada	0.3037	0.0940	0.0066
BERT-base	Bruta	0.2433	0.0695	0.0366
BERT-base	Calibrada	0.2278	0.0670	0.0155

Como ler

Acurácia e F1 avaliam decisões; log loss e Brier penalizam probabilidades erradas, especialmente excesso de confiança. ECE compara confiança e frequência observada, mas depende dos intervalos escolhidos. Um valor pequeno de ECE isoladamente não garante calibração em cada subgrupo.

Não há rótulo neutro. O IMDb utilizado contém avaliações polarizadas. Uma probabilidade próxima de 0,5 significa incerteza do classificador. Os exemplos neutros das demonstrações finais são sintéticos e não constituem um teste de detecção de neutralidade.

Falsos positivos e falsos negativos

Classe positiva = avaliação positiva. **FP / tipo I:** avaliação negativa prevista como positiva. **FN / tipo II:** avaliação positiva prevista como negativa. As taxas condicionam no rótulo real: FPR = FP/(FP+TN); FNR = FN/(FN+TP).

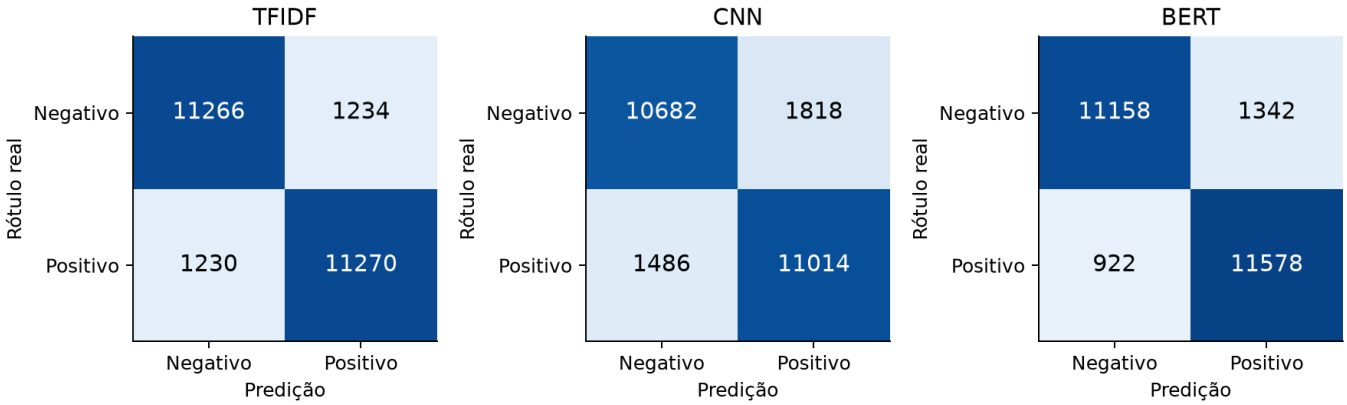


Figura 3. Contagens no teste; há 12.500 avaliações de cada classe.

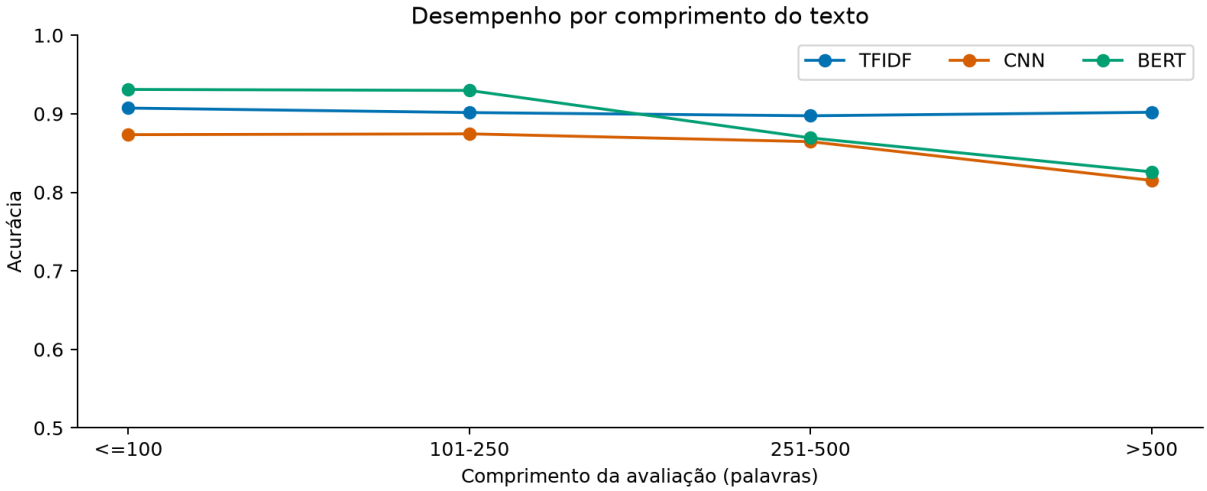


Figura 4. Desempenho por comprimento do texto completo, medido em palavras.

Palavras	n	TF-IDF	CNN	BERT
<=100	3246	90.73%	87.34%	93.10%
101-250	14624	90.15%	87.45%	92.97%
251-500	5285	89.74%	86.45%	86.93%
>500	1845	90.19%	81.52%	82.60%

Avaliações longas podem conter ressalvas, narrativas e conclusões depois do limite das redes. A associação entre comprimento e erro é descritiva: não isola o efeito causal do truncamento. As tabelas completas registram denominadores e intervalos de Wilson por classe.

Grupos semânticos e associações com erros

Um encoder independente, all-MiniLM-L6-v2, representa os textos. K-means aprende oito grupos em 2.500 avaliações do treino sem rótulos; os 25 mil exemplos do teste recebem esses grupos. Termos característicos também vêm do treino.

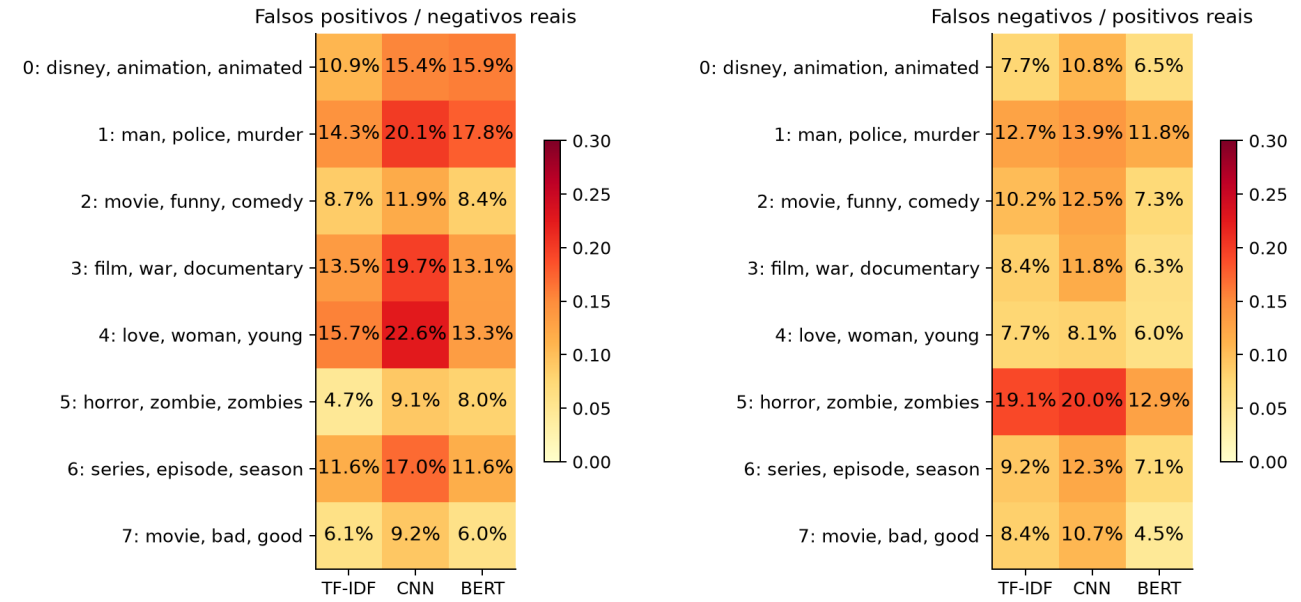


Figura 5. Taxas condicionais por grupo. Termos são descritores automáticos, não categorias humanas validadas.

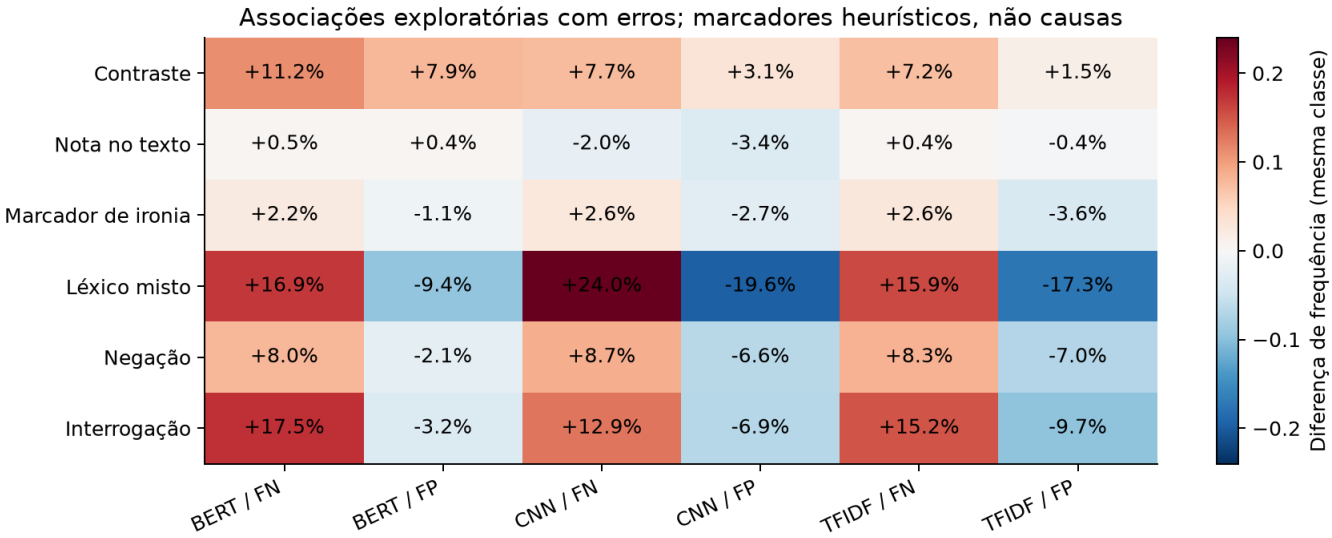


Figura 6. Frequência do marcador nos erros menos frequência nos acertos da mesma classe real.

FP é comparado a TN entre avaliações negativas; FN é comparado a TP entre positivas. Isso evita confundir características de uma classe com características de erro. Marcadores de negação, contraste, mistura lexical e possível ironia são heurísticos e sobrepostos. As associações geram hipóteses para leitura dos exemplos; não demonstram causas.

Quando o modelo de deep learning falha?

Abaixo, um FP e um FN de cada modelo, selecionados entre erros de alta confiança. São casos diagnósticos; não estimam a frequência dos padrões. Os textos completos e mais 30 exemplos, incluindo amostra aleatória de erros, acompanham os resultados.

Modelo / erro	Início da avaliação	Hipótese de leitura do texto completo
TF-IDF + logística / FP imdb_test_06245 P+ = 0.9997 404 palavras	Mickey Rourke hunts Diane Lane in Elmore Leonard's Killshot It is not like Mickey Rourke ever really disappeared. He has had a steady string of appearances before he burst back on the scene. He was memorable in: Domino, [...]	O texto recomenda Killshot e contém elogios diretos, além de elogios a outros filmes. O rótulo oficial negativo contrasta com essa leitura. É um rótulo discutível, não uma demonstração clara de falha semântica do classificador; o rótulo é preservado.
TF-IDF + logística / FN imdb_test_20621 P+ = 0.0008 213 palavras	This was Laurel and Hardy's last silent film for Roach Studios. However, since the public had a real thirst for "talkies", this same short was re-made by the team just a few years later with only a few small plot changes [...]	A avaliação rotulada positiva contém críticas explícitas: worst part, contrived and pointless, unconvincing e ended with a whimper. Há elogios pontuais a Laurel e Hardy. O escore negativo acompanha boa parte do conteúdo textual, mostrando a ambiguidade entre o tom do texto e seu rótulo agregado.
CNN / FP imdb_test_04118 P+ = 0.9993 60 palavras	This is definitely one of the best Kung fu movies in the history of Cinema. The screenplay is really well done (which is not often the case for this type of movies) and you can see that Chuck (in one of his first role)is [...]	O texto curto elogia o filme como um dos melhores do gênero e chama a luta final de masterpiece, mas seu rótulo oficial é negativo. A predição positiva parece compatível com a leitura; pode haver ruído ou inconsistência de rótulo. Não há truncamento neste exemplo.
CNN / FN imdb_test_20108 P+ = 0.0006 50 palavras	Great cult flick for MST-3K types: Richard Boone is a mess -- bad hair, arthritis, even his dark glasses aren't right; about as good as a bad dino-flick can get... actually, that charging saber-toothed Styracosaurus was [...]	A recomendação para fãs de filmes cult convive com a mess e repetidas ocorrências de bad. Great cult flick e pretty cool dão o enquadramento favorável. A leitura sugere humor e apreciação de um filme considerado ruim; a crítica lexical isolada pode enganar. O texto é curto, então truncamento não explica este caso.
BERT-base / FP imdb_test_03553 P+ = 0.9804 74 palavras	This film has the language, the style and the attitude down ... plus greats rides from Occy (a world champ) and the great Jerry Lopez. John Philbin as Turtle has the surf pidgin down, and the surfing scenes are still the [...]	O texto curto chama o filme de true classic e elogia as cenas de surfe como as melhores, mas o rótulo oficial é negativo. A leitura parece compatível com a predição positiva. É outro rótulo discutível, sem truncamento, e não uma falha semântica clara.
BERT-base / FN imdb_test_16175 P+ = 0.0179 203 palavras	Obviously made on the cheap to capitalize on the notorious "Mandingo," this crassly pandering hunk of blithely rancid Italian sexploitation junk really pours on the sordid stuff with a commendable lack of taste and restr [...]	Apreciação de cinema exploitation combina elogios com vocabulário depreciativo. O texto tem 320 WordPieces; o prefixo de 192 termina antes dos elogios à atuação, trilha e fotografia. O truncamento omite evidência favorável neste caso, mas não foi realizado um teste causal de seu efeito.

Confiança não é explicação. Termos positivos podem descrever atores, outro filme ou a premissa dentro de uma crítica negativa; ressalvas negativas podem aparecer numa avaliação globalmente positiva. Conferir o texto completo e o prefixo recebido pela rede é necessário antes de atribuir um erro a um mecanismo específico.

RFM / AGOP: controlar a saída do BERT

Adaptação de Beaglehole et al. ao token CLS de um encoder classificador. Ajusta-se regressão com kernel Laplaciano e atualiza-se a métrica pelo produto externo médio dos gradientes (AGOP). A direção é seu autovetor principal, orientado pela correlação com o rótulo positivo.

$K(x,z) = \exp[-\sqrt{(x-z)^T M (x-z)}/L]$
M seguinte = média de grad $f(h)$ grad $f(h)^T$

Seleção só na validação: bloco 9, largura 30.0, iteração 1. As atualizações recursivas seguintes pioraram a AUC de validação. Usam-se 512 exemplos de treino, 256 de validação e 256 de teste; AUC da sonda no teste: 0.950. A AGOP não é a Hessiana exata.

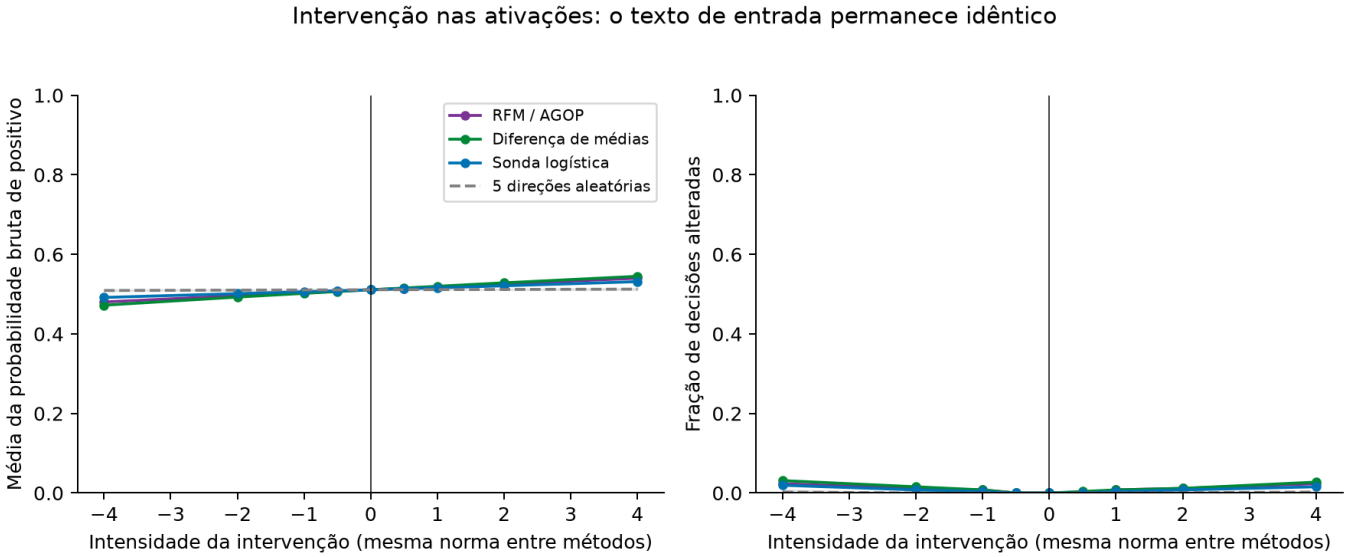


Figura 7. Intervenções com a mesma norma; média e faixa de cinco direções aleatórias. Texto de entrada idêntico.

Alfa	P(positivo) média bruta	Decisões alteradas
-4.0	0.480	2.34%
0.0	0.511	0.00%
4.0	0.540	2.34%

O que foi testado. Intensidade zero reproduz a saída original; o caminho com prefixo em cache coincide com o forward completo; hooks são removidos após a intervenção. Há controles de diferença de médias, sonda logística e direções aleatórias com a mesma escala aprendida no treino.

Interpretação. O efeito é modesto: 6 / 6 decisões mudaram em alfa -4 / +4 no conjunto de teste. A diferença de médias teve efeito igual ou maior, sem evidência de vantagem da RFM. Texto fixo não transforma o sentimento do autor. Probabilidades sob intervenção não têm calibração validada; gradientes e AGOP são do preditor kernel, não a Hessiana completa do BERT.

Edição de palavras e limites do exercício

Para modificar o texto de fato, usa-se uma etapa separada com exatamente o encoder ajustado do classificador. A transformação e o bias MLM vêm do pré-treinamento; a projeção de saída continua ligada aos embeddings ajustados. Duas palavras de opinião são mascaradas e preenchidas em sequência, sem reranqueamento por sentimento. Cinco sondas, sete intensidades e um controle aleatório produzem 70 condições, todas preservadas.

Sonda / alfa	Texto editado	Juiz TF-IDF	Juiz BERT
negative_a / -4	the acting was suspended and the story was suspended.	0.207	0.403
negative_a / 0	the acting was good and the story was good.	0.786	0.947
negative_a / 4	the acting was excellent and the story was wonderful.	0.998	0.969
neutral_a / -4	the movie was cancelled and the acting was cancelled.	0.350	0.369
neutral_a / 0	the movie was successful and the acting was praised.	0.096	0.905
neutral_a / 4	the movie was successful and the acting was excellent.	0.894	0.907

Os juízes acima avaliam as edições sem hooks. Todas as condições, as curvas agregadas e a similaridade semântica ao original estão no notebook e no relatório HTML.

Compare cada edição a alfa=0: o mascaramento por si só já troca palavras. Transferir uma direção de CLS para todos os tokens e para uma cabeça MLM pode falhar. Fluência, sentimento humano e preservação dos fatos exigem leitura; escores dos classificadores não substituem essa avaliação. Este exercício não é reescrita livre validada.

Leitura qualitativa. Alfa=+4 gerou elogios claros em negative_a, mas alfa=0 já gerava good/good. Em alfa=-4, acting was suspended muda fatos ou perde naturalidade. Houve controle parcial das escolhas lexicais, sem reescrita bidirecional confiável.

Limites e continuidade

Uma semente, modelos com diferentes limites de entrada, teste com repetições internas e amostras pequenas de steering. Próximos passos justificáveis: avaliar mais sementes, comparar limites de texto equivalentes e revisar amostras de erros/edições às cegas. Não selecionar novas configurações com os resultados deste teste.

Referências e reprodução

Maas et al. (2011), Learning Word Vectors for Sentiment Analysis.
Google BERT-base-uncased: modelo e tokenizer.
Beaglehole et al. (2025), Toward universal steering and monitoring of AI models.
Notebook executado, README, código PyTorch, dicionário de dados, previsões, configurações e testes acompanham o relatório. Fontes, revisões e hashes estão nos metadados.