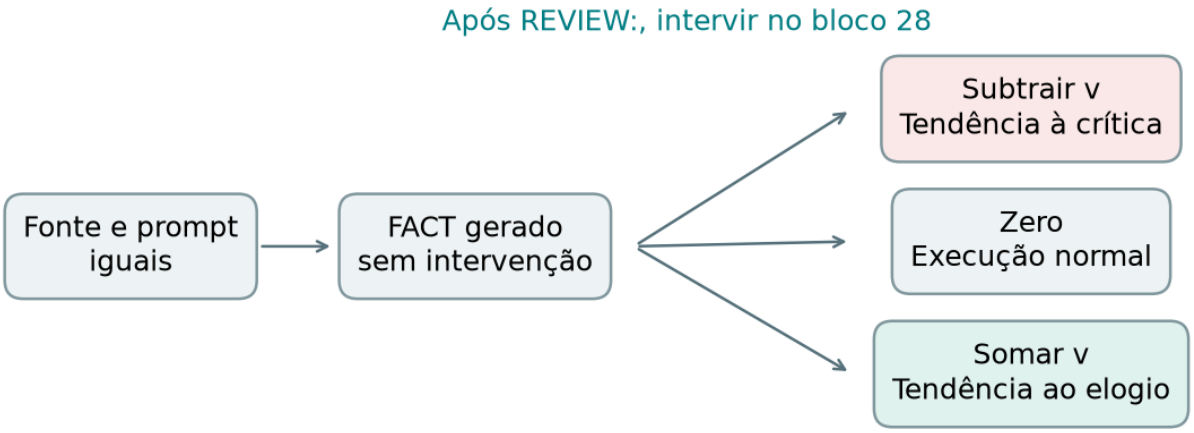
O que muda quando deslocamos uma ativação?

Nestor, Letícia e Gabriel | Introdução a Deep Learning

Pergunta didática: com a fonte, o prompt e os pesos do modelo fixos, como uma soma no estado interno altera o texto gerado? A analogia com modelos de imagem é a intervenção em representações. Não pressupomos um código global como o de uma GAN nem uma transformação invertível como a de um normalizing flow.



O mesmo Qwen, três papéis

Papel	Como usamos
Classificar	Um prompt pede negative ou positive; lemos os logits desses próximos tokens.
Revelar representações	Capturamos vetores contextuais de 4.096 dimensões depois de blocos do transformer.
Gerar	O modelo escreve FACT e REVIEW; alteramos as ativações somente ao produzir a opinião.

O Qwen3-8B permanece congelado: 8.190.735.360 parâmetros, nenhum treinável nesta execução. Não adicionamos uma cabeça de classificação. A primeira direção veio de uma RFM auxiliar; a direção de geração agora selecionada usa **diferença de médias**. São procedimentos diferentes.

O objetivo é demonstrar o mecanismo e seus limites, sem exigir que steering seja superior a uma instrução direta. Este relatório incorpora novas inferências e preserva o primeiro experimento no histórico.

Como descobrimos as direções?

Primeiro experimento: RFM e AGOP

1. Extraímos ativações de 512 resenhas IMDb rotuladas, em prompts de classificação.
2. Treinamos um preditor auxiliar RFM sobre essas ativações.
3. Calculamos seus gradientes em relação às ativações.
4. Formamos a AGOP, média de g g^T, e extraímos seu autovetor principal.
5. Orientamos o sinal pela correlação com os rótulos de treino. O bloco 24 foi escolhido na validação.

São gradientes do preditor auxiliar, não a Hessiana do Qwen. A AGOP identifica um eixo de sensibilidade; seu sinal precisa ser orientado. Somar e subtrair o mesmo vetor produz os dois sentidos de intervenção.

Direção selecionada para a geração: diferença de médias

Para cada um de 128 enredos de treino, criamos dois pedidos: escrever uma crítica positiva ou negativa. Extraímos a última ativação do prompt, antes de gerar. São 256 estados no bloco 28. A direção é a média dos estados com pedido positivo menos a média com pedido negativo, normalizada. As frases de opinião das referências não entram nessa extração.

Na demonstração, o pedido de sentimento é removido. Fonte e prompt são iguais nos três sentidos; somente o vetor muda. Os contrastes rotulados pertencem à etapa de descoberta da direção.

h alterado = h + alfa x s x v

Elemento	Configuração selecionada
v	Vetor unitário, 4.096 coordenadas; bloco 28
alfa	-2, 0, +2; escolhidos na validação
s	100.8510; escala fixada com dados de treino
Onde	Após o token gerado REVIEW:, nos próximos passos de geração. FACT e o marcador são gerados sem esse deslocamento.

Ler sentimento, alterar uma decisão e controlar uma sequência são problemas diferentes. Nenhuma destas direções é um eixo universal de sentimento.

Um enredo sem opinião

Mesma fonte: test_plot_000

Fonte

In the film Signal 2040, Bela, a pilot in a mountain village, discovers an empty theater. With help from Evan, Bela works to organize a performance before the town festival ends.

Intervenção negativa

FACT: In the film Signal 2040, Bela, a pilot in a mountain village, discovers an empty theater. With help from Evan, Bela works to organize a performance before the town festival ends.
REVIEW: The film's direction lacks coherence and the pacing feels disjointed.

Sem steering

FACT: In the film Signal 2040, Bela, a pilot in a mountain village, discovers an empty theater. With help from Evan, Bela works to organize a performance before the town festival ends.
REVIEW: The film's storytelling is engaging with a steady pace.

Intervenção positiva

FACT: In the film Signal 2040, Bela, a pilot in a mountain village, discovers an empty theater. With help from Evan, Bela works to organize a performance before the town festival ends.
REVIEW: The film offers a thoughtful blend of gentle storytelling and warm performances.

A tentativa de organizar uma apresentação é mantida nos três textos, sem inventar sucesso ou fracasso. REVIEW muda de crítica à direção e ao ritmo para elogio da narrativa e das atuações. FACT usa duas frases, embora o prompt peça uma.

Saídas integrais, sem edição ou seleção por qualidade. Os três casos foram definidos pela ordem do manifesto: primeiro enredo e primeira resenha de cada rótulo. A leitura qualitativa é do assistente, sem anotação humana independente.

Uma resenha originalmente negativa

Mesma fonte: imdb_test_01721

Fonte

I rented this movie with my friend for a good laugh. We actually got laughed at by the clerk at the video store because of our questionable movie tastes. Unfortunately, I don't remember the first half of the movie because all I did was stare at the giant metal braces Jane wore. and I didn't hear anything either due to the incomprehensible lisp. The other thing that was able to grasp my attention besides her metal mouth was her questionable fashion sense. This movie was made in 2005 but it seems like the wardrobe people jumped all the way back to 2000 for the clothes. If you remember the days when Aaron Carter was considered a "popstar" and you like high waisted jeans, ankle socks and knee length skirts, then this little trip down memory lane is perfect for you.

Intervenção negativa

FACT: The reviewer rented the movie with a friend, was laughed at by a clerk, couldn't hear dialogue due to a lisp, and noted questionable fashion and outdated wardrobe.
REVIEW: The film's lack of clarity and dated style detract from its overall effectiveness.

Sem steering

FACT: The reviewer rented the movie with a friend, was laughed at by a clerk, couldn't hear dialogue due to a lisp, and noted questionable fashion and outdated wardrobe.
REVIEW: The film's direction and performances lack clarity and coherence.

Intervenção positiva

FACT: The reviewer rented the movie with a friend, was laughed at by a clerk, couldn't hear dialogue due to a lisp, and noted questionable fashion and outdated wardrobe.
REVIEW: The film offers a unique visual experience with charming retro aesthetics and a distinctive, engaging performance.

A opinião muda de falta de clareza e estilo datado para elogio da estética retrô e da atuação. O prefixo permanece igual, mas ainda reproduz juízos da fonte, como questionable fashion; não é inteiramente neutro.

Saídas integrais, sem edição ou seleção por qualidade. Os três casos foram definidos pela ordem do manifesto: primeiro enredo e primeira resenha de cada rótulo. A leitura qualitativa é do assistente, sem anotação humana independente.

Uma resenha originalmente positiva

Mesma fonte: imdb_test_15518

Fonte

I caught this flick on the trail end of a tape I had used to capture a movie I truly wanted to wanted to see again. When I saw Raquel Welch's name in the opening credits, I decided to watch it. It was actually mildly entertaining, and took me back "in the wayback machine" to the farcical movies that Hollywood churned out during the sixties, much in the same genre as the current Austin Powers stuff. Oh the acting was not superb, nor was the plot, but it was worth watching. There was some delightful scenery, although Ms. Welch provided the most pleasant of such. Tape it if you get the chance and watch it when you have absolutely nothing else to do. It is not a snoozer, but it won't have you rolling in the aisles wanting more, either.

Intervenção negativa

FACT: The reviewer watched a film featuring Raquel Welch, found it mildly entertaining, and compared it to 1960s farcical movies and Austin Powers.
REVIEW: The film's pacing and direction feel overly generic and unoriginal.

Sem steering

FACT: The reviewer watched a film featuring Raquel Welch, found it mildly entertaining, and compared it to 1960s farcical movies and Austin Powers.
REVIEW: The film offers a nostalgic, if uneven, experience with charm and decent scenery.

Intervenção positiva

FACT: The reviewer watched a film featuring Raquel Welch, found it mildly entertaining, and compared it to 1960s farcical movies and Austin Powers.
REVIEW: The film offers a nostalgic blend of light-hearted fun with charming visuals and a warm performance from Raquel Welch.

O sentido negativo critica ritmo e direção genéricos; o positivo elogia humor leve, imagens e atuação de Raquel Welch. Há mudança clara de avaliação; o resumo comum ainda relata a opinião do primeiro autor.

Saídas integrais, sem edição ou seleção por qualidade. Os três casos foram definidos pela ordem do manifesto: primeiro enredo e primeira resenha de cada rótulo. A leitura qualitativa é do assistente, sem anotação humana independente.

O efeito se mantém em fontes reservadas?

Configuração congelada antes de gerar o teste: 64 fontes novas para esta etapa, sendo 32 resenhas reais e 32 enredos neutros sintéticos. Onze condições produzem 704 textos. Todas as saídas são mantidas; não há reranqueamento nem novas tentativas por qualidade.



Figura: proporção de fontes em que os dois sentidos foram identificados como as opiniões-alvo. Diagnóstico automático pelo mesmo Qwen sem steering. Nos textos estruturados, ele lê o campo REVIEW; FACT é avaliado separadamente quanto a suporte factual. Não é acurácia contra avaliação humana independente.

Condição	Ambos os sentidos: média [IC 95%]
Nova direção, só opinião	85,9% [75,4%; 92,4%]
Direção original, todas as posições	0,0% [0,0%; 5,7%]

Verificação	Negativa	Positiva
Opinião-alvo reconhecida	90,6%	92,2%
Sem alerta factual pelo juiz automático	64/64	54/64
Trecho factual e seus tokens iguais ao zero	64/64	64/64
Limites de geração atingidos	0	0

Intervalos descritivos: Wilson para proporções; 5.000 reamostragens pareadas das fontes para diferenças. O prompt é igual entre os controles, mas direção, bloco, amplitude e local de aplicação mudam juntos em relação ao controlador original. TF-IDF, CNN e BERT leem também o texto completo.

O que aprendemos e o que permanece limitado

O treino pequeno explica a primeira falha?

A direção original já separava bem os rótulos em classificação: AUC de aproximadamente 0,977 na validação. Isso enfraquece a hipótese de que faltou apenas treinar o scorer. A transferência para escrita era mais fraca; contexto, posição e orçamento de entrada mudavam juntos. Não isolamos uma causa única.

Testamos 128, 512 e 2.048 exemplos auxiliares, diferentes blocos, contextos e posições. Mais dados ajudaram algumas representações, mas não resolveram sozinhos a geração. A solução selecionada combina uma direção encontrada no contexto de escrita com a aplicação localizada na opinião.

As novas variantes RFM usam covariância de gradientes centrados, diferente da AGOP bruta original; suas curvas não equivalem a apenas aumentar o treino da mesma sonda original.

Fatos preservados pelo deslocamento não equivalem a fatos corretos

O prefixo FACT ficou idêntico entre zero e as intervenções. Isso impede que o steering mude esse trecho, mas o modelo sem steering pode ter resumido a fonte incorretamente. A frase REVIEW ainda pode acrescentar detalhes indevidos. Por isso, avaliamos fatos e opinião separadamente e mantemos os erros no material.

Na leitura dos casos reservados, a versão positiva de imdb_test_05223 inventa uma cidade pequena e uma época mágica do ano. Em imdb_test_22261, o resumo comum fica ambíguo sobre quem critica a aparência de Harrison Ford. São problemas preservados na nova opinião e no resumo sem intervenção.

O juiz sinalizou dez opiniões positivas por fatos. Na releitura do assistente, nove alertas parecem confundir uma avaliação diferente com erro factual, como elogiar atuações que a fonte criticava. Não corrigimos automaticamente os números: o juiz é um diagnóstico, não uma garantia de verdade.

Controles e leitura

Zero reproduz a execução normal; retirar os hooks restaura o modelo. Verificamos independência entre linhas do lote e identidade dos tokens factuais. Três direções aleatórias têm a mesma norma e o mesmo local de aplicação da nova direção. O assistente leu os 12 trios definidos antes do teste. As 32 fontes antigas também foram reavaliadas após congelar a seleção.

Limites do alcance

Um modelo, geração gulosa curta e um formato com campos explícitos. O resultado não demonstra controle geral de texto livre. O juiz semântico é o mesmo modelo-base; seus escores não são confiança calibrada. As resenhas vêm de um benchmark já usado no projeto, e exposição no pré-treinamento não foi auditada. Há busca extensa na validação, mas o novo teste de geração não escolheu a configuração.

Reprodução

O notebook lê resultados reais e reconstrói a direção selecionada em CPU; não precisa carregar o Qwen. Repetir a inferência requer os pesos públicos e CUDA. As fontes, prompts, tokens, vetores, escolhas congeladas e hashes acompanham o pacote. O primeiro relatório e notebook ficam em results/qwen_improved/previous_didactic.

Modelo oficial Qwen3-8B | Qwen3 Technical Report | RFM / AGOP | Contrastive Activation Addition | IMDb Stanford