O que muda quando alteramos uma ativação?

Nestor, Letícia e Gabriel | Introdução a Deep Learning

Pergunta didática. Mantendo os pesos e a entrada fixos, o que acontece com as decisões e com o texto gerado quando deslocamos uma representação interna de um modelo de linguagem?

A proposta estende a discussão de intervenções em espaços latentes de modelos de imagem. O objetivo é compreender e demonstrar o mecanismo e seus limites. **Não é necessário mostrar que steering supera prompting.**

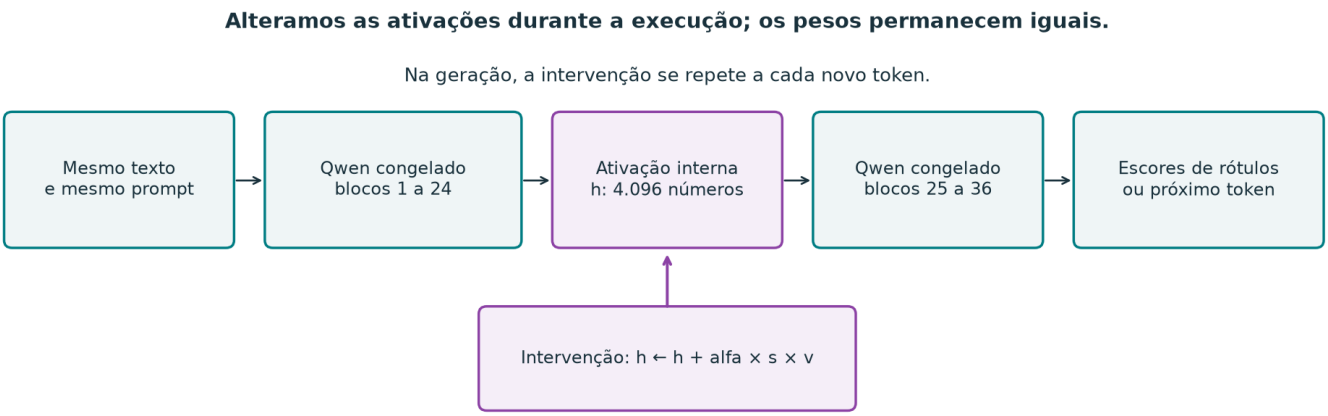


Figura 1. Esquema do ponto de intervenção. Na geração, o ciclo continua token por token; nenhum peso do Qwen é atualizado.

Papel do mesmo Qwen congelado	O que observamos ou fazemos
Classificar	O prompt pede negative ou positive. Lemos os escores desses dois próximos tokens.
Fornecer representações	Capturamos vetores contextuais de 4.096 dimensões em camadas internas.
Gerar texto	O modelo escreve uma crítica. Somamos a direção às ativações a cada passo.

O que foi aprendido?

Um preditor auxiliar RFM aprende sobre ativações de 512 resenhas rotuladas; dele extraímos uma direção associada a sentimento. O Qwen3-8B mantém seus pesos. Não adicionamos uma cabeça de classificação nem fazemos fine-tuning.

Este relatório reorganiza resultados existentes. Não houve nova inferência, alteração dos exemplos gerados ou seleção de uma nova direção a partir dos resultados apresentados.

Do vetor interno à intervenção

Uma ativação não é apenas o embedding da palavra

O transformer calcula um vetor contextual por posição e por camada. Para aprender a direção, extraímos a última posição do prompt depois dos blocos 12, 24 e 32. Cada vetor tem 4.096 coordenadas e depende da resenha e das instruções. Não manipulamos a tabela de embeddings de entrada.

Como aprendemos uma direção

1. Usamos ativações de 512 exemplos de treino com rótulos de sentimento.
2. Ajustamos um preditor auxiliar com kernel, a RFM.
3. Calculamos a AGOP, média dos produtos externos dos gradientes desse preditor, e extraímos seu autovetor principal.
4. Orientamos o vetor para correlação positiva com os rótulos de treino. Camada e parâmetros são escolhidos na validação.

São gradientes do preditor auxiliar, não a Hessiana do Qwen. A direção é operacional e dependente do contexto, sem garantia de um eixo universal de sentimento.

h modificado = h original + alfa × s × v

Elemento	Significado nesta execução
h	Ativação depois do bloco 24; as camadas 25 a 36 continuam o processamento.
v	Direção unitária de 4.096 dimensões, extraída da AGOP.
s	Escala calculada somente nas ativações de treino.
alfa	Sentido e intensidade: -4, 0 e +4 nos exemplos centrais. Zero não desloca a ativação.
Onde somamos	Todas as posições válidas do prompt e cada novo token durante a geração.

A ligação com GANs e normalizing flows

Modelo	O que a analogia permite dizer
GAN	Uma direção no código latente pode alterar a imagem produzida pelo gerador.
Normalizing flow	Há uma transformação invertível entre dados e representação latente.
Transformer aqui	Intervimos nas representações internas por token e camada. Não pressupomos um único código global ou uma transformação invertível.

Mesma resenha, outra decisão

O prompt pede uma palavra: negative ou positive. Lemos os dois logits de próximo token e normalizamos somente entre eles: P(positivo) = exp(l+) / [exp(l+) + exp(l-)]. Isso não é JSON nem uma nova cabeça classificadora.

Os textos abaixo são completos e não foram truncados. A resenha e o prompt são iguais nas três condições. O que muda é a soma nas ativações. As probabilidades sob intervenção são escores restritos, sem calibração validada.

imdb_test_00718 | rótulo original: negativo

> This movie is a cinematic collage of gangster clichés. The writing is grade z and the plot and story are constructed without care or logic. It a messy pastiche of stereotypical gangsters (think of Bugs Bunny cartoons) and silly supporting characters (the lady doctor and the writer). There are much better Bogart films out there. In fact, Bogart looks like he slept through this performance. He puts very little effort into this character. I think the directorial advice he received was something like "He's a bad guy. Act bad". This guy is the era's equivalent of Darth Vader; obvious, evil and the anti-hero. Don't waste your time with this one.

Condição	Alfa	Logit l+ - l-	Escore P(+)	Decisão
Negativa	-4	-22.25	<0,001	negative
Sem steering	+0	-18.00	<0,001	negative
Positiva	+4	15.25	>0,999	positive

imdb_test_19691 | rótulo original: positivo

> Wow! I picked this off the rental shelf because I loved Robert Carlyle and Jonny Lee Miller in 'Trainspotting.' This is a phenomenal movie; it has action, romance, suspense, intrigue and wit. When I wasn't laughing, I was at the edge of my seat. This is definitely a film I would recommend to people with an appreciation for intelligent dialogue and a fresh perspective of the 18th century. This film has everything to keep ME happy!

Condição	Alfa	Logit l+ - l-	Escore P(+)	Decisão
Negativa	-4	-17.25	<0,001	negative
Sem steering	+0	15.75	>0,999	positive
Positiva	+4	19.25	>0,999	positive

O que isso mostra? A intervenção altera a resposta do modelo. A opinião expressa pelo autor no texto original permanece igual. Mudar a decisão não demonstra, por si só, controle sobre uma sequência gerada.

Seleção: primeiro exemplo de cada rótulo na ordem do subconjunto reservado, com 40 a 150 palavras e sem truncamento. A escolha não depende do efeito do steering. Escores extremos são mostrados com desigualdades para evitar confundir arredondamento com certeza.

Geração: descrição sem opinião

Prompt fixo: escrever duas frases em inglês avaliando o filme, preservando nomes, acontecimentos e cenário. O prompt não pede sentimento positivo nem negativo. Geração gulosa, até 96 novos tokens.

Mesma fonte: neutral_01

Maya is a radio astronomer at a mountain station. During a storm, she and a technician repair a transmitter before the station loses contact with a nearby town.

Intervenção negativa | alfa = -4

The film effectively captures the isolation and tension of Maya's remote work, highlighting her resourcefulness during the storm. The setting enhances the film's atmosphere, emphasizing the vulnerability of communication in harsh natural conditions.

Sem steering | alfa = 0

The film offers a tense and atmospheric portrayal of Maya's work as a radio astronomer in a remote mountain setting. The storm-driven plot brings her and the technician together in a race against time to prevent a critical communication failure.

Intervenção positiva | alfa = +4

The film follows Maya, a dedicated radio astronomer, as she and a technician work together to repair a transmitter during a storm, ensuring communication with a nearby town. The setting on a remote mountain station adds a sense of isolation and urgency to their mission.

O que observar

A fonte descreve acontecimentos, sem avaliar o filme. A intervenção negativa ainda produz elogios como “effectively captures” e “enhances”. A positiva fica mais descritiva. Há mudança de formulação, mas não uma inversão confiável de sentimento.

“Positiva” e “negativa” nomeiam o sentido da intervenção; não garantem o sentimento da saída. Fonte e saídas são integrais e sem edição. Leitura qualitativa do assistente, sem anotação humana independente.

As fontes demonstrativas são neutral_01 e a primeira resenha oficial de cada rótulo na ordem do manifesto. A escolha não depende da mudança de sentimento. A fonte neutra foi escrita para a demonstração, não é uma classe neutra do IMDb.

Geração: resenha negativa

Prompt fixo: escrever duas frases em inglês avaliando o filme, preservando nomes, acontecimentos e cenário. O prompt não pede sentimento positivo nem negativo. Geração gulosa, até 96 novos tokens.

Mesma fonte: imdb_test_08426

I saw the trailer for this film before watching Titanic, and I must admit that it whetted my appetite. Volcano seemed to be quite spectacular and full of promise. But what a damp squib. Corny is not the word for the script, and the characterizations are often ludicrous. The stupid daughter is just beyond belief - she is supposed to be 13 not 4. But then the scientists,firemen and peripheral characters don't offer any more. This movie ranks just in front of Cruise II and Twister, but only because those 2 films are completely appalling. This does have some reasonable effects, but overall its a 1 out of 10. Don't waste your time

Intervenção negativa | alfa = -4

The film *Volcano* starts with a promising trailer that hints at a chaotic and entertaining disaster movie, but it quickly falls apart with a weak script and poorly developed characters. Despite some decent special effects, the movie is ultimately a disappointing experience that fails to live up to its initial potential.

Sem steering | alfa = 0

The film promised a spectacular and engaging experience, but ultimately delivers a disappointingly weak and poorly written story. While it has some decent visual effects, the script is corny and the characters are largely unconvincing, making it a frustrating watch.

Intervenção positiva | alfa = +4

The film initially seemed promising with its spectacular visuals and intriguing premise, but it ultimately falls flat with a weak script and unconvincing character portrayals. While it has some decent special effects, the overall experience is disappointing and not worth the time.

O que observar

As três saídas mantêm uma avaliação negativa. A intervenção positiva não transforma a crítica em elogio. O texto muda, mas o sinal da intervenção não determina o sentimento observado.

“Positiva” e “negativa” nomeiam o sentido da intervenção; não garantem o sentimento da saída. Fonte e saídas são integrais e sem edição. Leitura qualitativa do assistente, sem anotação humana independente.

Geração: resenha positiva

Prompt fixo: escrever duas frases em inglês avaliando o filme, preservando nomes, acontecimentos e cenário. O prompt não pede sentimento positivo nem negativo. Geração gulosa, até 96 novos tokens.

Mesma fonte: imdb_test_18461

I must I was a little skeptical when I entered the cinema to watch OSS117 : french comedies tend to be so self-satisfied nowadays that only the most stupid ones score high at the national box-office. But I was surprised that though the humor does not always reach the level of the Monthy Pythons, the many references to the French's vision of the world in the 1950, which OSS117 represents, are hilarious et the director managed to recreate film-making style of that time with an astonishing fidelity. To put it short, a bit of a good surprise, not to mention the excellent performances from various secondary actors. And at least for once, Jean Dujardin's style (which can get on many people's nerves) complies perfectly with the character he plays.

Intervenção negativa | alfa = -4

OSS117 offers a delightful blend of humor and historical parody, capturing the comedic style of 1950s French cinema with remarkable accuracy. The film delivers a solid surprise, featuring strong supporting performances and a well-balanced portrayal of Jean Dujardin's comedic style.

Sem steering | alfa = 0

The film offers a delightful surprise with its clever homage to 1950s French cinema, capturing the style and humor of the era with impressive accuracy. Jean Dujardin's performance is particularly well-suited to the character, blending seamlessly with the film's nostalgic tone.

Intervenção positiva | alfa = +4

The film was a pleasant surprise, offering a nostalgic recreation of 1950s French cinema with impressive fidelity and humor that, while not reaching the heights of Monty Python, is still highly entertaining. The performances, particularly from the secondary cast, and Jean Dujardin's fitting portrayal of his character, add to the overall charm of the movie.

O que observar

As três saídas continuam favoráveis. Mesmo sob intervenção negativa aparecem elogios como “delightful” e “remarkable”. A direção aprendida no contexto de classificação não controla consistentemente o tom nesta tarefa de escrita.

“Positiva” e “negativa” nomeiam o sentido da intervenção; não garantem o sentimento da saída. Fonte e saídas são integrais e sem edição. Leitura qualitativa do assistente, sem anotação humana independente.

Intervir na decisão e na geração

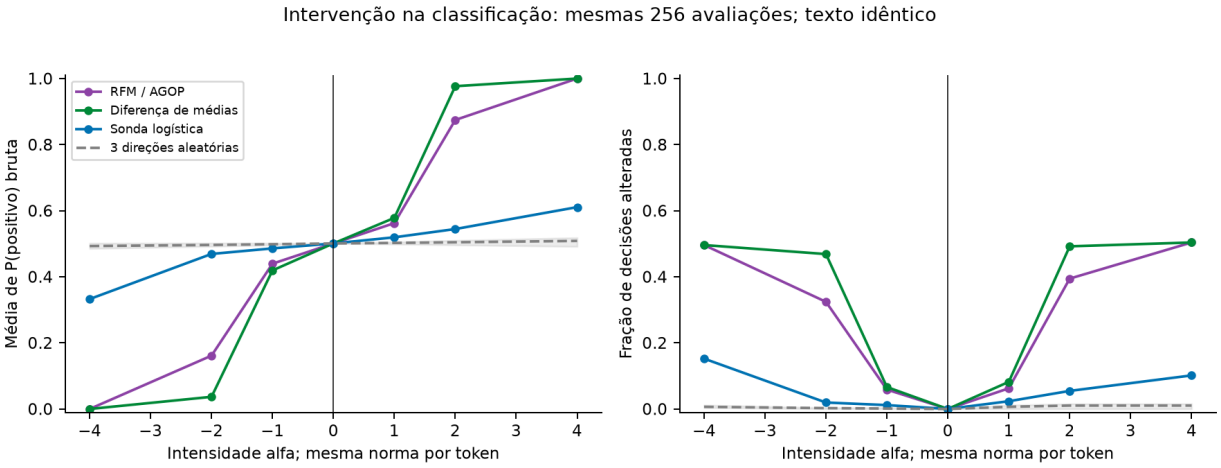


Figura 2. Mesmas 256 resenhas, texto idêntico. As curvas mostram decisões e escores sob intervenção, não mudança da opinião original.

Com alfa -4, todas as decisões ficaram negativas; com alfa +4, todas positivas. Em relação à execução normal, foram alteradas 127 e 129 decisões, respectivamente. A direção por diferença de médias também produziu esse efeito. O controle com zero reproduz os escores originais.



Figura 3. Mudança média dos escores das saídas em relação à geração sem steering da mesma fonte. Há 32 fontes por condição; os avaliadores rodam sem intervenção.

Na geração livre, a polaridade não mudou consistentemente. A direção foi aprendida em prompts de classificação e aplicada também em prompts de escrita. A dependência de contexto é uma hipótese explicativa, não uma causa demonstrada.

A conclusão para o seminário

Ler uma propriedade nas ativações, alterar uma decisão e controlar o significado de um texto inteiro são tarefas diferentes. O experimento demonstra uma intervenção interna real e os limites observados nesta configuração. Não precisamos eleger uma técnica vencedora para explicar esse mecanismo.

Escopo, controles e reprodução

Onde entram as instruções diretas?

Servem para comparar o local da intervenção: entrada textual versus estado interno. Nesses controles, o prompt pede explicitamente sentimento positivo ou negativo e não há hook. Eles não integram o trio de prompt idêntico. Também preservamos controles por diferença de médias, sonda logística e três direções aleatórias.

O que foi medido

Qwen3-8B em BF16 e modo sem raciocínio. RFM com 512 exemplos de treino; escolhas em 256 da validação; intervenções de classificação em 256 do teste. Geração: 24 resenhas oficiais curtas e oito descrições neutras sintéticas, em 17 condições, totalizando 544 saídas. Nenhuma saída foi descartada ou reranqueada.

Contexto: teste oficial	Acurácia	F1 macro
TF-IDF + logística	90.14%	90.14%
CNN	86.78%	86.78%
BERT-base ajustado	90.94%	90.94%
Qwen3-8B congelado	95.26%	95.26%

São 25.000 avaliações. Qwen recebe até 768 tokens da fonte; BERT usa 192 WordPieces e ajuste supervisionado. A comparação não isola arquitetura, pré-treinamento ou orçamento de entrada. O resultado é contexto, não a pergunta central.

Limites e verificação

Uma configuração e conjunto pequeno de geração. Os juízes automáticos não estabelecem fluência ou preservação factual. Não houve anotação humana independente. O teste foi reutilizado de uma etapa anterior; possível exposição ao IMDb no pré-treinamento não foi auditada. A camada foi escolhida por classificação, não por geração.

A execução original verificou hook zero, restauração dos hooks e equivalência entre continuação em cache e execução completa. Esta revisão confere as saídas com os arquivos de origem e executa o notebook de leitura, sem carregar o modelo.

Como usar e reproduzir

O notebook executado mostra os trios lado a lado e permite escolher outra fonte entre as 32. O HTML mantém a galeria completa, métricas e auditorias no apêndice. O protocolo está em QWEN_EXPERIMENTO.md. O notebook lê os resultados incluídos sem GPU; repetir a inferência exige CUDA e os pesos públicos.

Fontes

Qwen3-8B: modelo oficial. Qwen3 Technical Report.
Beaglehole et al.: RFM / AGOP. Implementação dos autores.
Maas et al.: Large Movie Review Dataset (IMDb).